

h_da
HOCHSCHULE DARMSTADT
UNIVERSITY OF APPLIED SCIENCES

Hochschule Darmstadt

– Fachbereich Informatik –

Untersuchung der Steigerung der Usability durch Einführung eines Dashboards in den Legacy-Testpoolmonitoring-Prozess

Abschlussarbeit zur Erlangung des akademischen Grades

Bachelor of Science (B. Sc.)

vorgelegt von

Sandra Gräf

Matrikelnummer: 1111826
sandra.graef@stud.h-da.de

Referent	:	Prof. Dr. Marcus Zinn
Korreferent	:	Prof. Dr. Stefan T. Ruehl
Abgabedatum	:	08. September 2025

Sandra Gräf: *Untersuchung der Steigerung der Usability durch Einführung eines Dashboards in den Legacy-Testpoolmonitoring-Prozess*, Eine Nutzerstudie zur Analyse der Effektivität, Effizienz und Zufriedenheit, © 08. September 2025

ERKLÄRUNG

Ich versichere hiermit, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von mir selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

Darmstadt, 08. September 2025

Sandra Gräf

ABSTRACT

This bachelor thesis investigates the suitability and significance of the presented dashboard solution as a modernization measure to sustainably improve the usability of legacy monitoring processes. The term *usability* is defined by DIN EN ISO 9241-110 and subdivided into the three dimensions of *effectiveness*, *efficiency*, and *user satisfaction*. The basis of this study is the inefficient usability of the result view of a legacy test pool, which is nevertheless used for daily system status monitoring.

To evaluate the suitability of the newly developed dashboard, its impact on the improvement of the three usability dimensions was examined. For this purpose, a two-part user study was conducted and its results statistically evaluated. The first part of the study consisted of a user survey, whose questionnaire was based on Jochen Prümper's survey to verify the implementation of the design recommendations of DIN EN ISO 9241-110. The second part comprised a task-based usability test derived from the survey, which in turn formed the basis for the users' evaluation of the system.

Within the user study, the new interface, which compresses the test results of many views of the legacy system into just two, convinced with a clear and intuitive presentation. This led to shorter processing times and greatly improved user satisfaction. Although the dashboard was the cause of an increased error rate in the usability test, an overall improvement of the monitoring process was evident. The solution is therefore classified as a suitable and non-invasive modernization method, but shall serve exclusively as an initial step toward system optimization within the modernization process.

ZUSAMMENFASSUNG

Die vorliegende Bachelorarbeit untersucht die Eignung und Bedeutung der vorgestellten Dashboard-Lösung als Modernisierungsmaßnahme, um die Usability von Legacy-Monitoring-Prozessen nachhaltig zu verbessern. Der verwendete *Usability*-Begriff wird durch die DIN EN ISO 9241-110 definiert und in die drei Dimensionen *Effektivität*, *Effizienz* und *Nutzerzufriedenheit* unterteilt. Grundlage der Untersuchung ist die ineffiziente Nutzungsmöglichkeit der Ergebnisanzeige eines Legacy-Testpools, die dennoch zum täglichen Monitoring des Systemzustands verwendet wird.

Zur Bewertung der Eignung des neu entwickelten Dashboards wurde dessen Einfluss auf die Verbesserung der drei Usability-Dimensionen im Monitoring untersucht. Dafür wurde eine zweiteilige Nutzerstudie durchgeführt und deren Ergebnisse statistisch ausgewertet. Der erste Teil der Studie bestand aus einer Nutzerbefragung, deren Fragenkatalog auf dem Fragebogen von Jochen Prümper zur Überprüfung der Umsetzung der Gestaltungsempfehlungen der DIN EN ISO 9241-110 basiert. Der zweite Teil umfasste einen darauf aufbauenden, aufgabenbasierten Usability-Test, der wiederum die Grundlage für die Bewertung des Systems durch die Nutzer bildete.

In der Nutzerstudie konnte die neue Oberfläche, welche die Testergebnisse vieler Ansichten des Altsystems auf zwei komprimiert, durch eine klare und intuitive Darstellung überzeugen. Dies führte zu kürzeren Bearbeitungszeiten und deutlich verbesserter Nutzerzufriedenheit. Obwohl das Dashboard im Usability-Test die Ursache einer erhöhten Fehlerquote war, ist insgesamt eine Verbesserung des Monitoring-Prozesses erkennbar. Die Lösung wird daher als eine geeignete und nicht invasive Modernisierungsmethode eingestuft, dient im Modernisierungsprozess jedoch ausschließlich als erster Schritt zur Systemoptimierung.

Hinweis: *In dieser Arbeit wird aus Gründen der besseren Lesbarkeit das generische Maskulinum verwendet. Weibliche und anderweitige Geschlechteridentitäten werden dabei ausdrücklich mitgemeint, soweit es für die Aussage erforderlich ist.*

DANKSAGUNG

Ich möchte mich hiermit ganz herzlich bei allen Personen bedanken, die mich tatkräftig bei der Erstellung dieser Arbeit unterstützt und motiviert haben.

Zuerst möchte ich *Prof. Dr. Marcus Zinn* danken, der mir auf Hochschulseite beistand. Dafür, dass er mein Thema zum betreuen gewählt hat, dass er mir nochmal neu aufgezeigt hat, was es bedeutet, eine wissenschaftliche Arbeit zu schreiben und dafür, dass er für jede Frage bereit stand.

Ich möchte weiterhin *Dr. Elisabeth Brandenburg* danken, die mich als wissenschaftliche Betreuerin unterstützt hat. Dafür, dass sie mir den Einstieg in die psychologische Seite - der Usability-Begriff an sich, das Vorstellen der ISO-Norm und die Einführung in die benötigte Statistik - dieser Forschung gelehrt und ermöglicht hat. Dafür, dass sie mir geholfen hat, meine Gedanken in die richtigen Kapitel zu sortieren und meinen Fokus immer wieder auf das Ziel gelenkt hat.

Auch Danke an meine beiden Betreuer *Marcus Schütz* und *Marcel Schmall*, die mir auf der Firmenseite beistanden, welche ihr fachliches Wissen zu den Systemen und dessen Zusammenspiel geteilt und immer wieder erklärt haben, bis ich es richtig wiedergeben konnte. An dieser Stelle geht auch ein großer Dank an das gesamte Team, dessen Mitglieder als Teilnehmer der Nutzerstudie diese überhaupt ermöglicht haben.

Ein großes Danke geht an meine Familie und Freunde. *Meine Eltern* und *Dennis*, welche diese Arbeit akribisch korrekturgelesen haben. *Saskia*, die mir Gesellschaft beim Schreiben geleistet und mich bei verschiedenen Entscheidungsfindungen unterstützt hat. Sowie alle weiteren Personen, welche mir ihr vollstes Verständnis in dieser Zeit entgegengebracht haben.

Zum Abschluss möchte ich meinen besonderen Dank an *Yannick Meinberg* geben, der mit mir die Nächte durchgemacht hat, jedes Kapitel mehr als einmal gelesen und mir wichtige Fehler aufgezeigt sowie wertvolle Verbesserungsvorschläge eingebracht hat. Dafür, dass er mir den Kontakt zu Elisabeth aufgebaut hat. Und schließlich dafür, dass er mir in dieser Zeit so den Rücken frei gehalten hat, damit ich mich auf diese Mammutaufgabe konzentrieren konnte.

Vielen Dank für eure Unterstützung.

INHALTSVERZEICHNIS

I Thesis

1 Einleitung 2
- 1.1 Motivation zur Entwicklung und Erforschung der Dashboardlösung . . . 2
- 1.2 Ziel der Arbeit . . . 2
- 1.3 Angewandte Methodik . . . 3
- 1.4 Aufbau der Arbeit . . . 3

2 Analyse des Forschungsstandes in Bezug auf Modernisierungsansätze für Legacy-Anwendungen als Optimierung für nutzerzentrierte Oberflächen 4
- 2.1 Grundlagen zur Modernisierung von Legacy-Systemen . . . 4
  - 2.1.1 Methoden zur Modernisierung anhand unterschiedlicher Eingriffstiefe in das Legacy-System . . . 5
  - 2.1.2 Definition Legacy-Code . . . 6
  - 2.1.3 Grundlagen zu Codetesting . . . 7
- 2.2 Grundlagen und psychologische Ansätze zur Gestaltung nutzerfreundlicher und moderner Dashboards . . . 8
  - 2.2.1 DIN EN ISO Normenreihe 9241 zur Gebrauchstauglichkeit und Ergonomie interaktiver Systeme . . . 9
  - 2.2.2 Definition Usability nach ISO 9241-11 . . . 9
  - 2.2.3 Definition User-Experience und Abgrenzung von Usability . . . 10
  - 2.2.4 Interaktionsprinzipien nach DIN EN ISO 9241-110 . . . 10
  - 2.2.5 Standardisierter Fragebogen von J. Prümper nach ISO 9241-110 . . . 13
  - 2.2.6 Grundsätze für menschenzentriertes Design . . . 13
- 2.3 Moderne Tools zur nutzerfreundlichen Visualisierung von Daten 15
  - 2.3.1 Codeanalysetool Sonar . . . 15
  - 2.3.2 Dashboard-Framework Grafana . . . 16

3 Dashboards als potenzielle Lösung von Effizienz- und Übersichtlichkeitsproblemen in Legacy-Testsystemen 17
- 3.1 Herausforderungen in der Erstellung von Dashboards und der Arbeit mit Legacy- und Code-Testing-Systemen . . . 17
- 3.2 Fokussierung auf die Problemstellung der Effizienz und Übersichtlichkeit verteilter Testsysteme . . . 18
- 3.3 Beitrag moderner Dashboards zur Effizienzsteigerung und verbesserten Übersichtlichkeit von Legacy-Testsystemen . . . 18
- 3.4 Methodisches Vorgehen zur Entwicklung und Validierung eines Dashboards als moderne Anzeige der Testpoolergebnisse . 19
  - 3.4.1 Analyse des Ist-Zustandes der Testpool-Ergebnisanzeige zur Identifikation bestehender Anforderungen . . . 19

3.4.2 Entwicklung eines Dashboards als moderne Ergebnisübersicht . . . 19
3.4.3 Validierung der Dashboard-Lösung anhand einer zweigeteilten Nutzerstudie . . . 20
4 Stand der Technik des bestehenden Legacy-Testpoolmonitoring-Prozesses 21
4.1 Technische Umsetzung des Datenflusses zur Anzeige . . . 21
4.2 Überblick und Aufbau der bestehenden Ergebnisanzeige . . . 22
4.3 Beschreibung des bisherigen Arbeitsablaufs . . . 23
4.4 Zustandsanalyse des alten Systems als Vorlage zur Anforderungsanalyse für das neue System . . . 24
5 Entwicklung eines Dashboards als moderne Anzeige der Testpoolergebnisse 26
5.1 Anforderungsanalyse anhand des Zustands des bestehenden Legacy-Systems . . . 26
5.2 Designskizze des zukünftigen Arbeitsablaufs . . . 26
5.3 Auswahl des Dashboard-Tools . . . 27
5.4 Technische Umsetzung des Datenflusses zur Dashboardanzeige 28
5.5 Überblick über den strukturellen Aufbau und Inhalt des Dashboards . . . 29
5.6 Zustandsanalyse auf Grundlage der identifizierten Anforderungen . . . 30
6 Validierung des entwickelten Dashboards in Bezug auf die Usability im Vergleich zum Legacy-System 33
6.1 Aufstellen der zu überprüfenden Hypothesen . . . 33
6.2 Verwendete Medien für den Versuch . . . 35
6.2.1 Erstellung des Fragebogens für die Nutzerbefragung . . 36
6.2.2 Erstellung des Aufgabenkatalogs für den Usability-Test 36
6.3 Beschreibung des Versuchsdesigns . . . 37
6.4 Beschreibung des Versuchsaufbaus . . . 38
6.5 Beschreibung der Teilnehmerstichprobe . . . 38
6.6 Beschreibung der Versuchsdurchführung . . . 39
6.7 Hypothesentest anhand der erhobenen Ergebnisse . . . 40
6.7.1 Vorgehen zur Bestimmung der Signifikanz der Ergebnisse zur Hypothesenauswertung . . . 40
6.7.2 Auswertung der Effektivität (H_1) . . . 45
6.7.3 Auswertung der Effizienz (H_2) . . . 49
6.7.4 Bewertung der Intuitivität des Dashboards auf Grundlage der Effizienzbewertung . . . 55
6.7.5 Auswertung der Zufriedenheit (H_3) . . . 56
7 Diskussion und Einordnung der Ergebnisse zur Bewertung der Usability des entwickelten Dashboards 60
7.1 Bewertung der Usability auf Grundlage der Effektivität, Effizienz und Zufriedenheit . . . 60
7.2 Kritische Reflexion der angewandten Methodik . . . 61
7.2.1 Reflexionen in Bezug auf den Usability-Test . . . 61

7.2.2 Reflexionen in Bezug auf die Nutzerbefragung 62
7.3 Abschließende Bewertung zur Eignung von modernen Dashboards 63
8 Schlussfolgerungen, Limitationen und Ausblick 65
8.1 Zusammenfassung der wichtigsten Ergebnisse 65
8.2 Einordnung in den aktuellen Forschungsstand 66
8.3 Grenzen des entwickelten Prototyps und mögliche Weiterentwicklungen 66
8.4 Ausblick und Empfehlungen für weitergehende Forschung . . 67

II Appendix
A Anforderungstabellen nach ISO 9241-110 69
B Anhänge zum Dashboard 76
B.1 Parser-Code - von den Testergebnis-Daten zum JSON-File . . . 76
B.2 Beispiel JSON-Output vom Parser 82
C Anhänge zur Nutzerbefragung 83
C.1 Abkürzungsverzeichnis der nachfolgenden ISO-Interaktionsprinzipien 83
C.2 Begründung zur Ausfilterung bestimmter Fragen aus dem Fragebogen [Proo6] 83
C.3 Gekürzter Fragebogen der Nutzerbefragung nach Prümper . . 85
C.4 Vollständige Ergebnisse der Nutzerbefragung 86
C.5 Histogramme der Differenzen 88
C.6 Wiederholung des Signifikanztests nach Entfernung der Extrema 89
D Anhänge zum Usability-Test 91
D.1 Vollständiger Aufgabenkatalog des Usability-Tests 91
D.2 Begründung zur Auswahl und Reihenfolge der Aufgaben des Usability-Tests 91
D.3 Vollständige Ergebnisse des Usability Test 95
E Mitschriften von Mitarbeiteraussagen während der Befragung und des Usability-Tests 97

Literatur 103

ABBILDUNGSVERZEICHNIS

Abbildung 2.1 Beziehung zwischen den Hauptquellen für Empfehlungen zur Benutzer-System-Interaktion [Dina, S. 16] . . 9
Abbildung 4.1 Kontrollsequenz des Datenflusses vom ausgeführten Test zur Ergebnisanzeige 22
Abbildung 4.2 Beispielhafter Aufbau einer Oberfläche im alten System 22
Abbildung 5.1 Kontrollsequenz des Datenflusses vom alten System zum Dashboard 28
Abbildung 5.2 Aufbau des entwickelten Dashboards 29
Abbildung 6.1 Signifikanzniveau beim einseitigen und zweiseitigen t-Test [SR18, S. 399] 41
Abbildung 6.2 Beipiel Box-Plot: Vergleich der Ergebnisse aus der Nutzerbefragung Frage 1 und 4 (Daten aus Tabelle C.1) . . 44
Abbildung 6.3 Usability-Test: Fehlerquoten der Nutzer (Daten aus Tabelle D.2) 45
Abbildung 6.4 Usability-Test: Fehlerquoten der Nutzer (Ausschnitt aus Abbildung 6.3) 47
Abbildung 6.5 Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Aufgabenangemessenheit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14) 47
Abbildung 6.6 Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Steuerbarkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14) 48
Abbildung 6.7 Usability-Test: Vergleich der mittleren Bearbeitungsdauer (Daten aus Tabelle 6.4) 49
Abbildung 6.8 Usability-Test: Zeitvergleich von beiden Systemen - im Verhältnis zur Fehlerquote (Daten aus Tabelle D.2) . . . 50
Abbildung 6.9 Usability-Test: Vergleich Genauigkeit-Zeit im alten und neuen System (Daten aus Tabelle D.2) 51
Abbildung 6.10 Usability-Test: Vergleich der mittleren Bearbeitungsdauer im Verhältnis zur Fehlerquote (Daten aus Abbildung 6.3 und Abbildung 6.7) 52
Abbildung 6.11 Usability-Test: Effizienzvergleich vom neuen mit dem alten System (Daten aus Tabelle D.5) 53
Abbildung 6.12 Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Erlernbarkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14) 54
Abbildung 6.13 Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Selbstbeschreibungsfähigkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14) 55

Abbildung 6.14 Antwortverteilung der Nutzerbefragung (Daten aus Tabelle C.1) 57
Abbildung 6.15 Signifikanzbewertung der Ergebnisse der Nutzerbefragung (Daten aus Tabelle 6.8) 58
Abbildung 6.16 Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Erwartungskonformität nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14) 58
Abbildung 6.17 Antwortverteilung bzgl. der Wahrscheinlichkeit zur zukünftigen Dashboard-Nutzung (Daten aus Tabelle 6.9) . 59
Abbildung C.1 gekürzter Fragebogen nach J. Prümper [Pro06] (Bildschirmaufnahme aus Survio) 85
Abbildung C.2 Histogramme mit den Differenzen neu-alt der Nutzerbefragung 88
Abbildung C.3 Signifikanzbewertung der Ergebnisse der Nutzerbefragung nach Entfernung der Extrema (Daten aus Tabelle C.3) 90

TABELLENVERZEICHNIS

Tabelle 2.1 Zuordnung der Interaktionsprinzipien der DIN EN ISO 9241-110 zur den drei Dimensionen der Usability 11
Tabelle 4.1 Anzahl der vom alten System umgesetzten Empfehlungen nach der Tabelle der DIN EN ISO 9241-120 [Dina] (Zusammenfassung von Anhang A) 25
Tabelle 5.1 Überblick und Zuordnung der alten Funktionalität und Arbeitsweise auf das neue Dashboard 30
Tabelle 5.2 Anzahl der vom neuen System umgesetzten Empfehlungen nach der Tabelle der DIN EN ISO 9241-120 [Dina] im Vergleich zum alten System (Zusammenfassung von Anhang A; Erweiterung der Tabelle 4.1) . . . 31
Tabelle 6.1 Usability-Test: Überblick über die Aufgabentypen (Zusammenfassung aus Abschnitt D.1 und Abschnitt D.2) . 37
Tabelle 6.2 Antworten aus Frage 1 der Nutzerbefragung (Daten aus Tabelle C.1) 41
Tabelle 6.3 Beispiele zur Erstellung von Box-Plots (Daten aus Tabelle C.1) 44
Tabelle 6.4 Usability-Test: Vergleich der mittleren Bearbeitungsdauer (Weiterverarbeitung der Daten aus Tabelle D.2) . 49
Tabelle 6.5 Formel zur Effizienzberechnung 52
Tabelle 6.6 Usability-Test: Zeitmittelwerte und Signifikanzauswertung der Aufgaben 1 und 2 (Weiterverarbeitung der Daten aus Tabelle D.1 und Tabelle D.5) 54
Tabelle 6.7 Usability-Test: Zeitmittelwerte und Signifikanzauswertung der Aufgaben 4.1 und 4.2 (Weiterverarbeitung der Daten aus Tabelle D.1, Tabelle D.5) 56
Tabelle 6.8 Nutzerbefragung - Differenz der Antwortmittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle C.1) 57
Tabelle 6.9 Ergebnisse der Umfrage zur Wahrscheinlichkeit der eigenen zukünftigen Dashboard-Nutzung (Daten aus Tabelle C.1) 59
Tabelle A.1 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (1/7 Aufgabenangemessenheit) 69
Tabelle A.2 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (2/7 Selbstbeschreibungsfähigkeit) 70
Tabelle A.3 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (3/7 Erwartungskonformität) 71

Tabelle A.4 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (4/7 Erlernbarkeit) . . . 72
Tabelle A.5 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (5/7 Steuerbarkeit) . . . 73
Tabelle A.6 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (6/7 Robustheit gegen Nutzungsfehler) . . . 74
Tabelle A.7 Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (7/7 Nutzerbindung) . . . 75
Tabelle C.1 aufgezeichnete Daten der Nutzerbefragung . . . 86
Tabelle C.2 Zusammenfassung der Ergebnisse der Nutzerumfrage (Weiterverarbeitung der Daten aus Tabelle C.1) . . . 87
Tabelle C.3 aufgezeichnete Daten der Nutzerbefragung nach Entfernung der Extrema (Ausschnitt aus Tabelle C.1) . . . 89
Tabelle D.1 aufgezeichnete Daten des Usability-Tests . . . 95
Tabelle D.2 Zusammenfassung der Ergebnisse des Usability-Tests (Weiterverarbeitung der Daten aus Tabelle D.1) . . . 96
Tabelle D.3 Usability Test - Differenz der Zeitmittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle D.2) . . . 96
Tabelle D.4 Usability Test - Fehlerquoten, -mittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle D.2) . . . 96
Tabelle D.5 Usability-Test - Effizienzbewertung der Systeme im Verhältnis zueinander (Weiterverarbeitung der Daten aus Tabelle D.1) . . . 96

Teil I

THESIS

1 EINLEITUNG

Neben den zahlreichen intuitiven Neuerfindungen und Verbesserungen von Systemen und Prozessen, welche eine zunehmende Usability und User-Experience vorweisen, stehen die Bestandssysteme oder auch Legacy-Systeme. Ausgezeichnet durch eine gewachsene Struktur wird dessen Instandhaltung durch beispielsweise Fachpersonalmangel zunehmend schwieriger und teurer.

1.1 MOTIVATION ZUR ENTWICKLUNG UND ERFORSCHUNG DER DASHBOARDLÖSUNG

In den letzten zwanzig Jahren ist die Nachfrage nach der Modernisierung von Firmen-Systemen stetig gewachsen. Viele Guidelines werden für gewachsene Code-Anwendungen konzipiert und empfehlen den Aufbau von Testsystemen, um das unveränderte Codeverhalten während des Modernisierungsprozesses garantieren zu können. Allerdings können auch diese Testing-Systeme mit der Zeit zunehmend verwachsen. Die Instandhaltung solcher Systeme ist jedoch wenig erforscht. Durch die umfangreiche Struktur dieser Testpools ist die Aufgabe, deren Ergebnisse regelmäßig zu überwachen, monoton und zeitintensiv.

Diese Forschungsarbeit ist darin motiviert, einen Beitrag zu nachhaltigen und zukunftsfähigen Lösungen beizusteuern. Mit dem Generationenwechsel kristallisieren sich einige Probleme heraus, welche die Personen, welche die Systeme mit aufgebaut haben, über die Jahre mitschliffen. Auf dieser Grundlage hat sich das Problem mit der gewachsenen Struktur in der Ergebnisanzeige des Testpools aufgezeigt. Hierfür soll eine passende Lösung gefunden werden, dessen Qualität mit dieser Arbeit eingeordnet und bewertet wird.

1.2 ZIEL DER ARBEIT

Im Rahmen dieser Forschung wird der Frage nachgegangen, wie moderne Dashboards erfolgreich im Modernisierungsprozess eingesetzt werden können. Dabei wird vor allem deren Usability in Form der Effektivität der Ergebnisfindung, deren Effizienz der Aufgabenerfüllung sowie der Nutzerzufriedenheit betrachtet.

Das Ziel ist es dabei, herauszufinden, inwiefern die Einführung eines modernen Dashboards sinnvoll ist, um die Usability des Legacy-Testpoolmonitoring-Prozesses zu verbessern.

1.3 ANGEWANDTE METHODIK

Anhand einer Nutzerstudie innerhalb der Software GmbH, die im Bereich digitale Transformation tätig ist, wird das zuvor genannte Ziel der Arbeit untersucht. Es wird ein neues Dashboard entwickelt und auf dessen Usability anhand der Empfehlungen der DIN EN ISO 9241-110 [Dina] analysiert, um diese mit der Usability des bestehenden Altsystems zu vergleichen. Die Nutzerstudie bestehend aus einer Kombination aus Usability-Tests und Nutzerbefragung ermöglicht eine Gegenüberstellung der Systeme. Der Fragebogen der Nutzerbefragung baut auf dem Vorbild der Nutzerbefragung von Jochen Prümper [Pro06] auf, welcher zur Sicherstellung der Umsetzung der Empfehlungen der DIN EN ISO 9241-110 dient.

1.4 AUFBAU DER ARBEIT

In dieser Arbeit wird die Qualität der Usability des neuen Dashboards mit dem alten System verglichen. Dafür werden in Kapitel 2 für diese Auswertung relevante psychologische Grundlagen bezüglich der Umsetzung eines nutzerfreundlichen Designs vorgestellt, an dessen Prinzipien sich die Entwicklung des Dashboards orientiert. Außerdem wird eine Norm vorgestellt, die zur Definition der Usability-Dimensionen dient und die Grundlage der Qualitätsbewertung darstellt. In Kapitel 3 wird das Thema der Arbeit umfassender eingeordnet, um gängige Probleme und Ansätze aufzuzeigen, welche die Forschung motivieren. Daraufhin wird in Kapitel 4 das Altsystem vorgestellt. Die Erfassung dessen Zustands dient als Grundlage, um die Anforderungen an das neu zu entwickelnde Dashboard zu bilden. Das Dashboard sowie sein Designprozess werden in Kapitel 5 vorgestellt. Dabei werden zusätzlich relevante Unterschiede zum Altsystem aufgezeigt. In Kapitel 6 wird der empirische Teil der Arbeit in Form einer Nutzerstudie zum Vergleich des Dashboards mit dem Altsystem durchgeführt. Hierfür werden Hypothesen auf Grundlage der Usability-Kriterien aufgestellt. Diese werden im Anschluss statistisch ausgewertet. Die Ergebnisse werden in Kapitel 7 zusätzlich zusammengefasst und umfassend analysiert, um die Ablehnung oder Akzeptanz der Hypothesen neu einzuordnen und im Forschungskontext auszuwerten. Daraufhin wird die Eignung des Dashboards als Modernisierungsmaßnahme herausgestellt.

2

ANALYSE DES FORSCHUNGSSTANDES IN BEZUG AUF MODERNISIERUNGSANSÄTZE FÜR LEGACY-ANWENDUNGEN ALS OPTIMIERUNG FÜR NUTZERZENTRIERTE OBERFLÄCHEN

In diesem Kapitel werden Begriffe für die Modernisierung von Ergebnisanzeigen definiert. Um die Relevanz von Moderniserungen zu unterstreichen, wird im ersten Teil der Legacy-Begriff definiert sowie verschiedene Moderniserungstechniken vorgestellt. Es wird weiterhin aufgezeigt, was ein Testpool ist und wofür dieser angewendet wird.

Im zweiten Teil werden psychologische Ansätze zur Gestaltung moderner, interaktiver und menschenzentrierter Oberflächen dargelegt. Dabei wird die DIN EN ISO 9241-110 zur Gebrauchstauglichkeit und Ergonomie interaktiver Systeme sowie verschiedene Ansätze zur Sicherstellung dessen Umsetzung vorgestellt.

Schließlich werden zwei Tools zur Erstellung moderner Dashboards als Grundlage des nachfolgenden Prototyps dieser Forschung (s. Kapitel 5) vorgestellt.

2.1 GRUNDLAGEN ZUR MODERNISIERUNG VON LEGACY-SYSTEMEN

Es gibt eine „Notwendigkeit zur Veränderung“ [Flo24]. Vor allem in gewachsenen Systemen, im allgemeinen Sprachgebrauch auch Legacy-Systeme (dt. Altsysteme) genannt, ist dies jedoch mit sehr hohem Aufwand verbunden.

Um diese Systeme zu modernisieren, wird ein konkreter Anreiz gebraucht. Schon 2010 beschrieb Stantchev, dass das Wachstum der Anwendung in vielen Fällen zu einer schwer beherrschbaren Komplexität geführt habe und zum Beispiel dessen Erweiterungsmöglichkeiten beeinträchtige [SKK10, S. 19; Flo24].

Es gibt viele Gründe, welche Unternehmen dazu zwingen, ihre Systeme auf den aktuellen Stand zu heben. Aufgrund von Personalmangel fehlt es den Firmen an Fachkräften mit dem benötigten Wissen. Die neue Generation wird anhand von modernen Technologien gelehrt und das Personal mit dem geeigneten Fachwissen wird aufgrund ihres Alters nicht mehr lange arbeiten können. Vor allem die Instandhaltung bestehender Code-Strukturen sowie der Wissentransfer gestalten sich aufgrund des Fachkräftemangels als schwierig. Dies erzeugt hohe Wartungskosten [HZW24].

Eine Studie der Beratungsgesellschaft Lünendonk hat ergeben, dass die geschäftskritischen Anwendungen von 62% der befragten Unternehmen stark veraltet sind und eine Modernisierung verlangen [Axe25]. Dabei ergreifen mehr als die Hälfte der Unternehmen keine konkreten Maßnahmen, die dem entgegen wirken [SKK10, S. 4]. [Axe25; Flo24; SKK10, S. 4].

Wird durch ein Moderniserungsprozess eine Verbesserung des Systemzustands erreicht, so profitiert das Unternehmen von einer erhöhten Qualität, wodurch Prozesse effizienter und zuverlässiger erfolgen. Dies führt durch den reduzierten Aufwand wiederum zu Kosteneinsparungen [Opp25, S. 16].

Aus diesen Gründen werden in diesem Kapitel verschiedene Möglichkeiten vorgestellt und eingeordnet, wie dieser umfangreiche Schritt der Modernisierung begonnen werden kann. Weiterhin wird die Relevanz von der kontinuierlichen Überprüfung der Code-Basis in Form von Tests sowohl im Tagesbetrieb, aber vor allem im Modernisierungsprozess, aufgezeigt.

2.1.1 *Methoden zur Modernisierung anhand unterschiedlicher Eingriffstiefe in das Legacy-System*

Im vorherigen Kapitel wurde dargestellt, dass Modernisierungen nicht nur als Maßnahme selbst, sondern gut begründet umgesetzt werden sollten. Ziel ist, das System zu verbessern. Ein System, welches ausschließlich auf eine neue Technologie übertragen wurde, kann dabei die historisch gewachsene Struktur übernehmen und genauso unübersichtlich erscheinen wie zuvor [Flo24].

Nach einer Umfrage von Kannenberg setzen 72% auf **Replatforming**, also die Umstellung des eigenen Systems auf eine neue Anwendung. Damit ist häufig die Migration in die Cloud gemeint. Ingesamt 72% der Unternehmen wechseln auf On-Premise oder private Cloudlösungen, um nicht von anderen Konzernen abhängig zu sein [Axe25]. Da moderne Cloudlösungen durch den Umfang an Servern und Komponenten eher mehr Komplexität mit sich bringen als zuvor, empfiehlt Stocker, Fachkräfte mit Erfahrung im Cloudbetrieb bereitzustellen [Flo24].

Knapp 80% der Unternehmen setzen auf modulare Architekturen [Axe25]. Die **Modularisierung** beschreibt die Auslagerung von Codesegmenten in Helferfunktionen. Diese ist eine wichtige Methode zur Simplifizierung, große und umfangreiche Methoden zu zerteilen. Ziel ist es, die Kernelemente überschaubarer zu gestalten und vor allem Code-Dopplungen in Module auszulagern, die mit der Zentralfunktion interagieren. Einen weiteren Aspekt der Zerteilung stellt die Aufteilung eines Systems in seine Komponenten dar, welche über feste Schnittstellen miteinander interagieren. Diese Aufteilung ermöglicht es dem System, flexibel Funktionalitäten anzupassen, ohne das Verhalten anderer Komponenten zu beeinflussen. [Axe25; EMEG21; SKK10, S. 19]

Um eine Anwendung zu modularisieren, gibt es die Möglichkeit, das System neu zu schreiben (*Rewrite*) oder zu überarbeiten und umzustrukturieren (*refactor*) [EMEG21, S. 127].

47% der Unternehmen nutzen die Strategie **Rewrite** oder auch **Rebuild** genannt [Axe25]. Diese bauen ihr System von Grund neu auf und strukturieren es anhand der Erkenntnisse aus dem alten System, mit dem Ziel, das alte System vollständig zu ersetzen. Allerdings ist dieser Ansatz sehr invasiv, benötigt ein hohes Investment und ist mit einem entsprechend hohen Risi-

ko verbunden. Entweder muss die Bearbeitung des alten Systems pausiert werden, bis das neue System vollständig einsatzfähig ist, oder der Arbeitsaufwand verdoppelt sich, indem beide Systeme parallel betrieben werden. Quaisser sagt, dass große 'Big-Bang-Projekte' nie wirklich erfolgreich gewesen seien [zitiert nach Flo24]. Dieser Ansatz hat große Nachteile, wodurch er zumeist nicht umsetzbar ist. Es werde ein Parallelbetrieb (Koexistenzphase) benötigt, bis alles migriert, modernisiert und abgelöst ist [Flo24]. [Axe25; EMEG21, S. 127; Fea13, S. 5; SKK10, S. 19]

Das **Refactoring** (dt. Umgestaltung) ist ein sukzessiver Prozess zur Code-Optimierung, den 64% der Unternehmen als Modernisierungsstrategie nutzen [Axe25]. Es ist ein langsamer Prozess und benötigt ein hohes Fähigkeitslevel der Entwickler, einem systematischen Plan zu folgen, da dieser andernfalls zu neuen Fehlern führen kann. Jedoch erlaubt das Refactoring, den Code zu verbessern und umzustrukturieren, ohne das Verhalten zu beeinflussen. Dadurch kann eine Modularisierung im eigenen Rhythmus gewährleistet werden, ohne die Einführung neuer Features währenddessen zu verhindern. Dabei ist es wichtig, dass nicht immer die perfekte Lösung gesucht wird. Die subjektive Code-Qualität darf sich verschlechtern, wenn dadurch eine Verbesserung des Code-Zustands erreicht werden kann. Das Refactoring ist somit eine Modernisierungsstrategie, welche wenig Investment benötigt, kaum Risiko birgt und somit einen Ansatz mit wenig Auswirkungen darstellt. Um sicherzustellen, dass sich durch diesen Prozess kein Code-Verhalten ungewollt verändert, werden Tests benötigt, welche das gewünschte Verhalten durchgehend bestätigen [EMEG21, S. 127; Fea13, S. 5].

Insgesamt wird empfohlen, Systeme in kleinen Schritten zu modernisieren. Dabei sollte der Fokus auf der Funktion der Komponenten und deren Interaktion liegen. In Form von Routinen kann eine kontinuierliche und zukunftsfähige Verbesserung erreicht werden. Ein Anfang stellt das Umstrukturieren für den Überblick sowie das Aufbrechen von Funktionen und Abhängigkeiten dar, welche langfristig dabei unterstützen, die Code-Komplexität zu verringern. Weiterhin kann dies dabei helfen, den Code umfangreich testen zu können (s. Unterabschnitt 2.1.3) [Fea13, S. 18; Nad22].

2.1.2 *Definition Legacy-Code*

Soll Software verändert werden, gibt es vier mögliche Gründe dafür. Entwickler können ein Feature hinzufügen, einen Fehler beheben, ein Refactoring oder eine Optimierung vornehmen. Dies impliziert die Veränderung der Code-Struktur oder bestehender Funktionalität, der Einbau von neuer Funktionalität oder die Anpassung des Ressourcen-Verbrauchs. Dabei soll das bestehende Verhalten bewahrt werden. Das bedeutet, dass der Code so wenig wie möglich aber so viel wie nötig verändert werden soll [Fea13, S. 7].

Während eine aufgeräumte und gepflegte Umgebung dem Entwickler hilft, Überblick über den Code zu behalten, reicht dies in wachsenden und vor allem Legacy-Systemen nicht dafür aus, alle Einzelheiten zu kennen. Wird an dem Code eine Änderung vorgenommen, ist es kaum möglich, zu

erkennen, ob der Code dadurch verbessert oder verschlechtert wurde. Zudem ist es ineffizient für den Entwickler, jede Einzelheit per Hand zu testen, ob sich das Verhalten exakt so verändert hat, wie es vorgesehen war. „Code ohne Tests ist schlechter Code“ [Fea13, S. XVI]. El-Morabea et al. ergänzt, dass ungetesteter Code wie eine tickende Zeitbombe sei und jederzeit in Form von Bugs oder Abstürzen explodieren könne [EMEG21, S. 17]. Um zu garantieren, dass sich an dem Verhalten des bestehenden Codes bei Codeänderungen nichts verändert, werden Tests benötigt [Fea13, S. XVI; EMEG21, S. 128; Opp25, S. 25].

Tests sind ein „wesentlicher Bestandteil des Entwicklungszyklus“ [Opp25, S. 16]. Sie helfen Entwicklern, hohe Qualitätsstandards einzuhalten und garantieren die Stabilität und Zuverlässigkeit von Softwareprodukten [Opp25, S. 25]. Wird die Software ausreichend getestet, sieht der Entwickler sofort, wenn sich das Code-Verhalten ungewollt verändert hat. Dafür wird der Aufbau und die Pflege eines umfangreichen Test-Frameworks zur regelmäßigen und häufigen Überprüfung von der einzelnen Funktionseinheit bis zum komplexen Zusammenspiel verschiedener Services benötigt [Fea13, S. 45; EMEG21, S. 3].

Zur Reduktion des manuellen Aufwands werden diese Testframeworks automatisiert. Dieses hilft weiterhin zur Steigerung der Testabdeckung und ermöglicht dem Entwickler eine direkte Rückmeldung. Da sich somit auch der Arbeitsprozess effizienter gestaltet, kann das Unternehmen von Kosteneinsparungen profitieren [Opp25, S. 24].

Mithilfe einer solchen Testbasis lässt sich Code schnell modifizieren, ohne dass der Entwickler den vollständigen Überblick benötigt. Zudem werden auch strukturelle Veränderungen (*Refactoring*), welche das Verhalten nicht verändern, durch die Testunterstützung vereinfacht [Fea13, S. XVI, 5, 45; EMEG21, S. 128].

2.1.3 *Grundlagen zu Codetesting*

Wie zuvor bereits erwähnt, werden Tests dafür genutzt, das Verhalten von unberührtem Code bei einer Änderung beizubehalten und somit die Code-Qualität garantieren zu können. Fundamental für die Qualitätssicherung ist das Konzept der *Code-Coverage* (dt. Code-Abdeckung). Sie misst, „wie viel Prozent des Codes durch Tests abgedeckt werden“ [[Ile03] nach [Opp25, S. 13]] und hilft somit, ungetesteten Code ausfindig zu machen. Eine hohe Code-Coverage führt zu einer hohen Softwarequalität und trägt damit zur Reduktion von Fehlern bei [[Ile03] nach [Opp25, S. 13]].

Erfolgt eine hohe Code-Abdeckung im gewachsenen Legacy-Code, so ist proportional ebenso viel Test-Code zu bewältigen. El-Morabea et al. betont „so wie wir schlechten Code haben können, können wir auch schlechte Tests haben. Schließlich sind Tests auch Code. “ [übersetzt nach [EMEG21, S. 3]]

Software kann zur besseren Testbarkeit und somit Erreichung einer höheren Testabdeckung modularisiert werden (s. Unterabschnitt 2.1.1). Beides sind Bestandteile des *Test Driven Development* (TDD). Wird ein fehlschlagen-

der Test geschrieben, dann wird dieser zum Erfolg gebracht. Schließlich wird der Code refactored, beispielsweise mit Hilfe von Modularisierungstechniken. Die neuen Module können erneut getestet werden [EMEG21, S. 8; SKK10, S. 19].

Tests werden in verschiedene Testphasen unterschiedlichen Umfangs unterschieden. Neben dem manuellen Testen gibt es automatisierte Tests. *Unit*-Tests überprüfen eine Einheit oder ein Modul. *Integration*-Tests kümmern sich um die Integration, also das Zusammenspiel zwischen einzelnen Systemen, während *System*-Tests ganze Systemkomplexe auf ihr Zusammenspiel überprüfen. Ein Beispiel dafür sind UI-Tests (User-Interface, dt. Benutzeroberfläche). Weitere Tests sind Confirmation-Tests (dt. Abnahme- oder auch *Akzeptanz*-Tests). [EMEG21, S. 2, 81 ff.; Opp25, S. 18; Pi20, S. 6].

Bezüglich des Umfangs wird in der Lehre die *Test-Pyramide* verwendet. Sie besagt, dass je simpler eine Art von Test ist, desto mehr dieser Tests sollten eingesetzt werden. Je komplexer und aufwändiger eine Art von Test ist, desto weniger werden davon benötigt. In dem Zusammenhang wird auch nach sogenannten *Happy-Paths* (dt. glückliche Pfade, wie das System funktionieren sollte) und *corner-cases* (dt. Eck-Fälle, Situationen die vermeintlich seltener erscheinen und Fehler werfen) unterschieden. [EMEG21, S. 65 ff.]

Es werden weiterhin die Testmethoden *Whitebox* und *Blackbox* unterschieden. Whitebox-Tests, wie Unit- und Intergration-Tests, werden von Entwicklern erstellt, welche ein profundes Wissen über das getestete System haben. Sie können hinter die Strukturen blicken und stellen einzelne Funktionen sicher. Blackbox-Tests wie Systemtests testen eher oberflächlich und geben an, ob das erwartete Verhalten eines Systems aufgetreten ist. Beispielsweise wird eine Schnittstelle auf ihre Antworten getestet. [Pi20, S. 4 f.]

2.2 GRUNDLAGEN UND PSYCHOLOGISCHE ANSÄTZE ZUR GESTALTUNG NUTZERFREUNDLICHER UND MODERNER DASHBOARDS

Die *Ergonomie* beschreibt ein Gebiet, welches sich darauf konzentriert, Produkte und Bedingungen an den Menschen anzupassen, um somit für ihn gute und in ihrer Funktionalität vollständige Produkte zu entwickeln. Im technischen Kontext ist das Teilgebiet der *kognitiven Ergonomie* relevant. Diese fokussiert sich auf die Denkweise von Menschen und somit der Mensch-Maschine-Interaktion, um Oberflächen intuitiv und ansprechend für den Menschen zu gestalten. Diese Oberflächen werden auch *Human Machine Interfaces* genannt. Sie agieren als Brücke zur Informationsvermittlung an den Menschen sowie zur Bedienung der Maschine. Die Vollständigkeit aller Funktionen stellt dabei eine Voraussetzung zur Verbesserung der Gestaltung dar. [Vol15, S. 14 f., 24 f.]

In diesem Kapitel wird der Begriff der Usability Im Rahmen der DIN EN ISO 9241 Normenreihe definiert. Dieser wird klar von der User-Experience abgetrennt, welche ebenfalls in diesem Kontext verwendet wird. Daraufhin werden die Interaktionsprinzipien der Din EN ISO 9241-110 sowie weite-

re psychologische Ansätze vorgestellt, welche zur Erstellung nutzerfreundlicher Systeme hilfreich sind.

2.2.1 *DIN EN ISO Normenreihe 9241 zur Gebrauchstauglichkeit und Ergonomie interaktiver Systeme*

Die Normen unter der DIN EN ISO 9241 aus dem Jahr 2020 geben Vorgaben und Empfehlungen zur Gestaltung interaktiver Systeme. Abbildung 2.1 stellt den Zusammenhang der Hauptquellen für Empfehlungen zur Benutzer-System-Interaktion dar. Es sind die Parts 11, 110, 112 und weitere zu erkennen. Die DIN EN ISO 9241-11 definiert den Begriff Usability, währenddessen Part 110 und 112 Prinzipien und Grundsätze mitgeben, um die Usability eines Systems gewährleisten zu können [Zusammenfassung nach Dina].

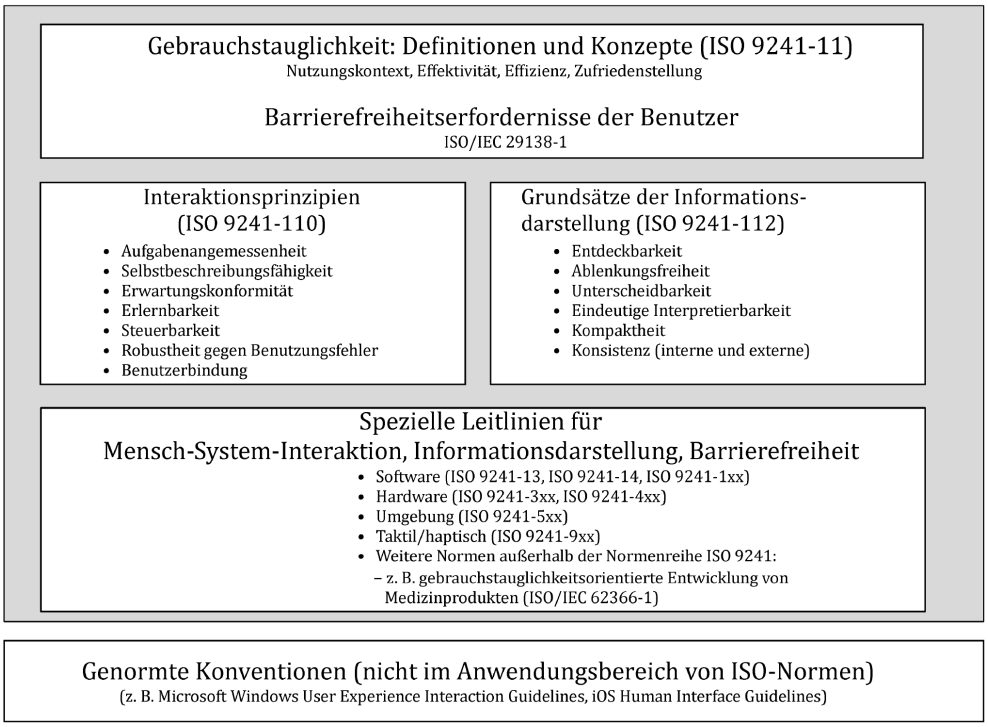


Abbildung 2.1: Beziehung zwischen den Hauptquellen für Empfehlungen zur Benutzer-System-Interaktion [Dina, S. 16]

Die DIN-Normen sind in diesem Fall die nationale Umsetzung der internationalen ISO-Normen und werden nachfolgend synonym mit *ISO* referenziert.

2.2.2 *Definition Usability nach ISO 9241-11*

Der Begriff der Usability (dt. Gebrauchstauglichkeit) beschreibt die Qualität eines Systems oder einer Oberfläche in Bezug auf dessen Einfachheit und Nutzbarkeit. Diese wird gemessen in den Dimensionen der Effektivität, Effizienz und der Zufriedenheit der Nutzer.

Die Effektivität beschreibt die funktionelle Eignung eines Systems. Das heißt, dass der Nutzer seine Aufgaben vollständig und korrekt mithilfe dieses Systems durchführen kann. Die Effizienz misst sich in Form von Zeit, um eine Aufgabe vollständig und richtig zu erfüllen, und der Rate, wie viele Fehler auf dem Weg dorthin gemacht werden. Die Zufriedenheit oder auch Akzeptanz (en. Satisfaction) [Vol15, S. 23] der Nutzer ist nicht in metrischen Kenngrößen zu erfassen. Es kann ein Zufriedenheitsspektrum auf Grundlage von zum Beispiel Fragebögen (s. Unterabschnitt 2.2.5) oder der Verhaltensanalyse während eines Testszenarios festgestellt werden. [Zusammenfassung nach Dina]

2.2.3 *Definition User-Experience und Abgrenzung von Usability*

Neben der Usability steht die User-Experience (UX, dt. Nutzererfahrung oder -erlebnis), dessen Inhalte leicht miteinander verwechselt werden. Die User-Experience wird in Part 210 der ISO 9241 definiert als „Wahrnehmungen und Reaktionen einer Person, die aus der tatsächlichen und/oder der erwarteten Benutzung eines Produktes, eines Systems oder einer Dienstleistung resultieren.“ [Dinb, S. 7]

Während bei der Usability die schnelle, fehlerfreie und angenehme Bedienung eines Systems im Vordergrund steht, wird die User-Experience zusätzlich mit Spaß, Vergnügen und positivem Erleben verbunden [Vol15, S. 23 f.].

Da die Gebrauchstauglichkeit (UE) ein Part des Nutzererlebnisses (UX) ist ($UX \subsetneq UE$) [Gas18, S. 14] wird diese nicht in Abbildung 2.1 aufgelistet. Der Part 112 mit den Grundsätzen zur Informationsdarstellung ist vor allem auf Benutzeroberflächen oder Dashboards anwendbar. Da sich dieser Part auf UX fokussiert, finden dessen Prinzipien hier aus Umfangsgründen keine Anwendung.

2.2.4 *Interaktionsprinzipien nach DIN EN ISO 9241-110*

Der Text der ISO 9241 Part 110 kombiniert die Ausprägungen der Usability mit Gestaltungsempfehlungen in Form von sieben Interaktionsprinzipien (ehem. Grundsätze der Dialoggestaltung). Indem Systeme und Schnittstellen gebrauchstauglicher, zugänglicher und konsistenter gestaltet werden, erleichtern und verbessern diese die kognitive Ergonomie der Mensch-System-Interaktion [Dina].

Die sieben Interaktionsprinzipien sind die Aufgabenangemessenheit, Selbstbeschreibungsfähigkeit, Erwartungskonformität, Erlernbarkeit, Steuerbarkeit, Robustheit gegen Benutzungsfehler und die Benutzerbindung. Die Gewichtung der Grundsätze kann unterschiedlich ausfallen, da diese von dem System, den Nutzern und deren Aufgaben abhängig sind. Zur Bewertung der Umsetzung der Empfehlungen ist die „Tabelle zur Unterstützung der Anwendung [der ISO 9241-110]“ [Dina] der ISO-Norm beigelegt. Die vollständige Version ist in Anhang A zu finden. Anhand der nachfolgenden Beschrei-

bungen werden die Interaktionsprinzipien wie in Tabelle 2.1 zu sehen, den drei Usability-Dimensionen zugeordnet.

		Usability		
		Effektivität	Effizienz	Zufriedenheit
Interaktionsprinzipien der DIN EN ISO 9241-110	Aufgaben-angemessenheit	ja	ja	nein
	Steuerbarkeit	ja	eher ja	ja
	Erwartungs-konformität	eher ja	nein	ja
	Erlernbarkeit	eher ja	ja	eher ja
	Selbstbeschreibungs-fähigkeit	eher ja	ja	nein
	Robustheit gegen Benutzungsfehler	eher ja	eher ja	nein
	Benutzerbindung	nein	nein	ja

Tabelle 2.1: Zuordnung der Interaktionsprinzipien der DIN EN ISO 9241-110 zur den drei Dimensionen der Usability

Nachfolgend werden die Interaktionsprinzipien der DIN EN ISO 9241-110 [Dina] mit Fokus zur Anwendung auf Dashboards zusammengefasst.

Ist ein System **aufgabenangemessen**, bedeutet dies, dass es den Nutzer bei seinen Aufgaben unterstützt. Hierbei ist das System primär auf diese Aufgabe ausgerichtet, anstatt auf der dafür benötigten Technik dahinter zu basieren. Um den Aufwand einer Aufgabe zu optimieren, sollen beispielweise unnötige Schritte sowie ablenkende Informationen oder Interaktionsmöglichkeiten auf der Oberfläche gemieden werden. Dies äußert sich, indem zum Beispiel nur die Informationen auf der Oberfläche angezeigt werden, die für den aktuellen Schritt benötigt werden.

Die **Selbstbeschreibungsfähigkeit** hilft dem Nutzer, ein System intuitiv bedienen zu können. Es soll angemessene Informationen und offensichtliche Fähigkeiten des Systems mitteilen, ohne unnötige Interaktionen zu erfordern. Beispiele hierfür sind die Platzierung von Steuerelementen, deren eindeutige Unterscheidung von nicht interaktiven Schnittstellen und dem offensichtlichen Aufzeigen des aktuellen Navigationsverlaufs in Form von etwa breadcrumb trails (dt. Brotkrumenpfade). Diese Maßnahmen können die Notwendigkeit externer Hilfe, wie beispielsweise aus Handbüchern oder von Beratungsstellen, stark reduzieren.

Die **Erwartungskonformität** beschreibt, dass das Verhalten des interaktiven Systems vorhersehbar und somit basierend auf dem aktuellen Kontext mit den Nutzererwartungen konform sein soll. Es wird erwartet, dass sich das System angemessen verhält und entsprechend reagiert. Dies wird durch Arbeitsschritte gestützt, die mit dem Aufgabenverständnis des Nutzers sowie den Erfordernissen des breitesten Benutzerspektrums übereinstimmen. Dafür ist eine dem Nutzer vertraute Darstellung, Eingabe und Steuerung

erforderlich, welche innerhalb des Systems und darüber hinaus konsistent ist. Das System sollte mit Änderungen im Nutzungskontext zurechtkommen. Dafür soll es in der Lage sein, auf unterschiedliche Erfordernisse einzelner Nutzer sowie auf angeschlossene Ressourcen angemessen zu reagieren. Informationen sind auf verschiedenen Gerätearten und Anzeigegrößen angemessen darzustellen und die Änderungen hinsichtlich der physischen Umgebung des Benutzers anzupassen, wie beispielsweise das Übernehmen der Light- und Darkmode-Einstellung.

Damit ein System **erlernbar** ist, hat es das Explorieren und die Entdeckung seiner Fähigkeiten und deren Verwendung zu ermöglichen, um die vom Nutzer angestrebten Ergebnisse zu erreichen und ihm den Zugang zu weiteren Informationen zu ermöglichen. Es hat den Lernaufwand zu minimieren und Unterstützung beim Erlernen anzubieten. Dafür sollte es durch das Ausprobieren keine negativen Konsequenzen für den Nutzer geben. Zudem wird die Implementierung geeigneter Alternativen zur Suche nach und für das Navigieren zu Informationen und Funktionen empfohlen. Weiterhin soll das System Rückmeldung geben, um dem Nutzer zu helfen, die Folgen seiner Aktionen zu erlernen, und in dem Zuge die Entwicklung seiner Fertigkeiten im Zusammenhang mit den unterstützten Aufgaben fördern.

Die **Steuerbarkeit** erlaubt es dem Benutzer, die Kontrolle über die Geschwindigkeit, Abfolge und Individualisierung der Nutzung eines Systems zu behalten. Das beinhaltet die Möglichkeit zur Flexibilität des Nutzers, Aufgaben in einer beliebigen Reihenfolge durchzuführen, diese zu jeder Zeit zu unterbrechen und zu einem späteren Zeitpunkt an derselben Stelle wieder aufnehmen zu können.

Das System hat eine **Robustheit gegen Benutzungsfehler** aufzuweisen, indem diese dem Nutzer bei der Fehlervermeidung hilft, eine Toleranz und Hilfestellung im Fehlerfall aufweist sowie den Nutzer dabei unterstützt, diesen Fehler zu beheben.

Das letzte der Prinzipien ist die **Benutzerbindung**. Diese besagt, dass das System Funktionen und Informationen auf einladende und motivierende Weise darzustellen hat, um eine kontinuierliche Interaktion mit dem System zu fördern und eine positive User-Experience herbeizuführen. Die Benutzerbindung ist aus dem englischen *user engagement* übersetzt und kann ebenfalls als *Benutzer-Engagement* verstanden werden. In der deutschen Sprache ist das Wort *Engagement* im Vergleich zum Wort *Bindung* oft positiv besetzt, daher kann der englische Begriff *engagement* durch eine Kombination der beiden Bedeutungen beschrieben werden, ist jedoch noch umfassender zu verstehen. Das System soll den Nutzer motivieren, mit diesem zu interagieren. Dabei werden seine unterbewussten Bedürfnisse antizipiert. Es soll ein Vertrauensverhältnis aufgebaut werden, indem ein konsistentes Design und ein hochwertiges Erscheinungsbild gewahrt wird. Weiterhin soll der Nutzer zunehmend einbezogen werden, indem ihm die Gelegenheit geboten wird, Vorschläge zu Änderungen, Systemerweiterungen und -verbesserungen einzureichen.

Die Reihenfolge der Prinzipien stellt keine Rangfolge dar. Die Prinzipien und Empfehlungen sind generischer Natur und damit nicht an ein bestimmtes System oder Kontext gebunden. Der Inhalt der Prinzipien überschneidet sich teilweise, wobei die Bedeutung und Möglichkeit zur Anwendung des jeweiligen Prinzips vom Nutzungskontext, den Benutzergruppen und der gewählten Technik abhängt. [Zusammenfassung nach Dina]

2.2.5 *Standardisierter Fragebogen von J. Prümper nach ISO 9241-110*

Aufbauend auf der ISO 9241-110 hat Jochen Prümper einen Fragebogen erstellt, um die Umsetzung der enthaltenen Prinzipien und Empfehlungen anhand von Nutzerdaten überprüfen zu können. Der Fragebogen wurde bereits mehrfach überarbeitet und 2006 wurde eine Kurzversion erstellt. In dieser werden jeder der sieben Prinzipien drei Fragen zugeordnet, dessen Umsetzung auf einer 7-Punkte-Skala von den jeweiligen Nutzern zu bewerten sind [Prü97; Prü+06, S. 258].

2.2.6 *Grundsätze für menschenzentriertes Design*

Bei der Entwicklung von neuen Systemen wird meist erst die Technologie designt. Vor allem in diesen Technologie-fokussierten Systemen werden durch deren Komplexität und Unintuitivität Nutzungsfehler gemacht. Wird das Design *menschenzentriert* erarbeitet, so werden zuerst die Anforderungen an die Maschine erfasst [Vol15, S. 53 f.; Wic+13, S. 400].

Der Fokus liegt auf der *Intuition* des Systems. Diese beschreibt, dass ein Nutzer den Umgang mit einem System schnell erlernen kann und im Zusammenhang damit ohne eine umfangreiche Erklärung versteht, wie er dieses zu verwenden oder zu bedienen hat. Ein Beispiel ist die Zusammenfassung komplexer Systemdaten und -werte auf eine automatisierte Einschätzung sowie Ausgabe zu dessen Zustand. Die Darstellung von Systemdaten sollte so erfolgen, dass sie lesbar und intuitiv erkennbar ist. Um sich auf bestimmte Bereiche zu konzentrieren, muss die eigene *Aufmerksamkeit* darauf gelenkt werden. Dabei ist die *Area of Interest* (dt. der Bereich des Interesses) nur so groß, wie diese mit den Augenbewegungen abgedeckt werden kann [Vol15, S. 153; Wic+13, S. 52 ff.].

Werden auf einer Informationsanzeige viele Werte dargestellt, so muss nach dem gewünschten Ergebnis *seriell* gesucht werden. Diese monotone Aufgabe bedeutet, dass alle Ergebnisse stückweise gescannt werden. Nutzer, die für die Überwachung der Daten zuständig sind, müssen dennoch jederzeit auf ein unwahrscheinliches und entsprechend unerwartetes Event reagieren können. Dabei kann diese anstrengende und umfassende Suche, auch *extensive scanning* genannt, nur für eine gewisse Zeit erfolgen. Im Unterschied dazu steht die *parallele Suche*, welche eine Art Scannen auf einen Blick ermöglicht. Um dies zu ermöglichen, müssen gesuchte Ziele eindeutig von ihrer Umgebung unterscheidbar sein. Während Objekte mit beispielsweise der selben monochromen Farbe dazu tendieren, ähnlich verarbeitet zu

werden, stechen Objekte durch diesen *Pop-Out-Effekt* hervor. Dieser kann auf Grundlage von Form, Farbgebung, -intensität, -sättigung oder Kontrast entstehen. Die Unterscheidung durch Farbsättigung zeigt dabei beispielsweise eine größere Wirkung als unterschiedliche Farben gleicher Sättigung. Bis auf Farben mit etablierter Bedeutung, wie rot als Signalfarbe, ist es kaum möglich, die Absicht zu deuten. Die Suchzeiten nach einem Ziel erhöhen sich deutlich, wenn die Anzahl der Ablenkungen steigt, bleiben jedoch gleich, wenn die Unterscheidbarkeit zwischen Ziel und Ablenkung groß ist. Während ein homogenes Hintergrundgeschehen und eine einzigartige Eigenschaft des Ziels die Suche erleichtern, verlängert sich die Suchzeit, wenn die Anzeige mit Daten überfüllt ist und die Umgebung mit heterogenem *Clutter* (dt. Gerümpel) gefüllt ist. Es muss ein Kompromiss zwischen der Suchzeit und Genauigkeit eingegangen werden. Genauere Suchen scheinen langsamer zu sein, wobei allerdings Faktoren wie die Gleichheit zwischen Ziel und Ablenkung ebenso dazu neigen, Fehler zu verursachen [Vol15, S. 35, 89, 90 ff.; Wic+13, S. 58 ff., 96 f.].

Wickens erwähnt fünf Prinzipien, welche dabei unterstützen, nutzerfreundliche Dashboards zu entwerfen. Die Darstellung hat den Anforderungen der Aufgabe zu entsprechen. Darüber hinaus sollen dem Nutzer mentale Aufgaben, wie das Zusammenzählen von Werten für ein Gesamtbild, abgenommen werden. Die Graphen sollen eindeutig interpretiert werden können, wobei die *Data-Ink-Ratio* (dt. Verhältnis von veranschaulichten Daten zu angezeigter Farbe) hoch zu sein hat. Für den Überblick sollen unterschiedliche Graphen weiterhin konsistent aufgebaut werden. Werden mehrere Graphen dargestellt, so ist es wichtig, deren Unterschiede in Form einer Legende oder der Symbolik selbst herauszuarbeiten. Um jedoch dieses konsistente Bild über das gesamte System zu erzeugen, muss ein Kompromiss gefunden werden, sodass nicht immer alle der fünf Prinzipien angewendet werden können. Damit ist beispielsweise die konsistente Nutzung von Farben, Symbolen, Formen oder Bedienelementen gemeint [Vol15, S. 169; Wic+13, S. 86, 93, 406].

Werden verschiedene Graphen häufig in einem gemeinsamen Kontext verwendet, so besagt das *proximity compatibility principle* (dt. Gesetz der Nähe), dass diese zusammengehörigen Informationen beisammen darzustellen sind. Bei der Suche nach Informationen von verschiedenen Oberflächen eines Systems muss zusätzlich zu der Suchzeit auf einer Oberfläche die Zeit zum Wechseln zwischen und Finden der gewünschten Oberfläche einberechnet werden [WC95, S. 473 ff.; Wic+13, S. 50 ff.].

Menschen lernen anhand von Wiederholungen. Je öfter sie eine Aufgabe ausführen oder ein System bedienen, umso leichter fällt es ihnen. Je intuitiver ein System ist, desto weniger Lernaufwand wird benötigt. Gleichzeitig fällt es jüngeren Menschen leichter, sich in einer Multi-Tasking-Aufgabe auf einen bestimmten Aspekt zu konzentrieren. Dafür wird die Leistung des Kurzzeitgedächtnisses sowie ein gewisser Übungsgrad benötigt. Ältere Menschen sind nicht so effizient und es fällt ihnen schwerer, diesen Aspekt

in den vielen gleichzeitigen Aufgaben zu fokussieren. Somit wird das zuvor beschriebene *extensive scanning* noch anspruchsvoller [Wic+13, S. 344].

„Irren ist menschlich“[1] hat Seneca gesagt. Während Fehler unterschiedlichster Art beabsichtigt oder nicht passieren, können *Slips* (dt. Ausrutscher oder Überseher) in der Überwachung von Datenlagen problematisch werden. Laut Definition sind es keine Fehler, da die Intention und das Verhalten des Nutzers korrekt sind, jedoch führen sie zur Ausführung falscher Aktionen. Wenn eine Aufgabe automatisiert abläuft, liegt kaum Aufmerksamkeit auf der Ausführung, wodurch der Nutzer seinen Fehler nicht einmal mitbekommt [Wic+13, S. 312 f.].

Zur Vermeidung von Fehlern werden Aufgaben automatisiert. Für Aufgaben, die Menschen nicht, nur mit schlechter Qualität oder hohem Aufwand lösen können, bieten Maschinen effiziente Lösungen. Dabei soll der Mensch mit allen nötigen Informationen versorgt werden. Um eine Automation menschenzentriert zu gestalten, sollte dessen Ergebnisse verständlich und Vorgänge leicht zugänglich sein. Der Mensch sollte also weiterhin in den Prozess eingebunden bleiben, sodass sich Mensch und Maschine gegenseitig verstehen können. Dabei ist zu beachten, dass das System nicht zu viele Meldungen rausgibt. Diese sind häufig kaum gefiltert und erhöhen somit den Arbeitsaufwand, der durch die Automatisierung abgenommen werden sollte. Dies wird auch die *Ironie der Automation* genannt. Während die Automation zu monotonen Aufgaben, wie der Überwachung der Ergebnisse aus den automatisierten Aufgaben, führt, entzieht sie den Nutzer zu stark aus der Aufgabe. Auch hier greift das Konzept des Lernens, indem Aufgaben, die lange Zeit nicht ausgeführt werden, wieder verlernt werden. Sollte das System mit einer Aufgabe mal überfordert sein, kann der Mensch kaum noch weiterhelfen, da dieser den Überblick über das System und dessen Funktion verloren hat und das aufgetretene Problem nicht versteht [Vol15, S. 182, 193, 202 f.; Wic+13, S. 379 f.].

2.3 MODERNE TOOLS ZUR NUTZERFREUNDLICHEN VISUALISIERUNG VON DATEN

In diesem Abschnitt werden die beiden Tools Sonar und Grafana vorgestellt, welche im späteren Projektkontext Anwendung finden. Beide Tools ermöglichen eine Dashboard-Ansicht zur Darstellung erreichter Testergebnisse, um ein Monitoring der Software-Qualität zu ermöglichen.

2.3.1 *Codeanalysetool Sonar*

Sonar ist ein Werkzeug, um den Zustand und die Qualität von Software-Code zu analysieren und deckt dabei viele Programmiersprachen ab. Anhand der eigenen Testsuite stellt Sonar dessen Ergebnisse, wie beispielsweise die erreichte Code-Coverage (dt. Code-Abdeckung), in einer Dashboard-

1 Wiktionary. Irren ist menschlich. URL: https://de.wiktionary.org/wiki/Irren_ist_menschlich (besucht am: 25.08.2025).

Übersicht dar. Entsprechend der individuellen Anwendungsfälle kann Sonar in verschiedenen Editionen erworben werden. Dabei wird neben einer selbstgehosteten Instanz mit SonarQube eine Cloud-Lösung angeboten. Mit SonarLint wird weiterhin die Integration eines Linters zum Verbessern der Code-Qualität angeboten. [SonoDa; SonoDb; SonoDc]

2.3.2 *Dashboard-Framework Grafana*

Das Dashboard-Framework Grafana ermöglicht es, Daten grafisch und übersichtlich in Form eines Dashboards (dt. Anzeigetafel) darzustellen. Dabei ermöglichen verschiedene Open Source Plugins (dt. Zusatzmodule aus offener Quelle), viele Daten-Formate auszulesen und diese an die Dashboard-Elemente über einen API-Zugang zu übertragen und zu visualisieren. Mit einer großen Auswahl an Visualisierungsmöglichkeiten ermöglicht Grafana, Daten angepasst auf individuelle Bedürfnisse darzustellen. Je nach Nutzung bietet Grafana eine Enterprise- und Open Source Version an, wodurch es in der Cloud als auch selbstgehostet eingesetzt werden kann. [GraoDa; GraoDc; Mic23]

3

DASHBOARDS ALS POTENZIELLE LÖSUNG VON EFFIZIENZ- UND ÜBERSICHTLICHKEITSPROBLEMEN IN LEGACY-TESTSYSTEMEN

In Legacy-Testsystemen vereinen sich die Probleme und Schwierigkeiten aus gewachsenen Altsystemen sowie den zunehmend wachsenden Testpools. Da diese dauerhaft zu überwachen sind, werden Nutzer regelmäßig mit dessen Problemen konfrontiert.

Dieser Abschnitt greift die Probleme sowie Grundlagen zur Modernisierung von Legacy-Systemen erneut auf. Es wird eingeordnet, wie sich daraus die Problemstellung der Usability anhand dieser Testsysteme bildet. Zur Lösung dieses Problems werden daraufhin die zu untersuchenden Fragen sowie die Methodik zur Erforschung dieser beschrieben.

3.1 HERAUSFORDERUNGEN IN DER ERSTELLUNG VON DASHBOARDS UND DER ARBEIT MIT LEGACY- UND CODE-TESTING-SYSTEMEN

Veraltete Systeme stellen Unternehmen zunehmend vor Herausforderungen. Die Systeme sind groß, umfangreich, gewachsen und wenig getestet. Sie bestehen weiterhin aus vielen verschiedenen Technologien und sind schwierig zu warten. Die Fachkräfte, welche die Systeme aufgebaut und jahrelang betreut haben, stehen kurz vor der Rente und der Erhalt der Altsysteme ist langfristig nicht rentabel (s. Abschnitt 2.1).

Zuvor wurde primär darauf eingegangen, wie Legacy-Code zu modernisieren ist (s. Unterabschnitt 2.1.1). Daraus resultiert der Ansatz, die Systeme möglichst frühzeitig und stückweise mit dem Technikstand mitzuführen bzw. die Systeme sukzessiv nachzurüsten. Vor allem umfangreiche und gepflegte Testumgebungen vereinfachen die Modernisierung, indem das gewollte Systemverhalten dauerhaft überprüft werden kann.

Dabei ist dieser Testansatz nicht neu. Feathers beschrieb bereits 2005 in seinem Buch, dass das Testen unerlässlich zur Bewältigung von Legacy-Anwendungen ist [Fea13, S. 45]. Unternehmen, die sich im Verlauf der Jahre Testsysteme und Strukturen aufgebaut haben, können jedoch auch hier vor dem Problem stehen, dass diese Systeme sehr umfangreich gewachsen sind (s. Unterabschnitt 2.1.2). Mit zunehmenden Maschinen, Versionen, Komponenten und Testfällen vermehren sich die zu überwachenden Ergebnisse rasant.

Trotz zusammenfassender Ergebnisübersichten ist es schwierig, den Überblick zu behalten und garantieren zu können, alle Werte überprüft zu haben. Zudem wird viel Zeit für dieses manuelle Monitoring benötigt (s. Unterabschnitt 2.1.2). Durch Monotonie, eine abnehmende Aufmerksamkeitsspanne sowie Routine sind Fehler im Prozess, wie nicht wahrgenommene Test-

ergebnisse oder eine fehlerhafte Interpretation dieser, möglich (s. Unterabschnitt 2.1.2). Diese Arbeit ist ohne Automatisierung somit höchst ineffizient (s. Unterabschnitt 2.1.2).

Werden neue Systeme zur Ergebnisanzeige, vor allem Dashboards, umgesetzt, muss das System zuerst analysiert werden, um den gesamten Umfang zu erfassen. Damit ein solches neues System direkt genutzt werden kann, ist eine Vollständigkeit der angezeigten Daten zu garantieren, um nicht zwischen den Systemen im Prozess wechseln zu müssen (s. Unterabschnitt 2.1.1).

3.2 FOKUSSIERUNG AUF DIE PROBLEMSTELLUNG DER EFFIZIENZ UND ÜBERSICHTLICHKEIT VERTEILTER TESTSYSTEME

In dieser Arbeit wird sich auf das Problem der ineffizienten Nutzungsmöglichkeiten von verteilten Testsystemen fokussiert. Durch ihren gewachsenen Charakter haben sich eine Vielzahl an Orten bzw. Seiten, auf denen dessen Ergebnisse abgelesen werden können, zusammengetragen.

Die Überwachung der Ergebnisse dieser *Testpools* dient der Überprüfung des Systemzustands. Die großen und umfangreichen Tests daraus werden beispielweise täglich, und damit vergleichsweise selten im Entwicklungsprozess, ausgeführt. Damit muss das aufwändige manuelle Monitoring dieser als seperater Schritt im Alltag eines Entwicklungsteams eingeplant und durchgeführt werden. Vor allem für neue Teammitglieder ist der Aufwand hoch, sich in ein solches System einzuarbeiten und einen Überblick zu gewinnen, welche Daten vorhanden sind und beachtet werden müssen.

3.3 BEITRAG MODERNER DASHBOARDS ZUR EFFIZIENZSTEIGERUNG UND VERBESSERTEN ÜBERSICHTLICHKEIT VON LEGACY-TESTSYSTEMEN

Zur Modernisierung des Systems wird sich hier auf die Usability als Qualitätskriterium in Form der Veränderung der Effektivität, Effizienz und Zufriedenheit gestützt. Ziel ist es, ein verteiltes Testsystem übersichtlicher zu gestalten und somit dessen Usability zu verbessern. Dafür wird folgende Fragestellung erforscht:

> Wie sinnvoll ist die Einführung eines modernen Dashboards im Hinblick auf das Ziel, den Legacy-Testpoolmonitoring-Prozess effizienter und nutzerfreundlicher zu gestalten?

Zur Beantwortung sollen anhand der in Abschnitt 3.4 folgenden Methodik folgende Teilaspekte geklärt werden:

- Wie weit kann die Usability mithilfe des Dashboards verbessert werden?
- Wie zufrieden sind die Nutzer mit dem Dashboard? Ist ein Umstieg auf das neue System denkbar?

- Wie unterscheidet sich das Dashboard anhand der Intuitivität vom alten System? Ist es auch für neue Nutzer ohne Vorwissen geeignet?
- Wie wirksam ist die Nutzung des Dashboards in Bezug auf die Effizienz des Monitoring-Prozesses?
- Beeinflusst die Nutzung des Dashboards die Effektivität des Monitoring-Prozesses?

3.4 METHODISCHES VORGEHEN ZUR ENTWICKLUNG UND VALIDIERUNG EINES DASHBOARDS ALS MODERNE ANZEIGE DER TESTPOOLERGEBNISSE

Die Ergebnisse der nachfolgenden Forschung dienen als Grundlage zur Beantwortung der Fragen aus dem vorangegangenen Abschnitt 3.3. Es wird als Modernisierungsversuch ein Dashboard auf Grundlage des alten Systems erstellt. Zur Validierung dessen wird eine Nutzerstudie bestehend aus einem Usability-Test sowie einer Nutzerbefragung durchgeführt. Im Folgenden wird der detaillierte Aufbau des Forschungsvorgangs vorgestellt.

3.4.1 *Analyse des Ist-Zustandes der Testpool-Ergebnisanzeige zur Identifikation bestehender Anforderungen*

Begonnen wird die Forschung mit der Aufarbeitung des aktuellen Zustands des Legacy-Systems. Zur Verdeutlichung sowie als Vorlage zum Vergleich wird das verwendete Tool, sein Design und Aufbau zum Ablesen der Testergebnisse dargestellt. Daraufhin wird der tägliche Arbeitsablauf mit diesem System vorgestellt.

Mithilfe der Anwendungstabelle aus der ISO 9241-110 wird dessen Zustand analysiert (s. Unterabschnitt 2.2.1). Diese setzt den Fokus auf alle Merkmale, welche im täglichen Monitoring-Prozess angewendet werden können. Weitere mögliche Eigenschaften, welche in der Tabelle aufgelistet sind, sind für diese Forschung nicht relevant.

Die Beschreibung des Altsystems ist in Kapitel 4 aufgeführt.

3.4.2 *Entwicklung eines Dashboards als moderne Ergebnisübersicht*

Das Ergebnis der Zustandsanalyse des Altsystems definiert die Vorlage, welche Anforderungen und Erwartungen an das neue System gestellt werden können. Zudem gibt dies eine Grundlage, in welchen Punkten das Altsystem potenziell übertroffen werden kann.

Daraufhin wird der Designprozess des Dashboards begonnen. Angefangen bei den Überlegungen zum neuen Arbeitsablauf, wird auf dessen Grundlage ein geeignetes Framework ausgewählt, um das Dashboard umzusetzen.

Es wird aufgezeigt, wie die Ergebnisdaten auf das Dashboard gelangen und welche Grundsätze und Bedingungen im Aufbau der neuen Oberfläche

bestehen. Weiterhin werden Unterschiede zur alten Oberfläche herausgearbeitet.

Zum Schluss wird der Zustand des neuen Dashboards anhand der zuvor festgelegten Anforderungen analysiert und kann daran mit dem Altsystem verglichen werden.

Das neue Dashboard wird in Kapitel 5 vorgestellt.

3.4.3 *Validierung der Dashboard-Lösung anhand einer zweigeteilten Nutzerstudie*

Zur Validierung und Bewertung des Dashboards wird mit der Nutzergruppe, welche das alte Monitoringsystem regelmäßig verwendet, eine Nutzerstudie durchgeführt. Diese teilt sich in einen Test und eine Befragung. Die Studie dient dazu, das Dashboard im Vergleich zum Altsystem einzuordnen und Schlüsse auf dessen Eignung im gestellten Kontext ziehen zu können.

Es wird ein Nutzertest (Usability-Test) mit Aufgaben aus dem Monitoring-Prozess im alten und neuen System ausgeführt. Die Aufgaben sind ausgewählt, um die Themen der nachfolgenden Nutzerbefragung inhaltlich abzudecken. Deren Ergebnisse geben Auskunft über die Effektivität und Effizienz des Dashboards in verschiedenen Bereichen des Monitorings.

Im Anschluss an den Test führen die Nutzer eine Befragung in Form eines Fragebogens für jedes System durch. Dieser ist auf dem Standard von J. Prümper aufgebaut (s. Unterabschnitt 2.2.5). Daraufhin wird die allgemeine Einschätzung des Nutzers abgefragt, ob dieser das System für ausreichend gut geeignet empfindet, um sich vorstellen zu können, es zukünftig zu nutzen.

Die Befragung dient dazu, zusätzlich zur objektiven Bewertung des Usability-Tests eine subjektive Wahrnehmung in Bezug auf die Effektivität und die Effizienz zu erhalten. Zudem gestatten die Antworten, eine Aussage bezüglich der Zufriedenheit der Nutzer mit den Systemen treffen und diese daran vergleichen zu können.

Die Beschreibung des Versuchs sowie die Ergebnisse der Nutzerstudie werden in Kapitel 6 dargelegt. Weiterhin werden diese in Kapitel 7 in Zusammenfassung mit den Ergebnissen der Anforderungs- und Zustandsanalyse im Forschungskontext diskutiert.

4

STAND DER TECHNIK DES BESTEHENDEN LEGACY-TESTPOOLMONITORING-PROZESSES

Die Grundlage dieser Untersuchung bildet ein über viele Dekaden gewachsenes Legacy-System, welches mehrere Millionen Zeilen C- und Java-Code umfasst. Dieses wird anhand dessen Testpools regelmäßig auf Funktion und Verhalten getestet.

Der Testpool enthält hauptsächlich große und umfangreiche Tests. Diese umfassen zum Beispiel, ob das System erfolgreich gebaut und kompiliert wurde. Es werden weiterhin die Ausgaben und Reaktionen von einfachen Terminal- beziehungsweise Character-Oberflächen bis zu Java-Dialogen überprüft. Das Systemverhalten wird über diese Oberflächentests indirekt mitgetestet. Anhand des Verhaltens auf der Oberfläche wird überprüft, ob alle Client-, Server- und weiteren Produkte in Kombination funktionieren.

Die Tests werden täglich anhand verschiedener Versionen der Software ausgeführt und müssen auf Fehler überwacht werden, damit diese zeitnah behoben werden können. In diesem Anwendungsfall wird der tägliche Umgang mit der Ergebnisanzeige dieser Tests untersucht. Zur Eingrenzung des Umfangs wird sich dabei auf den Testpool für den C-Code konzentriert.

Im nachfolgenden Kapitel wird das Tool der Ergebnisanzeige beschrieben, wie dieses aufgebaut ist und im Zusammenhang mit den Tests funktioniert, um deren Ergebnisse darzustellen. Daraufhin wird ein Überblick über die bisherige Oberfläche sowie den damit verbundenden Arbeitsablauf gegeben. Zum Schluss wird eine Zustandsanalyse durchgeführt, an welcher die Stärken und Schwächen des Systems herausgestellt werden, um im nachfolgenden Kapitel 5 auf dessen Grundlage, Anforderungen für ein neues, verbessertes System aufzustellen.

4.1 TECHNISCHE UMSETZUNG DES DATENFLUSSES ZUR ANZEIGE

Jeder Test aus dem Testpool wird gruppiert durch einen Job durchgeführt. Sobald die Testsammlungen eines Tools durchgelaufen sind, werden deren Ergebnisse in eine Textdatei geschrieben (s. Abbildung 4.1). Das Tool für die Ergebnisanzeige ist ein proprietäres Tool und eine Art Vorstufe eines Dashboards. Das Skript zur Ausführung dieser Oberfläche überprüft, ob alle Ergebnisse valide sind, sodass abhängig davon weitere Tests gestartet werden können. Das Anzeigetool liest die Textdatei mit den Ergebnissen aus, bereitet die Daten auf und erzeugt jeweils eine Übersichtsseite pro Version bzw. Anwendungsfall.

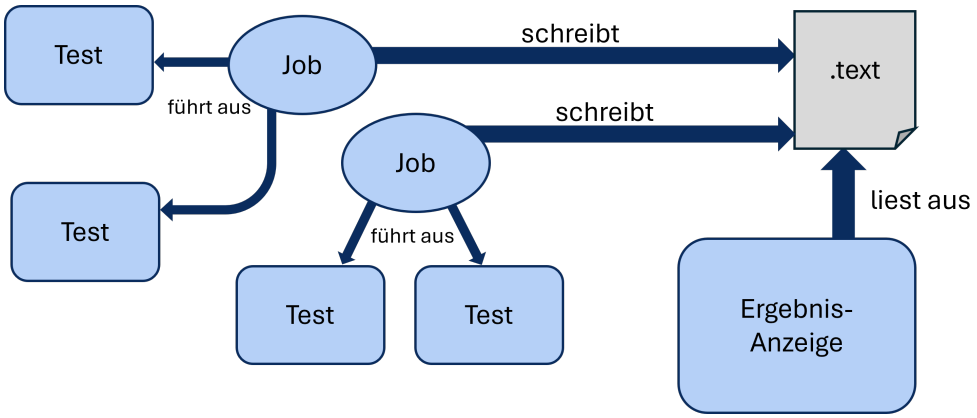


Abbildung 4.1: Kontrollsequenz des Datenflusses vom ausgeführten Test zur Ergebnisanzeige

4.2 ÜBERBLICK UND AUFBAU DER BESTEHENDEN ERGEBNISANZEIGE

Das System zur Anzeige der Testpoolergebnisse besteht aus verschiedenen Oberflächen, die jeweils einen Anwendungsfall darstellen. Abbildung 4.2 ist ein Ausschnitt aus der Oberfläche. Außerhalb des Bildausschnitts sind aufklappbare Menüs (Drop-Down-Menüs) zu finden, in denen die Attribute, wie beispielsweise der Maschinenname und die Versionsnummer, auswählbar sind. Die Oberflächen sind weiterhin über einen internen Link zugänglich, in dem alle Attribute zur Identifikation angegeben sind.

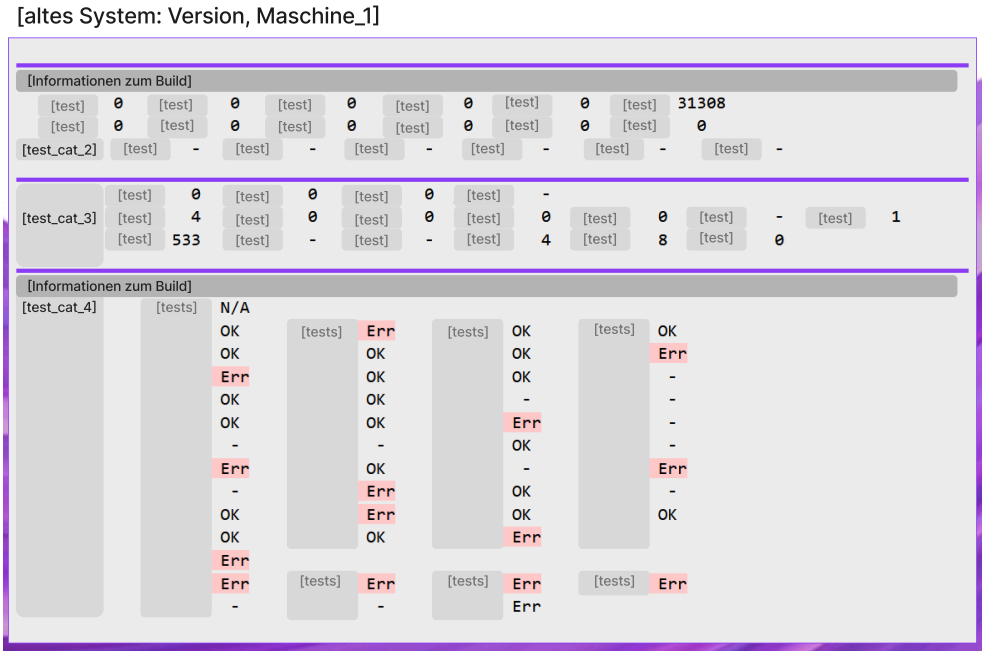


Abbildung 4.2: Beispielhafter Aufbau einer Oberfläche im alten System

Der Bildausschnitt von Abbildung 4.2 zeigt die Testergebnisse eines Anwendungsfalls. Die Attribute, die diesen Anwendungsfall beschreiben, stehen

links, oberhalb der Testergebnisse. Das Bild ist zensiert, damit keine Rückschlüsse auf interne Informationen gezogen werden können, wobei der konkrete Inhalt unabhängig für diese Untersuchung ist.

Im Hauptbereich sind insgesamt drei Reihen mit Textfeldern zu erkennen. Diese lassen sich in die Testfall-Kategorien unterscheiden, wie zum Beispiel *[test_cat_2]*. Dieser Kategoriename steht jeweils in der linken Spalte. Die erste dieser Kategorien hat keinen Namen, jedoch werden alle dort aufgeführten Tests mit dem Bauprozess (*Build*) assoziiert. Die dazugehörigen Informationen wie System, Datum, Uhrzeit und Versionsnummer sind an Stelle des Feldes *[Informationen zum Build]* aufgelistet.

Pro Kategorie sind alle Testumgebungen, die jeweils aus einer Sammlung an Tests bestehen, in Spalten aufgelistet. Rechts neben einer Spalte ist das jeweilige zusammengefasste Ergebnis dieser Testsammlung dargestellt. Hierbei zeigen die ersten drei Kategorien die Anzahl der fehlgeschlagenen Testfälle an. Steht ein einfacher Querstrich als Ergebnis, so konnte diese Testumgebung noch nicht vollständig ausgeführt werden, wodurch noch kein Ergebnis ersichtlich ist. In Test-Kategorie vier wird hingegen der Zustand der Testsammlung angezeigt. Bei „OK“ sind alle Tests ohne Fehler durchgelaufen. Wird „Err“ angezeigt, gibt es mindestens einen Test, der fehlgeschlagen ist. Der Querstrich sagt weiterhin aus, dass diese Tests noch nicht gelaufen sind. Eine weitere mögliche Anzeige ist „CORE“. Wird dies dargestellt, so ist ein Test abgestürzt und der Prozess muss neu gestartet werden. Der letzte dargestellte Status „N/A“ steht für not available (dt. nicht verfügbar). Diese Testsammlung findet im angezeigten Kontext keine Anwendung.

4.3 BESCHREIBUNG DES BISHERIGEN ARBEITSABLAUFS

Mithilfe der Ergebnisanzeige lässt sich der Allgemeinzustand des Systems überwachen (en. monitoring). Alle nachfolgenden Aussagen bezüglich des Arbeitsablaufs wurden aufgrund von Mitarbeiteraussagen (s. Anhang E) sowie eigener Erfahrung im Einarbeitungsprozess zusammengefasst.

Am Morgen öffnet die Person, die für das Monitoring zuständig ist, bis zu 20 Links für die verschiedenen Systeme und arbeitet diese stückweise ab. Die Drop-Down-Menüs der Attribute, die neben den Testergebnissen zu finden sind (s. vorheriger Abschnitt 4.2), werden zum Aufrufen der Oberflächen selten verwendet. Dadurch, dass alle vergangenen Varianten der Anwendungsfälle immer noch auswählbar und dadurch auch ungültige Kombinationen möglich sind, ist es gängig, sich alle benötigten Links als Lesezeichen in einem Ordner abzuspeichern.

Zum Monitoring wird jeweils nach gewissen Kennzahlen geschaut. Im Fehlerfall wird den zuständigen Personen Bescheid gegeben, damit sie diese Probleme erforschen und schließlich beheben können.

Diese Vorgehensweise ist jedoch unpraktisch, da neue Mitarbeiter sich diese Links erst erfragen müssen, da diese nirgendwo einheitlich aufgelistet und eindeutig deklariert sind. Da meist nur der Link zur akut benötigten Seite erfragt wird, muss dieser vom Ansprechpartner entsprechend einzeln

nach Anwendungsfall aus der Menge rausgefiltert werden, um diesen weiterzuleiten.

Weiterhin wird je nach Erfahrungsstand bzw. Kenntnissen entschieden, ob es sich am jeweiligen Tag um einen *Green Day*[1] handelt. In der nachfolgenden Nutzerstudie (s. Kapitel 6) wurde von den Teilnehmern mehrfach angemerkt, dass es sich am entsprechenden Tag gemäß Ergebnisanzeige nicht um einen Green Day handle. Es würden jedoch aktuell nur bekannte Fehler der Testumgebung gezeigt werden, die nicht kurzfristig lösbar seien. Da diese nicht das Produkt selbst beträfen, werde es somit dennoch als Green Day gewertet.

4.4 ZUSTANDSANALYSE DES ALTEN SYSTEMS ALS VORLAGE ZUR ANFORDERUNGSANALYSE FÜR DAS NEUE SYSTEM

Die bestehende Oberfläche zur Anzeige der Testpool-Ergebnisse ist über die Jahre gewachsen und nicht mehr die optimale Lösung. Zur Vorbereitung der Anforderungsanalyse für das neue System werden nachfolgend Merkmale aufgelistet, welche beibehalten werden sollen, sowie Schwächen und Probleme identifiziert, welche durch die neue Lösung zu beheben sind.

Das System zeigt alle Ergebnisse des Testpools vollständig und tagesaktuell an. Dabei können die Ergebnisse nach genutzter Maschine und Versionsnummer sowie nach Art des Tests unterschieden werden. Das System ermöglicht es weiterhin, Details der Testdurchführung anhand von Logeinträgen einzusehen.

Die Menge der Daten ermöglicht es dem alten System jedoch nicht, eine Übersichtlichkeit herzustellen. Das bedeutet, dass der Überblick über viele einzelne Oberflächen behalten werden muss und das System es nicht eindeutig ermöglicht, zwischen den Anwendungsfällen zu wechseln. Innerhalb einer Oberfläche sind die Ergebnisse in verschiedenen Varianten dargestellt. Im positiven Fall als *OK* oder Null und im Fehlerfall als Anzahl der Fehler oder als rot hervorgehobenes Feld mit *ERR* darin. Weiterhin sind die verfügbaren Oberflächen nicht ausreichend dokumentiert.

Die Umsetzung der Usability dieses Systems wurde anhand der „Tabelle zur Unterstützung der Anwendung [der ISO 9241-110]“ [Dina] bewertet. Darin wird erfasst, welche Empfehlungen für diesen Anwendungsfall umsetzbar sind und ob diese umgesetzt wurden (s. Unterabschnitt 2.2.4). Nachfolgend ist eine Zusammenfassung der Erkenntnisse der Zustandsanalyse in Tabelle 4.1 anhand der Interaktionsprinzipien aufgelistet.

1 Ein *Green Day* (dt. grüner Tag) ist ein Tag an dem das Testsystem keine Fehler anzeigt. Der Name kommt von der Farbdarstellung. Fehlerhafte Tests werden in der einzelnen Ergebnisübersicht rot dargestellt, während Tests, die fehlerfrei durchgelaufen sind, grün dargestellt werden.

Prinzip Nr.	Anzahl Empfehlungen	davon umsetzbar	davon umgesetzt
1) Aufgabenangemessenheit	6	6	2
2) Selbstbeschreibungsfähigkeit	8	6	3
3) Erwartungskonformität	11	8	5
4) Erlernbarkeit	6	6	1
5) Steuerbarkeit	10	6	4
6) Robustheit gegen Benutzungsfehler	12	1	0
7) Benutzerbindung	12	4	3
Summe	65	37	18

Tabelle 4.1: Anzahl der vom alten System umgesetzten Empfehlungen nach der Tabelle der DIN EN ISO 9241-120 [Dina] (Zusammenfassung von Anhang A)

5

ENTWICKLUNG EINES DASHBOARDS ALS MODERNE ANZEIGE DER TESTPOOLERGEBNISSE

Durch dessen gewachsene Struktur ist die alte Ergebnisanzeige des Testpools lediglich ineffizient nutzbar. Um das Monitoring dieser Ergebnisse effizienter zu gestalten, wurde ein Dashboard erstellt. Dieses basiert darauf, den Monitoring-Prozess durch Umstellung auf eine neue Oberfläche anhand der Usability-Kriterien Effektivität, Effizienz und Nutzerzufriedenheit zu steigern, ohne in das bestehende System einzugreifen.

Nachfolgend werden zuerst die Anforderungen auf Grundlage des bestehenden Systems (s. Abschnitt 4.4) analysiert. Daraufhin wird das verwendete Tool vorgestellt und der Datenfluss zum Dashboard sowie dessen vollständiger Aufbau dargestellt.

5.1 ANFORDERUNGSANALYSE ANHAND DES ZUSTANDS DES BESTEHENDEN LEGACY-SYSTEMS

Die neue Oberfläche soll die Ergebnisse des Testpools ebenso wie das alte System vollständig und tagesaktuell wiedergeben sowie nach den Kriterien Maschinenname, Versionsnummer und Art des Tests unterscheiden können. Hierbei kann das neue System die verteilten Daten des alten Systems zusammenfassend und einheitlich darstellen und lediglich im Fehlerfall maximal einen Klick mehr benötigen, um an wichtige Detailinformationen zu gelangen. Dies soll ermöglichen, den Zustand des gesamten Testpools mit wenigen Blicken zu erfassen.

Neben der Weiterleitung zu den Details der Testdurchführung soll das neue System dazu anregen, alle Quellen im Zusammenhang mit dem Testpool zu sammeln, um einen Überblick in Form einer Dokumentation zu erstellen.

Ziel ist es, ein System zu erschaffen, welches sowohl funktional als auch in Anbetracht der Usability eine Verbesserung zum alten System darstellt. Mithilfe der „Tabelle zur Unterstützung der Anwendung [der ISO 9241-110]“ [Dina], an welcher bereits der Zustand des alten Systems bewertet wurde, werden beide Systeme miteinander verglichen. Zur Verbesserung der Usability wird eine Steigerung der Anzahl der umgesetzten Empfehlungen erwartet.

5.2 DESIGNSKIZZE DES ZUKÜNFTIGEN ARBEITSABLAUFS

Unter Annahme der Vollständigkeit der Informationen und Funktionen auf dem Dashboard sowie der Etablierung des Dashboards in den Arbeitsablauf wird von folgendem Szenario ausgegangen:

Zum Beginn des Arbeitstages öffnet die zuständige Person das Dashboard mit den Testpool-Ergebnissen. Wenn alle Werte positiv sind bzw. keine Fehler angezeigt werden, so ist diese Information in kurzer Zeit leicht erfassbar.

Sollten Fehler auftreten, sind diese klar farblich markiert und unterscheidbar von den fehlerfreien Testfällen aufgeführt. Für die zur Behebung benötigten Fehlerdetails wird in unmittelbarer und klar identifizierbarer Nähe eine Verlinkung angeklickt und auf das alte System weitergeleitet, welches diese Informationen enthält.

Zusammengefasst soll das neue System im positiven Fall dieses fehlerfreie Ergebnis auf einer oder wenigen Oberflächen übersichtlich anzeigen. Im negativen Fall soll die neue Oberfläche dem Nutzer im Vergleich zum alten System schneller und eindeutiger anzeigen, wo Fehler aufgetreten sind. Zudem soll die Verwendung des neuen Systems den Nutzer im negativen Fall nur einen Mausklick mehr benötigen, um die Details zur Fehlerbehebung in Erfahrung zu bringen.

5.3 AUSWAHL DES DASHBOARD-TOOLS

Mit dem bestehenden Vorwissen sowie einem eingerichteten Server startete das Projekt zur Erstellung des Dashboards mit der Erwartung, Sonar (s. Unterabschnitt 2.3.1) nutzen zu können, da es bereits im Kontext eines anderen Produktes genutzt wurde. Weiterhin bietet Sonar viele nützliche Funktionalitäten an. Da das Dashboard in der Zukunft um eine Code-Analyse-Sektion erweitert werden soll, scheint die integrierte Funktionalität von Sonar angemessen. Jedoch ist die Lizenz von Sonar von der Anzahl der Codezeilen abhängig [SonoDb]. Mit der Menge der Codezeilen im bestehenden System (s. Kapitel 4) wurde entschieden, dass diese finanzielle Belastung[1] nicht realistisch tragbar ist, zumal die Gelder dafür regelmäßig neu beantragt werden müssten.

Das neue Dashboard wurde schließlich mit Grafana Version 11.6.1 erstellt. Zwar hat das Tool nicht die gleichen Code-spezifischen Funktionalitäten wie Sonar, ist jedoch ein modernes viel genutztes Tool (s. Unterabschnitt 2.3.2).

Zur Dashboard-Erstellung unterstützt Grafana jegliche Dateiformate über einen API-Zugriff [Mic23]. Es ermöglicht zudem ein einfaches Drag-and-Drop (dt. ziehen und fallen lassen) der Elemente zur Dashboard-Erstellung und bietet viele Einstellungsmöglichkeiten zum Individualisieren [GraoDb]. Weiterhin existiert im Projekt-Kontext bereits ein Server, auf dem Grafana installiert ist, weshalb sich für dieses Framework entschieden wurde, um das neue Dashboard zu erstellen.

1 Mit den angegebenen 720 Euro jährlich ab 100.000 Code-Zeilen entstehen bei etwa 2 Mio. Zeilen Code Kosten in Höhe von 14.400 Euro jährlich. [SonoDb]

5.4 TECHNISCHE UMSETZUNG DES DATENFLUSSES ZUR DASHBOARDANZEIGE

Die Dashboardanzeige sitzt symbolisch gesprochen auf dem alten System (s. Abschnitt 4.2) auf. Das bedeutet, dass es die bestehenden Daten auswertet und diese neu darstellt (s. Abbildung 5.1).

Die Daten werden von einem Parser eingelesen (s. Abschnitt B.1), welcher diese in Fehlerkategorien zusammenfasst (s. Abschnitt 5.5) und im JSON-Format abspeichert (s. Abschnitt B.2). Der Parser-Code wird regelmäßig durch einen Jenkins-Job aufgerufen und dessen Ausgabe auf einen Dateiserver gespeichert und die vorherige Datei überschrieben.

Das Dashboard kann auf den Server zugreifen und mithilfe der API über den Adress-Pfad die kategorisierten Daten aus der JSON-Datei auslesen. Diese werden regelmäßig neu abgefragt und angezeigt.

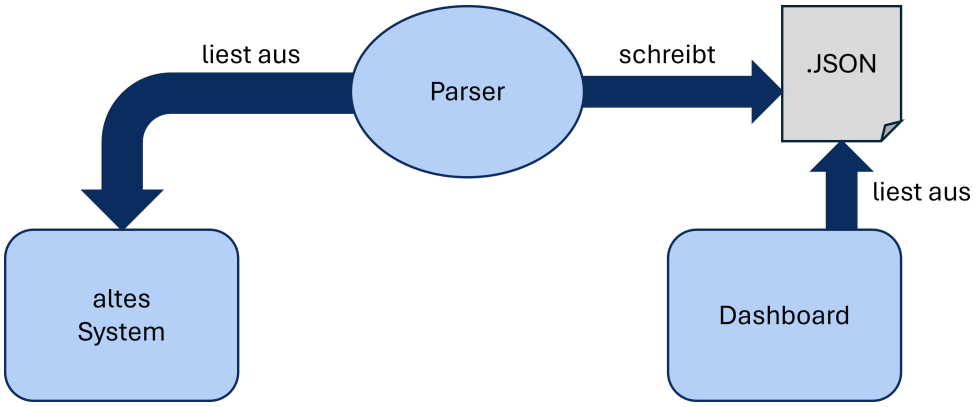


Abbildung 5.1: Kontrollsequenz des Datenflusses vom alten System zum Dashboard

5.5 Überblick über den strukturellen Aufbau und Inhalt des Dashboards

Die Daten aus den Oberflächen des alten Systems werden auf zwei Dashboards aufgeteilt. Dabei gibt es je eins für die Entwicklungsversion und eins für alle veröffentlichten und aktiv gewarteten Versionen (Release-Versionen). Da die Release-Versionen bis auf kleinere Fixes kein Bestand des Tagesgeschäfts mehr sind, ist die Anzahl der benötigten Tests bedeutend geringer. Somit kann der Statusbericht mehrerer Versionen gesammelt auf einem seperaten Dashboard angezeigt werden.

Grafana gibt eine Dashboard-Struktur in Reihen vor. Jede Reihe stellt ein System dar, welches im alten System jeweils eine eigene Seite benötigt. Diese Reihen sind für die Übersichtlichkeit zusätzlich einklappbar. Die Panele einer Reihe sind in drei Spalten aufgeteilt (s. Abbildung 5.2).

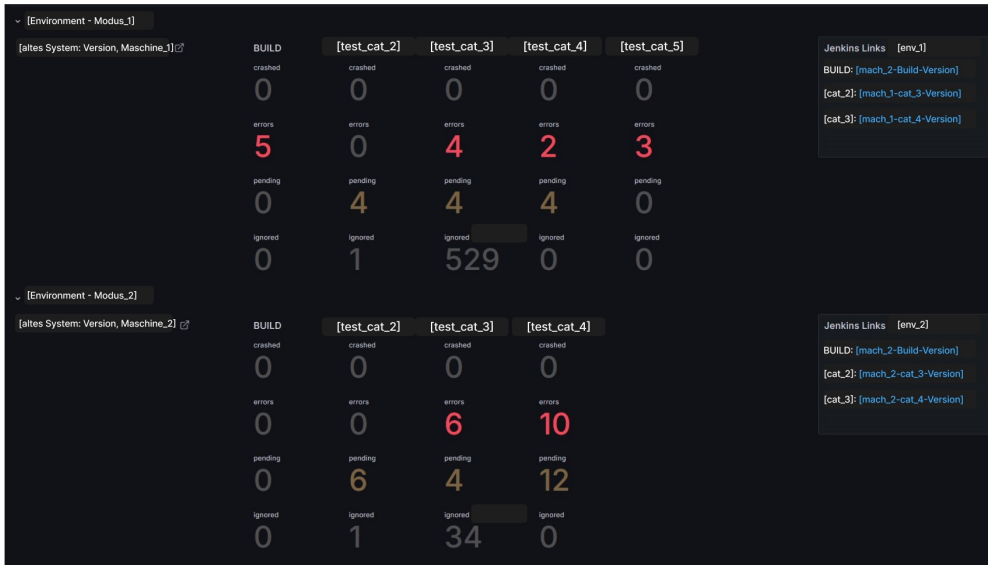


Abbildung 5.2: Aufbau des entwickelten Dashboards

Die jeweilige Fehlerzahl bzw. der Zustand der entsprechenden Testkategorie wird in der mittleren Spalte in verschiedenen Farben dargestellt. Im Falle eines Green Days, ein Tag an dem keine Fehler auftreten, steht in allen Feldern eine dunkelgraue Null. Um die Relevanz des Fehlerfalls darzustellen, werden diese Zahlen farbig hervorgehoben (s. Unterabschnitt 2.2.6). Die Fehlerkategorien sind 'System abgestürzt', 'Anzahl der Fehler', 'Anzahl der ausstehenden Tests' und 'ignorierte Tests'.[2] Aufgrund der Menge an Testfällen und der Anforderung, alle zusammengehörigen Daten auf einen Blick erfassen zu können (s. Abschnitt 5.1), sind die Test-Kategorien in Spalten und deren Ergebnisse in den Reihen darunter dargestellt. Im Vergleich zum alten System wurden die Reihen und Spalten vertauscht (s. Abbildung 4.2).

2 Die Kategorie 'Ignorierte Tests' umfasst zum Beispiel Testfälle mit länger bekannten Fehlern, die für die Einschätzung des Green Days ignoriert werden dürfen.

Neben den System-Zustandsinformationen, die auch das alte System anzeigt, bietet das Dashboard die Gelegenheit, weitere Informationen zu sammeln und zur Verfügung zu stellen. Links ist unter dem Reihentitel die Verlinkung auf die Oberfläche des alten Systems zu finden. Dieses bietet genauere Informationen im Fehlerfall (s. Abschnitt 4.2). Für detailliertere Informationen zu den Fehlern werden die Jenkins-Jobs der einzelnen Testkategorien in der Spalte auf der rechten Seite aufgelistet.

In der nachfolgenden Tabelle 5.1 werden die Unterschiede in Funktionen und Eigenschaften beider Systeme noch einmal gegenübergestellt.

<table>
<tr><td></td><td>altes System</td><td colspan="2">Dashboard</td></tr>
<tr><td>Für den täglichen Monitoring-Prozess benötigt</td><td>bis zu 30 Oberflächen</td><td colspan="2">2 Dashboards</td></tr>
<tr><td>Übersicht eines System, einer Maschine & Version</td><td>eine Oberfläche</td><td colspan="2">eine Reihe der selben Oberfläche</td></tr>
<tr><td rowspan="3">Inhalt einer Oberfläche</td><td rowspan="3">Übersicht eines Systems, einer Maschine & Version
→ eine Testkategorie je Reihe</td><td colspan="2">eine Testkategorie je Spalte</td></tr>
<tr><td>Develop</td><td>alle benötigten Kombinationen aus System, Maschine & Version in jeweils einer Reihe</td></tr>
<tr><td>Release</td><td>beide Release-Versionen</td></tr>
<tr><td rowspan="2">Angezeigte Ergebnisse</td><td>je Testsammlung (ca. 20-80 pro Oberfläche) wird ein Fehlerstatus angezeigt</td><td colspan="2">zusammengefasste Zahlen-Werte pro Fehlerkategorie / -status</td></tr>
<tr><td>Fehler können abhängig von der Testkategorie als Status (Err, OK, -, CORE) oder als Fehleranzahl dargestellt werden.</td><td colspan="2">Anzahl der jeweiligen Stati (crashed, errors, pending, ignored)
→ jede Kategorie hat dasselbe Layout</td></tr>
<tr><td>Anzeige des Green Days</td><td>ausschließlich: Null oder OK
→ keine roten Hervorhebungen oder andere Zahlen
→ Hintergrundwissen benötigt, welche Werte ignoriert werden dürfen</td><td colspan="2">ausschließlich dunkelgraue Null
→ keine roten Zahlen</td></tr>
<tr><td rowspan="2">Zugang zu weiterführenden Informationen</td><td rowspan="2">Verlinkung jedes Testcases hinter dem Testnamen führt zur Terminalausgabe des Testverlaufs</td><td colspan="2">Verlinkung zum alten System direkt unter der Reihenbeschreibung</td></tr>
<tr><td colspan="2">Verlinkung zu den einzelnen Jenkins-Jobs aufgelistet nach Kategorienamen</td></tr>
</table>

Tabelle 5.1: Überblick und Zuordnung der alten Funktionalität und Arbeitsweise auf das neue Dashboard

5.6 ZUSTANDSANALYSE AUF GRUNDLAGE DER IDENTIFIZIERTEN ANFORDERUNGEN

Das Dashboard ermöglicht es dem Nutzer, die Ergebnisse des Testpools übersichtlich, vollständig und tagesaktuell anzuzeigen. Dabei wurden zwei Dashboards implementiert, welche die tägliche Nutzung der Entwicklungsumgebung von der veröffentlichten Umgebung unterscheidet. Beide Dashboards

ermöglichen einen vollständigen Zugriff auf alle Systeme, welche an der Erzeugung der Ergebnisse des Testpools beteiligt sind.

Das neue System kann die Anzahl der Anwendungsfälle, welche im alten System mit je einer Oberfläche abgedeckt wurden, nicht reduzieren. Stattdessen trägt die Farbgestaltung, welche den Fehlerfall hervorhebt, zur Übersichtlichkeit bei. Zeigen alle Werte eine graue Null an, so ist der Green Day erreicht und die genauen Ergebnisse der einzelnen Anwendungsfälle müssen nicht weiter betrachtet werden.

Die übernommene Kategorisierung der Ergebnisse gibt dem Nutzer die gleiche gewohnte Struktur vor, wodurch er im Fehlerfall die Stelle im alten System eindeutig identifizieren kann. Anhand der Verlinkung zur entsprechenden Oberfläche des alten Systems kann schließlich auf die Detailausgabe zugegriffen werden.

Anhand der „Tabelle zur Unterstützung der Anwendung [der ISO 9241-110]“ [Dina] ist erkennbar, dass das neue System eine Vielzahl neuer Funktionen und Möglichkeiten bietet. Die Anzahl der umgesetzten Empfehlungen wurde innerhalb fast jeden Prinzips gesteigert (s. Tabelle 5.2).

Prinzip Nr.	Anzahl Empfehlungen	davon umsetzbar	altes System	neues System	
			davon umgesetzt	davon umgesetzt	
1	6	6	2	5	+3
2	8	6	3	5	+2
3	11	8	5	6	+1
4	6	6	1	6	+5
5	10	6	4	6	+2
6	12	1	0	1	+1
7	12	4	3	3	±0
Summe	65	37	18	32	+14

Tabelle 5.2: Anzahl der vom neuen System umgesetzten Empfehlungen nach der Tabelle der DIN EN ISO 9241-120 [Dina] im Vergleich zum alten System (Zusammenfassung von Anhang A; Erweiterung der Tabelle 4.1)

Hierbei ist darauf hinzuweisen, dass nicht ausschließlich weitere Empfehlungen umgesetzt werden konnten. Es ist nicht gelungen, im Rahmen des Prinzips der Selbstbeschreibungsfähigkeit, die „Informationen so darstellen, dass eindeutig ersichtlich ist, welche Benutzungsschnittstellen-Elemente interaktiv und welche nicht interaktiv sind“ [Dina, S. 19]. Während das alte System dies teilweise ermöglicht, wirken die Verlinkungen durch den Darkmode unscheinbar.

Im Rahmen des Prinzips der Erwartungskonformität konnten „Informationen auf unterschiedlichen Gerätearten und Anzeigegrößen [nicht] angemessen [dargestellt]“ [Dina, S. 23] werden. Die Layouts des alten Systems sehen auf verschiedenen Bildschirmgrößen gleich aus, dadurch entsprechend an-

gemessen, um sich im System zurechtzufinden. Das neue System ist anhand eines Rasters aufgebaut, welches sich beim Verändern der Bildschirmgröße oder der Seitenverhältnisse verschieben kann.

Stattdessen kann das neue System sich jedoch im Bereich der Benutzerbindung beweisen, da es so ausgelegt ist, „dass es Benutzererfordernisse antizipiert, deren sich der Benutzer möglicherweise gar nicht bewusst ist“ [Dina, S. 31]. Es liefert zusätzliche Informationen, welche zum Monitoring selbst nicht benötigt werden, jedoch beim Nutzer zu einem fundierten Hintergrundwissen über das System beitragen.

6

VALIDIERUNG DES ENTWICKELTEN DASHBOARDS IN BEZUG AUF DIE USABILITY IM VERGLEICH ZUM LEGACY-SYSTEM

Zur Validierung der modernen Dashboard-Lösung wurde eine Nutzerstudie durchgeführt. Hierfür wurde die Gruppe der Nutzer des bestehenden Systems einer Befragung und eines Usability-Tests unterzogen. Im Nachfolgenden werden die einzelnen Schritte des Versuchsaufbaus, dessen Randbedingungen, Durchführung und deren Ergebnisse dargestellt.

6.1 AUFSTELLEN DER ZU ÜBERPRÜFENDEN HYPOTHESEN

Bevor ein Versuch durchgeführt werden kann, werden Hypothesen aufgestellt, um festzulegen, welche Ergebnisse von der Untersuchung erwartet werden [SR18, S. 398]. Diese dienen der Beantwortung der Teilaspekte der Forschungsfrage (s. Abschnitt 3.3). Die Hypothesen werden zu der jeweiligen Teilfrage zugeordnet, zu dessen Beantwortung deren Ergebnis beiträgt.

Die nachfolgenden Hypothesen sind auf gepaarte Daten ausgelegt. Sie sind einseitig, da eine Verbesserung erwartet wird. Die Null-Hypothesen können ab einem Signifikanzniveau von 0,05 widerlegt werden.
Folgende Hypothesen wurden für diesen Versuch aufgestellt:

1) Wenn die Versuchsperson die Aufgaben mit der neuen Oberfläche bedient, dann kann sie diese effektiver und demnach zuverlässiger beantworten als mit der alten Oberfläche.

- H_{01} = Die Nutzung des neuen Systems ($\mu 2$) hat keinen oder keinen positiven Einfluss auf die Fehlerquote (f) der Anworten der gestellten Aufgaben im Vergleich zur Nutzung des alten Systems ($\mu 1$);
  $f(\mu 1) \leq f(\mu 2)$.
- H_{11} = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Fehlerquote (f) der Anworten der gestellten Aufgaben positiv im Vergleich zur Nutzung des alten Systems ($\mu 1$);
  $f(\mu 1) > f(\mu 2)$.

Werden von den Nutzern innerhalb der Aufgaben des Usability-Tests unter Nutzung des Dashboards signifikant weniger Fehler gemacht als mit dem alten System, so kann die Hypothese H_{01} verworfen werden. Anhand einer solchen Datenlage wäre ein positiver Einfluss des Dashboards auf die Effektivität des Monitoring-Prozesses ersichtlich.

Führt die Nutzung des Dashboards jedoch nicht zu einer signifikanten Verbesserung der Fehlerquote, so muss die Hypothese H_{01} beibehalten werden. Jedoch könnte aus diesem Ergebnis nicht abgeleitet werden, ob das alte System signifikant effektiver ist.

Zur Bewertung der Effektivität trägt die Bewertung der Umsetzung der Interaktionsprinzipien Aufgabenangemessenheit und Steuerbarkeit der DIN EN ISO 9241-110 [Dina] bei (s. Unterabschnitt 2.2.4).

2) Wenn die Versuchsperson die Aufgaben mit der neuen Oberfläche bedient, dann kann sie diese effizienter beantworten im Vergleich zur alten Oberfläche. (Effizienz = Fehlerquote : Zeit)

- H_{02} = Die Nutzung des neuen Systems ($\mu 2$) hat keinen oder keinen positiven Einfluss auf die Effizienz (e) der gestellten Aufgaben im Vergleich zur Nutzung des alten Systems ($\mu 1$);
  $e(\mu 1) \leq e(\mu 2)$.
- H_{12} = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Effizienz (e) der gestellten Aufgaben positiv im Vergleich zur Nutzung des alten Systems ($\mu 1$);
  $e(\mu 1) > e(\mu 2)$.

Das Dashboard beeinflusst die Effizienz des Monitoring-Prozesses positiv, wenn die Kombination aus Bearbeitungsdauer und Fehlerquote der Ergebnisse der Aufgaben eine signifikante Verbesserung darstellen. Mit dieser Datengrundlage kann die Hypothese H_{02} verworfen werden.

Da die Nutzer das Dashboard vor dem Versuch nicht kennen, ließe sich aus einer solchen Datenlage zusätzlich schließen, dass das Dashboard eine intuitive Nutzung ermöglicht.

Wird weiterhin die Umsetzung der Interaktionsprinzipien Erlernbarkeit, Selbstbeschreibungsfähigkeit und Aufgabenangemessenheit der DIN EN ISO 9241-110 [Dina] (s. Unterabschnitt 2.2.4) positiv bewertet, so trägt dies zu der insgesamten Bewertung bei, dass das Dashboard eine positive Auswirkung auf die Effizienz des Monitoring-Prozesses hat.

Lässt sich anhand der Datenlage keine positive Veränderung der Effizienz feststellen, so wird jedoch kein Rückschluss darauf gezogen, ob das alte System signifikant effizienter wäre.

3) Die Versuchsperson ist zufriedener damit, die Aufgaben mit der neuen Oberfläche zu bedienen im Vergleich zur alten Oberfläche und bewertet deren Usability demnach besser.

- H_{03} = Die Nutzung des neuen Systems ($\mu 2$) hat keinen oder keinen positiven Einfluss auf die Bewertung (b) der Software im Vergleich zur Nutzung des alten Systems ($\mu 1$);
  $b(\mu 1) \geq b(\mu 2)$.
- H_{13} = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Bewertung (b) der Software positiv im Vergleich zur Nutzung des alten Systems

$(\mu 1)$;
$b(\mu 1) < b(\mu 2)$.

Anhand einer positiven Bewertung der Prinzipien Erwartungskonformität und Steuerbarkeit [Dina] (s. Unterabschnitt 2.2.4) lässt sich eine Zufriedenheit der Nutzer mit dem Dashboard feststellen. Diese Erkenntnis trägt weiterhin dazu bei, einzuschätzen, ob ein Umstieg auf das neue System denkbar sei.

Stellt die Datenlage jedoch keine signifikante Verbesserung der Nutzerzufriedenheit dar, so lässt sich schlussfolgern, dass der Systemwechsel auf das Dashboard nicht sinnvoll und somit unwahrscheinlich ist.

Bedeutung der Ergebnisse in Bezug auf die Bewertung der Dashboard-Lösung

Die genannten Hypothesen decken alle Dimensionen der Usability ab (s. Unterabschnitt 2.2.2), wodurch sich die Auswirkungen und potenziellen Verbesserungen des Dashboards auf die Usability des Monitoring-Prozesses feststellen lassen.

Weiterhin ermöglichen diese Ergebnisse eine Einschätzung, wie sinnvoll die Einführung dieser Dashboard-Lösung in den Monitoring-Prozess ist. Während eine signifikante Verbesserung der objektiven Daten für ein sinnvolles Ergebnis steht, so würde eine negative Nutzermeinung bedeuten, dass die Einführung weiterhin sinnvoll ist, die Umsetzung jedoch zu verbessern ist.

Bei einer umgekehrten Datenlage mit einer signifikant höheren Nutzerzufriedenheit, jedoch schlechteren objektiven Testergebnissen müsste weiter evaluiert werden, wo deren Ursache liegt. Konnte der Nutzer nicht schnell genug lernen, so indiziert dies lediglich, dass weitere Zeit für die Umgewöhnung benötigt wird. Allerdings kann dies ebenfalls ein Anzeichen dafür sein, dass die neue Oberfläche mehr Komplexität zum Prozess beiträgt und somit mehr Aufwand für die Nutzer bestünde. Dies würde jedoch keinen Mehrwert für den Monitoring-Prozess erzeugen.

Da alle drei Dimensionen in die Bewertung der Sinnhaftigkeit der Einführung der neuen Dashboard-Lösung einfließt, führt ein doppelt neutrales Ergebnis mit einer signifikanten Verbesserung bereits zum Erfolg des Prototyps. Sollten die Ergebnisse jedoch zu einer signifikanten Verschlechterung des Zustands führen, so würde diese Lösung nicht als sinnvoll eingestuft werden.

6.2 VERWENDETE MEDIEN FÜR DEN VERSUCH

Für den Versuch wurden verschiedene Medien verwendet.

Für die Befragung der Personen wurde ein Meeting[1] aufgesetzt, welches aufgezeichnet werden kann. Die Teilnehmer haben einen Fragenkatalog (s. Unterabschnitt 6.2.1) und einen Aufgabenkatalog (s. Unterabschnitt 6.2.2)

1 mit Microsoft Teams

erhalten. Diese wurden in Form einer Umfrage über die kostenlose Online-Plattform Survio[2] aufbereitet.

Weiterhin wurden für den Versuch die Testpoolmonitoring-Oberflächen des alten Systems (s. Kapitel 4) sowie die Dashboards des neuen Systems (s. Kapitel 5) genutzt, um diese zu vergleichen. Die Anzeigedaten des neuen Systems wurden hierbei durch zufällige gemockte Daten ersetzt, damit dieselben tagesaktuellen Daten nicht zwei mal abgefragt werden und eine Verfälschung der gemessenen Zeiten verursachen.

6.2.1 *Erstellung des Fragebogens für die Nutzerbefragung*

Der Fragebogen für die Nutzerbefragung wurde nach dem Vorbild von Jochen Prümper [Proo6] (s. Unterabschnitt 2.2.5) erstellt. Das Validierungsverfahren zielt auf die Auswertung der Usability der Dashboard-Lösung im Vergleich zum bestehenden System ab. Da in die ISO-Norm jedoch auch die Auswertung der User-Experience inbegriffen ist, wurde der Fragenkatalog gekürzt. Die Abgrenzung zwischen den Begriffen Usability und User-Experience wird in Unterabschnitt 2.2.3 dargestellt.

Der Fragenkatalog wurde auf insgesamt zehn Fragen gekürzt. Alle weiteren können entweder nicht auf Dashboards beziehungsweise Informationsanzeigen angewendet werden oder haben keine Relevanz für die Auswertung in Bezug auf den Anwendungsfall des täglichen Monitorings. Die genaue Zuordnung der Begründungen zu den gefilterten Fragen ist in Abschnitt C.2 aufgelistet. Der resultierende Fragebogen ist in Abschnitt C.3 aufgeführt und dessen Fragen den Interaktionsprinzipien zugeordnet. Die verwendeten Abkürzungen der Prinzipien sind aus dem Originalfragebogen übernommen und in Abschnitt C.1 aufgeschlüsselt.

Nachfolgend wird mit der Kurzform 'Frage 1', 'Frage 2' etc. auf den Fragebogen referenziert.

6.2.2 *Erstellung des Aufgabenkatalogs für den Usability-Test*

Der Usability-Test wurde auf Grundlage des Fragebogens gestaltet, um alle abgefragten Szenarien abzudecken und Unterschiede zwischen den Systemen für die Bewertung hervorzuheben.

Der daraus resultierende Aufgabenkatalog ist in Abschnitt D.1 aufgelistet. Er umfasst den täglich benötigten allgemeinen Status der Tests, die Abfrage verschiedener Varianten von absoluten Werten, dessen Ergebnisse jeweils unterschiedlich abzulesen sind, sowie den Wechsel zwischen den beiden Dashboards. Ein zusammenfassender Überblick über die Aufgabentypen ist in Tabelle 6.1 aufgelistet. Eine detaillierte Auflistung über die Gründe der Aufgabenauswahl und der verwendeten Reihenfolge ist in Abschnitt D.2 aufgeführt.

Nachfolgend wird mit der Kurzform 'Aufgabe 1', 'Aufgabe 2' etc. auf den Aufgabenkatalog des Usability-Tests referenziert.

2 Survio. URL: https://www.survio.com/de/ (besucht am 14.06.2025).

<table>
<tr><td rowspan="2">Nr</td><td rowspan="2">Stichwort</td><td colspan="2">Aufgabentyp</td></tr>
<tr><td>altes System</td><td>neues System</td></tr>
<tr><td rowspan="2">1</td><td rowspan="2">Green Day</td><td>sind rote Felder mit 'ERR' oder Zahlen != 0 zu sehen?</td><td>Sind rote Zahlen zu sehen?</td></tr>
<tr><td colspan="2">Überblick über ein System</td></tr>
<tr><td rowspan="2">2</td><td rowspan="2">Build</td><td>Rechenaufgabe (ohne Farbgestaltung)</td><td>Ableseaufgabe (rote Zahl von 2 Systemen zusammenzählen)</td></tr>
<tr><td colspan="2">Zusammenfassung von 2 Systemen</td></tr>
<tr><td rowspan="2">3</td><td rowspan="2">Release</td><td>Rechenaufgabe (2 neue Oberflächen)</td><td>Ableseaufgabe (2. Dashboard)</td></tr>
<tr><td colspan="2">- das System / Oberfläche wird gewechselt
- je eine Aufgabe pro System</td></tr>
<tr><td rowspan="2">4</td><td rowspan="2">Modi</td><td>Zählaufgabe</td><td>Ableseaufgabe</td></tr>
<tr><td colspan="2">- das System / Oberfläche wird zurück gewechselt
- je eine Aufgabe pro System</td></tr>
</table>

Tabelle 6.1: Usability-Test: Überblick über die Aufgabentypen (Zusammenfassung aus Abschnitt D.1 und Abschnitt D.2)

6.3 BESCHREIBUNG DES VERSUCHSDESIGNS

Es wird untersucht, inwiefern sich die Ausprägung der Usability-Kriterien der Effektivität, Effizienz und Zufriedenheit verändert, wenn für den Usability-Test zum einen das alte und zum anderen das neue System verwendet werden und wie der Nutzer nach diesem Test das jeweilige System bewertet.

Die Daten teilen sich in abhängige und unabhängige Variablen. Die unabhängigen Variablen sind die Ursache für die zu erhebenen Daten und umfassen die einzelnen Fragen und Aufgaben. Jede Frage bzw. Aufgabe ist jeweils im alten und im neuen System von den Probanden zu bearbeiten.

Die erhobenen Ergebnisse sind die drei abhängigen Variablen. Diese umfassen das subjektive Maß der Zufriedenheit sowie die objektiven Maße der Zeit und des Fehlers. Als Zufriedenheit werden verschiedene Aspekte der Systeme bewertet. Die Zeit meint die Dauer, welche die Testperson zur Erfüllung der Aufgaben benötigt. Die Fehler werden als Rate oder Fehlerquote gemessen, zu wie viel Prozent die Aufgaben richtig beantwortet wurden. Im Anschluss können die Zeit und die Fehlerquote zu einer Effizienzbewertung verrechnet werden.

Damit die Beeinflussung der Testpersonen gering gehalten wird und ein *Reihenfolgeeffekt* [Ann09] ausgeschlossen werden kann, werden die Probanden in zwei Versuchsgruppen aufgeteilt, welche die Systeme in unterschiedlicher Reihenfolge bearbeiten.

Jeder Versuch wird aufgezeichnet, daher können die Daten kontrolliert und wiederholbar erfasst werden.

Um die Daten auszuwerten, werden die Mittelwerte zur Bestimmung der Tendenz des Ergebnisses verglichen sowie der t-Test (s. Unterabschnitt 6.7.1) zur Bestimmung der statistischen Signifikanz der Aussage durchgeführt.

Alle aufgezeichneten Daten sind metrisch und es kann eindeutig interpretiert werden, welches System für diesen Anwendungsfall besser geeignet sein wird.

6.4 BESCHREIBUNG DES VERSUCHSAUFBAUS

Für den Versuch wird ein Tool benötigt, mit dem der Bildschirm der Versuchspersonen aufgezeichnet werden kann, damit die Auswertung eindeutig und wiederholbar ist. In diesem Fall wurde die online Plattform Microsoft Teams verwendet, die über die Möglichkeit von Eins-zu-Eins-Meetings sowie der Bildschirmfreigabe und Aufnahmefunktion verfügt. Weiterhin ist eine Umgebung mit den Fragen und Aufgaben vorzubereiten. In diesem Fall wurde ein Link geteilt, welcher zu einer Umfrage führt, die alle benötigten Anleitungen, Anweisungen, Links, Aufgaben- und Fragestellungen enthält. Es ist vorauszusetzen, dass das verwendete System bzw. die Versuchsperson an ihrem persönlichen Gerät alle Zugriffsberechtigungen auf die benötigten Systeme besitzt.

6.5 BESCHREIBUNG DER TEILNEHMERSTICHPROBE

Es wurden acht Mitarbeiter und zwei Mitarbeiterinnen aus zwei Abteilungen der Software GmbH befragt. Beide Teams nutzen und verwalten das alte System zur Abfrage der Testpoolergebnisse. Neun der Probanden sind seit über 30 Jahren Teil der Firma mit variierender Expertise von wenig ausgeprägt bis zur täglichen Nutzung in dem abgefragten Gebiet. Fünf davon sind auf das Themengebiet spezialisiert.

Das Alter spannt sich von einmal 30-39 Jahre, dreimal 50-59 Jahre und siebenmal 60+ Jahre.

Acht Personen gaben an, das alte System täglich zu nutzen, zwei regelmäßig und eine Person unregelmäßig. Da die gezeigten Testpoolergebnisse relevant für das Tagesgeschäft sind, arbeitet jeder Mitarbeiter mit dem alten System. Währenddessen hat keiner das neue System zuvor gesehen. Es war jedoch bekannt, dass das Projekt geplant und umgesetzt wird.

Kollegen, die das Projekt betreut haben, sind aus der Untersuchung ausgenommen, um die gemessenen Zeitwerte durch eine bessere Orientierung auf der neuen Oberfläche sowie die subjektive Bewertung der Systeme durch Voreingenommenheit nicht zu verfälschen. Bis auf diese wurden alle Personen einbezogen, die mit dem alten System arbeiten und entsprechend für diese Untersuchung geeignet sind.

6.6 BESCHREIBUNG DER VERSUCHSDURCHFÜHRUNG

Für den Versuch werden die Probanden einzeln in Online-Meetings geladen. Das Vorhaben und der Kontext der Befragung wird zuvor kurz in der Einladung erwähnt, aber nicht weiter ausgeführt.

Nach Meetingstart wird erneut das Vorhaben und der Zweck der Befragung erläutert. Nach Aufforderung und Zustimmung überträgt die befragte Person ihren Bildschirm und die Aufzeichnung des Meetings wird gestartet.

Es wird ein Link zur Online-Umfrage geteilt. Damit ein möglichst vergleichbares Umfeld geschaffen werden kann, werden alle benötigten Anleitungen, Anweisungen, Links, Aufgaben- und Fragestellungen durch diese Umfrage vermittelt. Bis auf die Klärung von Verständnisfragen wird bis zur Diskussionsrunde am Ende nicht weiter mit der befragten Person interagiert.

Damit kein Text überflogen wird und wichtige Informationen überlesen werden, werden die Texte und Anweisungen schrittweise auf je eine Folie geschrieben.

In der Umfrage werden zuerst die demografischen Daten Alter, Zugehörigkeit in der Firma und Expertise in dem abgefragten Themengebiet durch kategorisierte Auswahlmöglichkeiten erfragt (z.B. Alter: 30-39 Jahre, 40-49 Jahre etc.).

Da zur Anwendung des alten Systems spezielles Wissen erforderlich ist, wird dieses in Form von einfachen Auswahlfragen abgefragt, um einzuschätzen, wie gut die Nutzer das System kennen.

Im Anschluss werden die Fragen und Aufgaben gestellt. Sieben Personen haben zuerst die Aufgaben mit dem alten System bearbeitet und vier Personen zuerst mit dem Neuen. Es werden für beide Systeme folgende Schritte bearbeitet:

- Das aktuelle System wird kurz vorgestellt und die Links für die jeweilige System-Anzeige zur Verfügung gestellt. Diese mussten separat geöffnet werden.
- Es werden 4 Aufgaben, jeweils auf einer einzelnen Folie gestellt (6 inkl. Teilaufgaben, s. Unterabschnitt 6.2.2).
- Im Anschluss wird der gesamte Fragenkatalog aufgelistet. Hierfür wird zuvor auf einer Extra-Folie die Bewertungsskala erklärt. Jede Frage hat einen Schieberegler auf einer 7-Punkte-Skala.
- Nach Beendigung wird zum anderen System gewechselt und erneut erklärt, dass es sich um die selben Fragen, jedoch mit anderen Ergebnissen handelt.

Nach beiden Durchläufen wird eine Bewertung auf einer 5-Punkte-Skala abgegeben, ob die Testperson sich vorstellen kann, die neue Oberfläche in Zukunft zu nutzen.

Zum Schluss gibt es die Möglichkeit für Feedback, Anmerkungen, Anregungen und Diskussionen.

6.7 HYPOTHESENTEST ANHAND DER ERHOBENEN ERGEBNISSE

In dieser Sektion werden die aufgestellten Hypothesen (s. Abschnitt 6.1) ausgewertet und die dafür relevanten Ergebnisse aufgelistet. Der verwendete Signifikanztest zur Akzeptanz bzw. Ablehnung einer Nullhypothese wird im nachfolgenden Unterabschnitt 6.7.1 vorgestellt und anhand eines Beispiels erklärt.

Alle vollständigen Ergebnisse der Nutzerbefragung sind im Anhang C und die Ergebnisse des Usability-Tests im Anhang D zu finden.

6.7.1 *Vorgehen zur Bestimmung der Signifikanz der Ergebnisse zur Hypothesenauswertung*

Mithilfe der Ergebnisse aus dem Usability-Test und der Befragung kann auf verschiedenen Ebenen dargestellt werden, welches System besser ist. Dieses ist jedoch nicht ausreichend, um die Nullhypothese eindeutig zu widerlegen. Mithilfe von Signifikanztests, wie dem t-Test, lässt sich eine Aussage treffen, wie wahrscheinlich es ist, dass das Ergebnis zufällig entstanden ist. [SR18, S. 401]

Der t-Test überprüft den Mittelwertunterschied zwischen 2 Stichproben. Dabei wird zwischen dem t-Test für unabhängige Stichproben, wie beispielsweise der Vergleich von zwei Stichproben aus verschiedenen Populationen, sowie dem t-Test für abhängige Stichproben, wie beispielsweise der Vergleich der selben Nutzergruppe zu zwei verschiedenen Zeitpunkten, unterschieden [BD06, S. 743]. Beim abhängigen t-Test werden die Differenzen der Wertepaare gebildet. Die eigentliche Rechnung entspricht dabei einem t-Test mit nur einer Stichprobe. [SR18, S. 414]

Die erhaltenen p-Werte sind dabei keine Indikatoren für die Größe des Effekts. Auch erlauben sie keine Abschätzung der Wahrscheinlichkeit, dass die Null- bzw. Alternativhypothese zutrifft. „Ein p-Wert ist die bedingte Wahrscheinlichkeit für ein Ergebnis (und alle noch extremeren Ergebnisse), unter der Bedingung, dass die Nullhypothese zutrifft.“ [SR18, S. 401] Das Signifikanzniveau α für den p-Wert ist eine vorgegebene kleine Irrtumswahrscheinlichkeit und beträgt in der Literatur gängigerweise 5%. Liegt das Ergebnis des t-Tests darunter, so lässt sich schlussfolgern, dass die beobachtete Abweichung von der Nullhypothese kein Zufall mehr sein kann. Die Gültigkeit der Nullhypothese ist sehr unwahrscheinlich, wodurch das Ergebnis statistisch signifikant wird. Damit kann sich gegen die Nullhypothese und für die Alternativhypothese entschieden werden. [SR18, S. 400 ff.]

Nachfolgend wird mit dem Unterschreiten des Signifikanzniveaus α die Ablehnung der Nullhypothese sowie die Akzeptanz der Alternativhypothese impliziert.

Das Ergebnis kann dabei positiv und negativ von der Nullhypothese abweichen. Bei begründeter Annahme einer Abweichung in eine Richtung kann einseitig getestet werden. Liegt diese nicht vor, muss zweiseitig getestet werden. Bei dem zweiseitigen Vorgehen wird α gleichermaßen auf beide

Seiten aufgeteilt. Da das Signifikanzniveau bei beiden Verfahren 5% beträgt, halbiert es sich dadurch je Richtung (s. Abbildung 6.1), wodurch es schwieriger ist, ein signifikantes Ergebnis zu erlangen. [SR18, S. 398 f.]

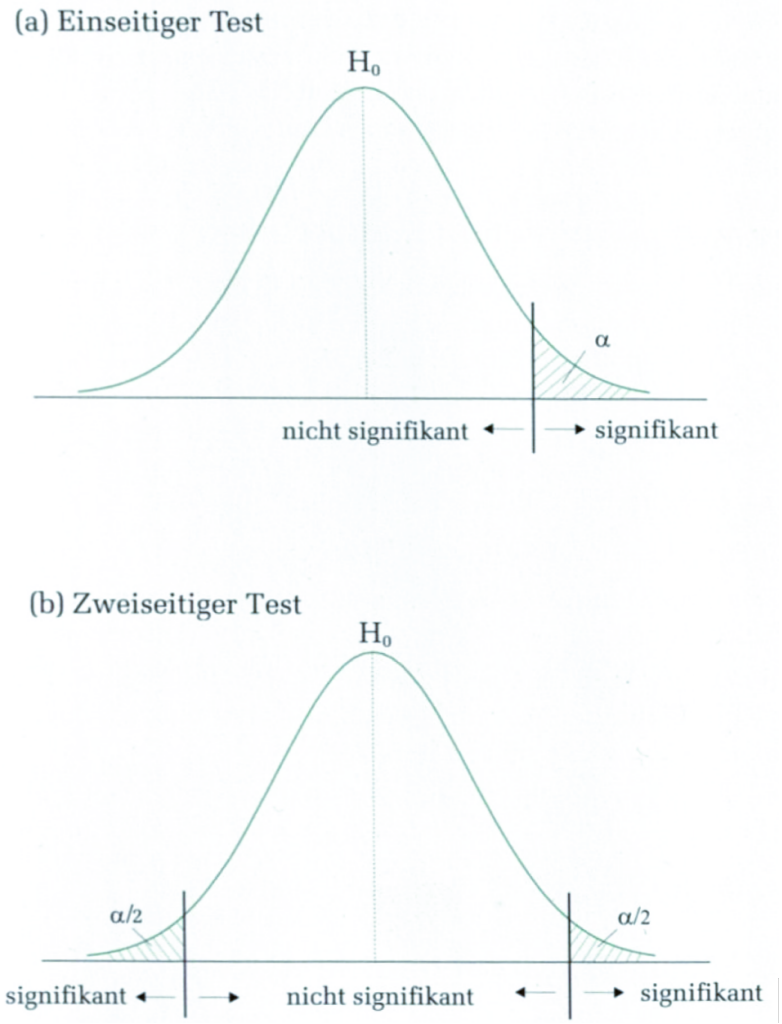


Abbildung 6.1: Signifikanzniveau beim einseitigen und zweiseitigen t-Test [SR18, S. 399]

Das nachfolgende Beispiel nutzt die Daten der ersten Frage der Nutzerbefragung (s. Unterabschnitt 6.7.5). Je höher die Antwort ausfällt, desto besser wurde das System bewertet.

System	Antworten der Nutzer (Frage 1)										
alt	2	2	1	-1	1	-2	2	-3	-2	-1	-1
neu	0	3	1	2	2	1	3	3	3	1	-2
Differenz x	-2	1	0	3	1	3	1	6	5	2	-1

Tabelle 6.2: Antworten aus Frage 1 der Nutzerbefragung (Daten aus Tabelle C.1)

Da die Signifikanz der Abweichung ermittelt werden soll, werden die Datensätze (s. Tabelle 6.2) mit einer Differenz von Null rausgefiltert. Es wurden folgende Hypothesen in Bezug auf die Bewertung (b) der beiden Systeme (μ) aufgestellt:

$H_0 :=$ Das neue System wird nicht besser bewertet als das alte System; $b(\mu_{alt}) \geq b(\mu_{neu})$

$H_1 :=$ Das neue System wird besser bewertet als das alte System; $b(\mu_{alt}) < b(\mu_{neu})$

Hierfür wird ein einseitiger, gepaarter t-Test durchgeführt [Zusammenfassung nach Mat25; SR18, S. 414] Die Voraussetzungen dafür sind zwei abhängige Stichproben in Form von Wertepaaren, metrische Daten und eine Normalverteilung der Differenzen. Diese wurde mithilfe des Online-Rechners von StatistikGuru[3] überprüft.

Anzahl der Fälle: $n = 10$

Freiheitsgrade: $d_f = n - 1 = \underline{9}$

Mittelwert: $\bar{x} = \frac{\sum x_{diff}}{n} = \underline{\underline{1,9}}$

Standardabweichung:

$$
\begin{aligned}
s &= \sqrt{\frac{\sum_{x=0}^{n} (x_n - \bar{x})^2}{n-1}} \\
&= \sqrt{\frac{(-2-1,9)^2 + (1-1,9)^2 + (3-1,9)^2 + (1-1,9)^2 + (3-1,9)^2 \\ \quad + (1-1,9)^2 + (6-1,9)^2 + (5-1,9)^2 + (2-1,9)^2 + (-1-1,9)^2}{10-1}} \\
&= \sqrt{\frac{(-3,9)^2 + (-0,9)^2 + 1,1^2 + (-0,9)^2 + 1,1^2 \\ \quad + (-0,9)^2 + 4,1^2 + 3,1^2 + 0,1^2 + (-2,9)^2}{10-1}} \\
&= \sqrt{\frac{15,21 + 0,81 + 1,21 + 0,81 + 1,21 \\ \quad + 0,81 + 16,81 + 9,61 + 0,01 + 8,41}{9}} \\
&= \sqrt{\frac{54,9}{3}} = \sqrt{6,1} \approx \underline{\underline{2,4698}}
\end{aligned}
$$

Standardfehler des Mittelwerts:

$$s_e = \frac{s}{\sqrt{n}} = \frac{2,4698}{\sqrt{10}} \approx \underline{\underline{0,7810}}$$

Teststatistik:

$$t = \frac{\bar{x} - 0}{s_e} = \frac{\bar{x}}{s_e} = \frac{1,9}{0,781} \approx \underline{\underline{2,432778}}$$

3 Wanja A. Hemmerich. StatistikGuru. Normalverteilung online prüfen. 2018. URL: https://statistikguru.de/rechner/normalverteilung-rechner.html (besucht am 14.06.2025).

Je größer der absolute t-Wert ist, umso kleiner ist der p-Wert und umso stärker ist der Beleg gegen die Nullhypothese. Mit einem Freiheitsgrad von 9 und dem einseitigen Signifikanzniveau α von 0,05, welches einem Flächenanteil von $1 - \alpha = 95\%$ oder 0,95 entspricht, kann aus der Tabelle der t-Verteilung der kritische t-Wert 1,833 abgelesen werden. [SR18, S. 1042 f.; BS10, S. 600 ff.]

$$t > t_{krit.}$$

$$2{,}4327 > 1{,}833$$

Mit dem t-Wert von 2,4327 liegt der Alpha-Wert zwischen 0,025 und 0,01.

$$0{,}01 < p < 0{,}025$$

Damit ist dieser geringer als das Signifikanzniveau, wodurch die Nullhypothese eindeutig verworfen werden kann.

$$p < 0{,}05$$

Der t-Test kann ebenso mithilfe von Microsoft Excel durchgeführt werden. Mit der Formel

$$= TTEST(Matrix_{alt}, Matrix_{neu}, 1, 1)$$

für einen einseitigen, gepaarten t-Test, wurde folgendes Ergebnis erzielt:

$$p \approx 0{,}019471718 \approx \underline{\underline{0{,}0195}}$$

Dieses fügt sich in das vorherige Ergebnis ein.

$$0{,}01 < 0{,}0195 < 0{,}025$$

Alle weiteren t-Test Ergebnisse wurden über diesen Weg erreicht und sind in Tabelle D.3 für den Zeitvergleich des Usability-Tests, in Tabelle D.4 für die Fehlerquotenvergleich des Usability-Tests und in Tabelle 6.8 für den Vergleich der Ergebnisse der Nutzerbefragung aufgeführt.

Die aufgeführten Daten, wie beispielweise in Tabelle 6.2, werden nachfolgend in Box-Plots dargestellt. Ein *Box-Plot* ist ein Diagramm, welches Lage- und Streuungsmaße abbildet (s. Abbildung 6.2) und ist wie folgt zu interpretieren [Zusammenfassung nach SR18, S. 194 ff.]). Die Daten werden von einem Querstrich innerhalb der Box halbiert, welcher den *Median* darstellt, sowie einem gleichfarbigen Diamanten, welcher den *Mittelwert* darstellt. Die *Box* umfasst die mittleren 50% der nach Rangfolge geordneten Daten. Das bedeutet, dass die Daten von der 25. bis 75. Perzentile oder auch vom 1. bis 3. *Quartil* (Q1, Q3) dargestellt sind. Der Bereich dazwischen wird auch *Interquartilsabstand* (en. interquartile range - IQR) genannt.

Außerhalb der Box stehen die *Whiskers* (dt. Schnurrhaare). Die Länge der Whiskers ist durch den *Zaun*, den Querstrich am Ende der Whiskers, be-

grenzt. Dieser befindet sich maximal 1,5 Interquartilsabstände von der Box entfernt. Liegt der äußerste Wert des Bereichs innerhalb des Zauns, wird der Whisker kürzer bis zu diesem äußersten Wert dargestellt.

Die Punkte außerhalb der Whiskers sind die *Ausreißer* und werden hier als Punkte dargestellt. Ausreißer, die außerhalb von drei IQR von der Box liegen, werden als extreme Ausreißer bezeichnet. Liegen sie zwischen dem Zaun und drei IQR, sind es normale Ausreißer.

Nachfolgend ist ein Beipiel zur Erstellung von Box-Plot-Diagrammen gezeigt (s. Tabelle 6.3, Abbildung 6.2). *Frage 1* dient als Weiterverarbeitung des Datensatzes, der zuvor für die t-Test-Berechnung genutzte wurde. *Frage 4* veranschaulicht zusätzlich die Darstellung von Ausreißern.

	Frage 1 - neues System -	**Frage 4** - neues System -
Q1	1	1
Q3	3	2
Median $\tilde{x}$	2	2
∅	1,545455	1,454545
IQR = Q3 - Q1	= 3 - 1 = **2**	= 2 - 1 = **1**
Whisker unten = Q1 - 1,5 * IQR	= 1 - 1.5*2 = **-2**	= 1 - 1.5*1 = **-0.5** ⇒ 0
Whisker oben = Q3 + 1,5 * IQR	= 3 + 1,5*2 = **6** ⇒ 3	= 2 + 1.5*1 = **3.5** ⇒ 3
Ausreißer	[∅]	**[-2]**

Tabelle 6.3: Beispiele zur Erstellung von Box-Plots (Daten aus Tabelle C.1)

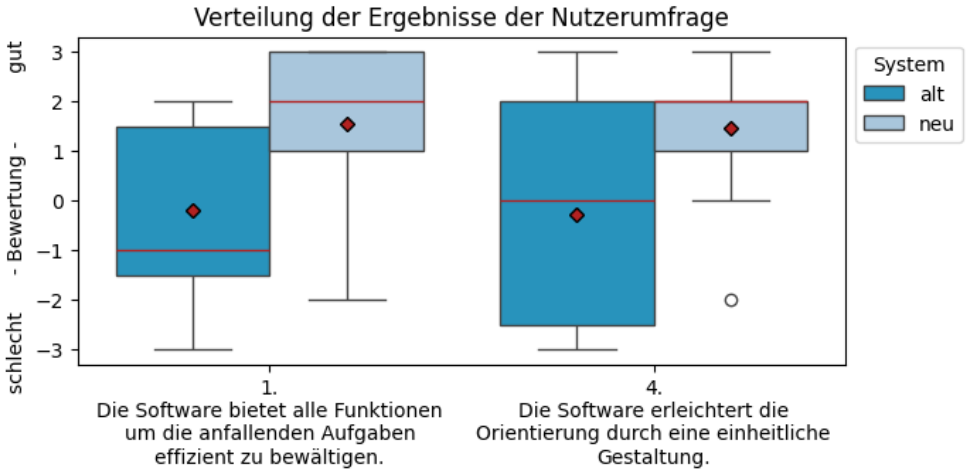


Abbildung 6.2: Beipiel Box-Plot: Vergleich der Ergebnisse aus der Nutzerbefragung Frage 1 und 4 (Daten aus Tabelle C.1)

6.7.2 *Auswertung der Effektivität (H_1)*

Ist ein System effektiv, ermöglicht es dem Nutzer, seine Ziele vollständig und fehlerfrei zu erreichen (s. Unterabschnitt 2.2.1). Neben der Vollständigkeit der funktionellen Anforderungen (s. Abschnitt 5.6) gilt es zu bestimmen, ob die Nutzung des neuen Systems weniger fehleranfällig ist als die Nutzung des alten Systems. Folgende Hypothese ist zu bestätigen:

> H_1 = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Fehlerquote (f) der Anworten der gestellten Aufgaben positiv im Vergleich zur Nutzung des alten Systems ($\mu 1$);
> $f(\mu 1) > f(\mu 2)$.

Auswertung der objektiven Daten des Usability-Tests

Anhand des durchgeführten Usability-Tests wurden die Antworten der Nutzer ausgewertet. In Abbildung 6.3 sind die Fehlerquoten pro Aufgabe dargestellt. Zu erkennen ist, dass das alte System bei zwei Drittel der Aufgaben keine Fehler verursachte. Auch der Durchschnitt des alten Systems beträgt ungefähr die Hälfte der durchschnittlichen Fehlerquote des neuen Systems. Das Dashboard hat bei jeder Aufgabe Fehler vorzuweisen, kann jedoch bei einem Drittel der Aufgaben eine geringere Fehlerquote vorzeigen als im alten System.

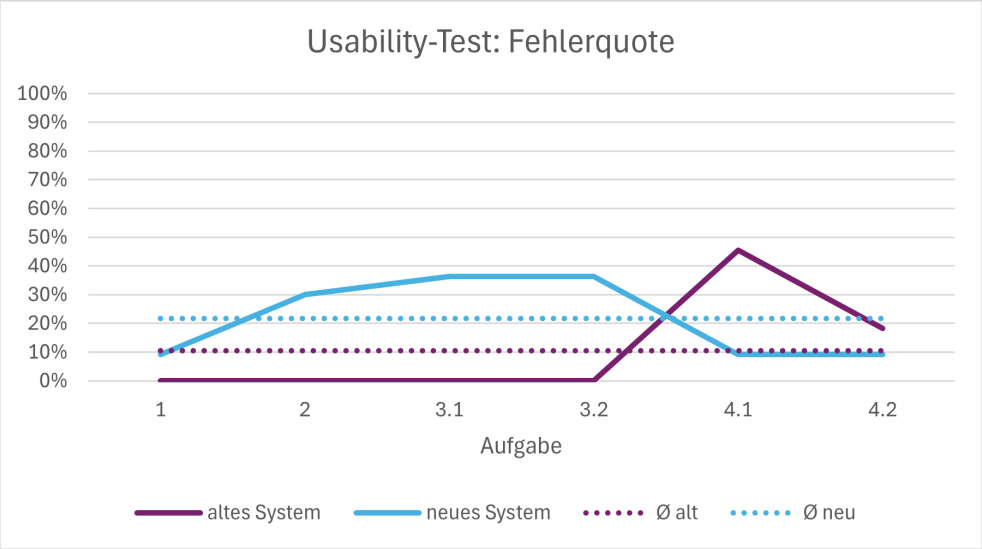


Abbildung 6.3: Usability-Test: Fehlerquoten der Nutzer (Daten aus Tabelle D.2)

Da die mittlere Fehlerquote unter Nutzung des neuen Systems leicht erhöht ist als die unter Nutzung des alten Systems, reicht es nicht aus, die Hypothese H_{01} anhand der Fehlerquote abzulehnen. Dies bedeutet jedoch nicht, dass das alte System besser ist, da der Unterschied nicht signifikant ist.

Ein Grund, wie die Quote entstanden ist, welcher auch von den Testpersonen genannt wurde (s. Anhang E), ist, dass das Dashboard anders aufgebaut

ist als das alte System. Wie in Abschnitt 5.5 erwähnt, wurden die Zeilen und Spalten der Kategorien und Inhalte getauscht, was dem Prinzip der Erwartungskonformität widerspricht [Dina]. Diese Formatierung wurde aufgrund der Kombination vieler Informationsquellen auf eine Seite bewusst gewählt, um die Daten einer Reihe direkt von den anderen Reihen unterscheiden zu können. Dies ist aufgrund der gestaffelten farblichen Gestaltung je Spalte möglich (s. Abbildung 5.2). Aus diesem Grund kann lediglich erneut probiert werden, ob eine zum alten System äquivalente Darstellung sinnvoll möglich ist, indem die Reihen beispielsweise durch eine Umrandung oder einen dezenten Hintergrund eindeutig voneinander unterschieden werden.

Eine Ungenauigkeit in den Aufgaben 3.1, 3.2, 4.1 und 4.2 hat dazu geführt, dass jeweils zwei Antworten im alten System als *richtig* akzeptiert werden mussten. Während das Ziel auf dem Dashboard eindeutig identifizierbar abgelesen werden kann, ist in Aufgabe 4.1 und 4.2 der Begriff 'noch nicht gelaufen' im alten System verwechselt worden mit der Fehleranzeige, dass der Test fehlerhaft war. In den Aufgaben 3.1 und 3.2 wurde das Gesamtergebnis einer Testkategorie gemeint, welches zusammenzuzählen war. Jedoch hat einer der Testfälle den gleichen Namen wie dessen Kategorie.

Dass das alte System in vier von sechs Fragen keine Fehler erzeugt hat, lässt sich damit erklären, dass die meisten Nutzer dieses System regelmäßig seit über 30 Jahren nutzen. Zum Lernerfolg wird die Wiederholung einer Tätigkeit benötigt (s. Unterabschnitt 2.2.6). Bei dem neuen System gab es hingegen keine Vorerfahrungen. Das System war für alle Beteiligten neu, zumal sich nur eine Person die neue Umgebung angesehen hat, bevor die Aufgaben begonnen wurden (s. Abschnitt 6.5).

Der Anstieg der Fehlerquote im alten System bei Aufgabe 4 zeigt auf, dass dort Werte für das Ergebnis zusammengezählt werden mussten, während die geforderte Antwort vom Dashboard lediglich abzulesen war. Es wurde sich im alten System häufiger verzählt oder verrechnet. Zusätzlich wurden Aussagen getroffen, dass einzelne Personen mit diesem System, jedoch nicht in diesem Kontext arbeiten, wodurch deren Wissen darüber eingeschränkt sei (s. Anhang E).

Dies trägt auch zur nachträglichen Einschätzung bei, dass die Aufgaben 3 und 4 wenig Relevanz für den Alltag haben. Die Aufgaben 3.1 und 3.2 befassen sich mit der Release-Version, welche kein Teil des Alltagsgeschäft ist. Die Aufgaben 4.1 und 4.2 handeln von einer Zählaufgabe im alten System, wobei im Alltag eher wichtig ist, ob es noch Tests gibt, die fehlerhaft sind. Die Anzahl der Fehler ist hierbei irrelevant.

Wird das Feedback der Versuchspersonen berücksichtigt, sodass die Aufgaben aufgrund der Alltagsrelevanz auf die Aufgaben 1 und 2 reduziert werden, dann zeigt sich folgendes Bild (s. Abbildung 6.4). Es ist eine eindeutige Tendenz erkennbar, dass das alte System besser ist als das neue, jedoch ist der Unterschied nicht signifikant.

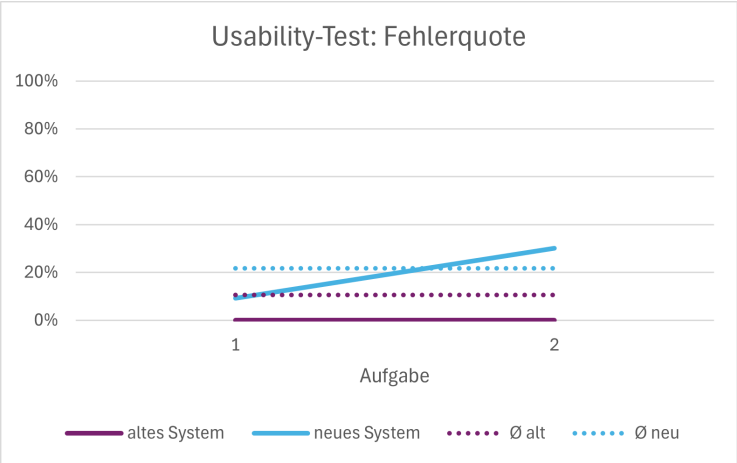


Abbildung 6.4: Usability-Test: Fehlerquoten der Nutzer (Ausschnitt aus Abbildung 6.3)

Auswertung der subjektiven Daten der Nutzerbefragung

Zusätzlich zu den objektiven Daten haben die Nutzer die Effektivität der Systeme in Form der ISO-Prinzipien Aufgabenangemessenheit und Steuerbarkeit (s. Unterabschnitt 6.2.1) bewertet.

In Bezug auf die Aufgabenangemessenheit bewerteten die Nutzer das neue System im Schnitt besser als das alte System (s. Abbildung 6.5). Dabei zeigt der t-Test ein signifikantes Ergebnis bei den Fragen 1 und 8 (s. Unterabschnitt 6.7.5).

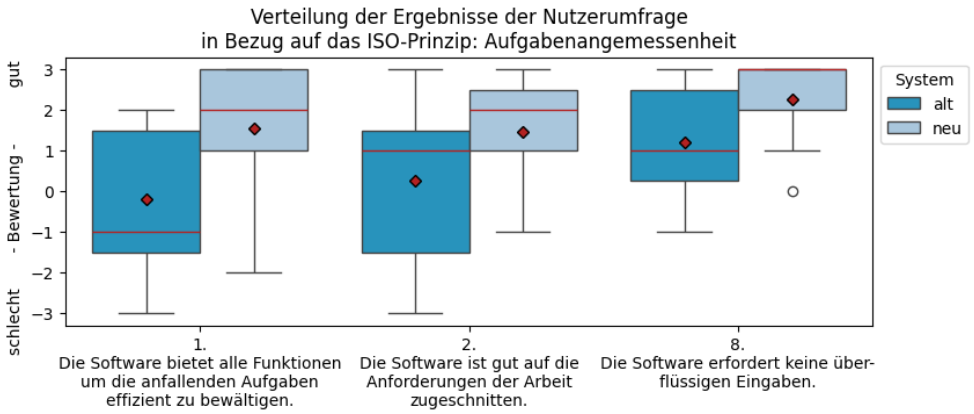


Abbildung 6.5: Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Aufgabenangemessenheit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14)

Auch die Steuerbarkeit wurde beim neuen System im Schnitt besser bewertet (s. Abbildung 6.6). Der Unterschied ist jedoch statistisch nicht signifikant (s. Unterabschnitt 6.7.5).
Da die Nutzer das Dashboard in Bezug auf die ISO-Kriterien Aufgabenangemessenheit und Steuerbarkeit aus der Nutzerumfrage nicht signifikant bes-

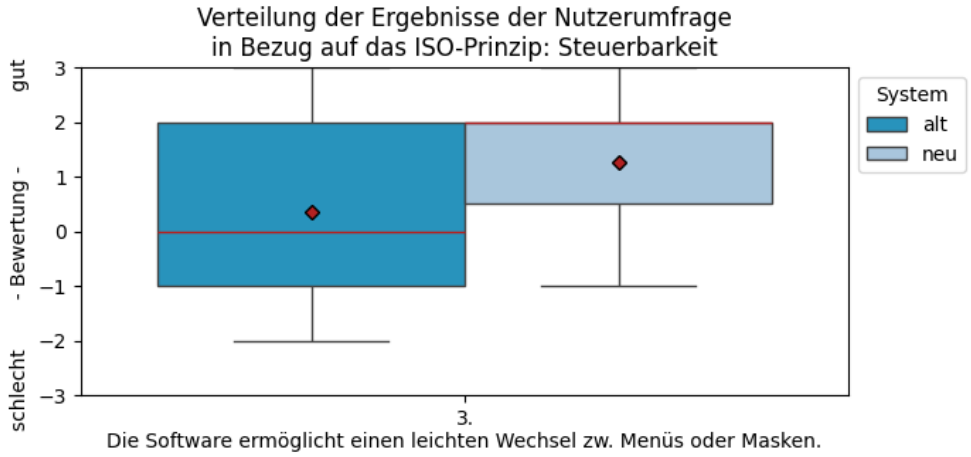


Abbildung 6.6: Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Steuerbarkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14)

ser bewerten, kann die Hypothese H_{01} auf dieser Grundlage zunächst nicht verworfen werden.

Allerdings sind während der Auswertung jeweils zwei Ausreißer in den Daten aufgefallen (s. Tabelle C.1). Bei den Fragen 2 und 3 haben zwei Personen entgegen allen weiteren Teilnehmern invertiert geantwortet. Sie sind die einzigen beiden, die das Dashboard negativ und das alte System positiv bewerten. Die beiden Testpersonen fallen nachfolgend auch in weiteren Bereichen auf.

Da der Verdacht auf einen Fehler zweiter Art, dem Beibehalten der Nullhypothese trotz Widersprüchen, besteht, wurden aus diesem Grund die beiden Signifikanztests noch einmal ohne diese Werte vorgenommen (s. Abschnitt C.6). Dadurch ist auch bei diesen Fragen ein signifikanter Unterschied zugunsten des Dashboards festzustellen.

Diese Auffälligkeit ist auch in weiteren Datensätzen teilweise mit extremeren Bewertungsdifferenzen zu beobachten (s. Abbildung C.2), hat allerdings den p-Wert unter Ausschluss der Datensätze lediglich verringert (s. Tabelle C.3) und liegt somit weiterhin unterhalb des Signifikanzniveaus.

Werden die beiden Ausreißer aus der Betrachtung entfernt, so zeigen die subjektiven Daten eine signifikante Verbesserung des Monitoring-Prozesses unter Nutzung des Dashboards im Vergleich zum alten System. Die Hypothese H_{11} kann somit in Kombination mit den weiteren Fragen der beiden Prinzipien auf Grundlage der subjektiven Ergebnisse bestätigt werden.

Zusammenfassend zeigen die Daten, dass die Teilnehmer das Dashboard gut nutzen können. Die eigenen Fehler oder Slips (s. Unterabschnitt 2.2.6) sind ihnen dabei nicht aufgefallen.

Während die Nutzerzufriedenheit durch Einsatz des neuen Dashboards verbessert werden konnte, besteht dennoch die Tendenz, mit dem Dashboard mehr Fehler zu machen. Diese ist jedoch auf den langen Lernprozess mit dem alten System sowie den nicht existenten Lernprozess mit dem neuen System zurückzuführen (s. Unterabschnitt 2.2.6).

6.7.3 *Auswertung der Effizienz (H_2)*

Ein System ist effizient, wenn ein Nutzer dieses schnell und ohne großen Aufwand bedienen kann. Die Bewertung dessen umfasst die nötige Zeit, die Anzahl der Schritte und die benötigte kognitive Belastung zum Erreichen eines Ziels (s. Unterabschnitt 2.2.1). Folgende Hypothese ist zu bestätigen:

> H_2 = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Effizienz (e) der gestellten Aufgaben positiv im Vergleich zur Nutzung des alten Systems ($\mu 1$);
> $e(\mu 1) > e(\mu 2)$.

Auswertung der objektiven Daten des Usability-Tests

Auf dem neuen Dashboard konnten alle Ergebnisse auf einer Oberfläche dargestellt werden. Weiterhin ist durch die Farbgestaltung eine parallele Suche nach potenziellen Fehlern möglich (s. Unterabschnitt 2.2.6).

Neben dieser Verringerung der Arbeitsschritte (s. Abschnitt 5.6) und der Fehlerquote (s. Abbildung 6.3) wird zur Effizienzbewertung die Bearbeitungszeit zur Beantwortung der Fragen benötigt.

Die Zeitmittelwerte beider Systeme sind vergleichend in Abbildung 6.7 dargestellt. Es ist erkennbar, dass die Bearbeitung der Aufgaben mit dem Dashboard schneller erfolgte, da die Nutzer rund 64% der Zeit des alten System benötigten. Der t-Test bestätigt einen statistisch signifikanten Unterschied (s. Tabelle 6.4).

System	alt	neu	Unterschied $\frac{alt}{neu}$	t-Test
∅ Bearbeitungsdauer in s	14,74	9,45	0,640735793	0,000174702

Tabelle 6.4: Usability-Test: Vergleich der mittleren Bearbeitungsdauer (Weiterverarbeitung der Daten aus Tabelle D.2)

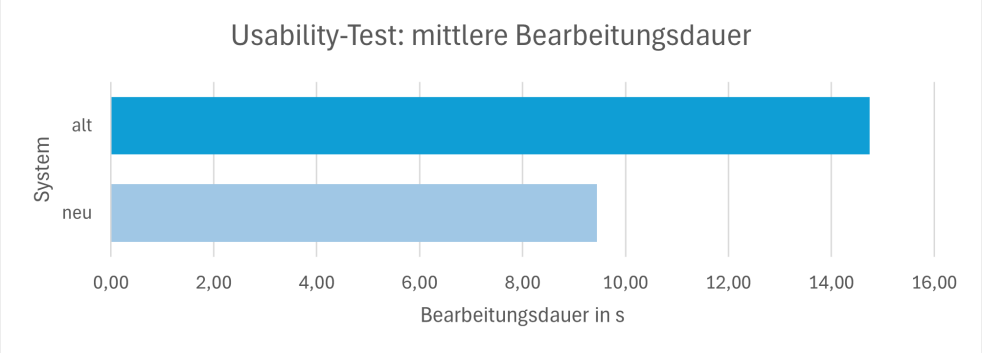


Abbildung 6.7: Usability-Test: Vergleich der mittleren Bearbeitungsdauer (Daten aus Tabelle 6.4)

In Abbildung 6.8 wird gezeigt, dass die Bearbeitungsdauer mit dem Dashboard bei jeder Aufgabe wie erwartet ersichtlich schneller war. Zusätzlich

zeigt sich anhand der Aufgaben 3 und 4, dass der Kontextwechsel zwischen mehreren Oberflächen mit dem Dashboard besser gelingt, obwohl das Dashboard insgesamt eine höhere Fehlerquote aufweist. Wie bereits im vorherigen Kaptitel erwähnt, ist diese jedoch daran zu erklären, dass die Nutzer mit dem alten System über mehrere Jahrzehnte eine Routine entwickelt haben (s. Anhang E), wobei das Dashboard für alle Beteiligten neu war.

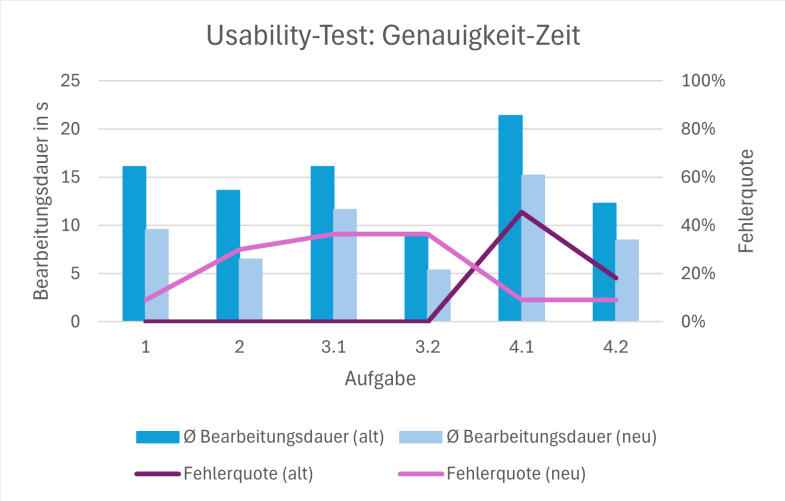


Abbildung 6.8: Usability-Test: Zeitvergleich von beiden Systemen - im Verhältnis zur Fehlerquote (Daten aus Tabelle D.2)

Das Dashboard orientiert sich an dem *proximity compatibility principle* [Wic+13; WC95], welches besagt, dass zusammengehörige Informationen beisammen darzustellen sind (s. Unterabschnitt 2.2.6). Die Anzahl der benötigten Schritte zur Erfüllung der Monitoring-Aufgabe wurde mithilfe des Dashboards minimiert, da die Anzeige von vielen Ergebnissen auf eine Oberfläche reduziert wurde (s. Abschnitt 5.6). Zusätzlich zu der verteilten Struktur des alten System können dessen Oberflächen unterschiedlich aufgebaut sein. Mit der kürzeren Bearbeitungsdauer zeigt sich, dass das sich Zurechtfinden auf einer Oberfläche wie dem Dashboard leichter scheint als auf mehreren wie beim alten System.

In Abbildung 6.9 ist zu erkennen, dass im alten System die Personen mit Fehlern langsamer waren als die ohne. Im neuen System ist das umgekehrt. Dies lässt sich daran erklären, dass die Personen, die das alte System nicht so gut kannten, länger für die Aufgaben benötigten und tendenziell auch mehr Fehler verursachten. In Aufgabe 4.1 und 4.2 werden im alten System mit einer längeren Bearbeitungsdauer mehr Fehler gemacht. Für diese Aufgabenstellung, alle erfragten Werte zusammen zu suchen, ist das alte System nicht so intuitiv wie das neue. Obwohl jahrelange Erfahrung vorliegt, ist es dennoch schwierig, sich zu merken, welche Information wo zu finden ist, zumal das alte System viele Abkürzungen vorweist. Da jedoch niemand das neue Dashboard kannte, lässt sich anhand der vorliegenden Daten schlussfolgern, dass die Anzeige etwas genauer untersucht wurde, bevor die Person zum Ergebnis gelang.

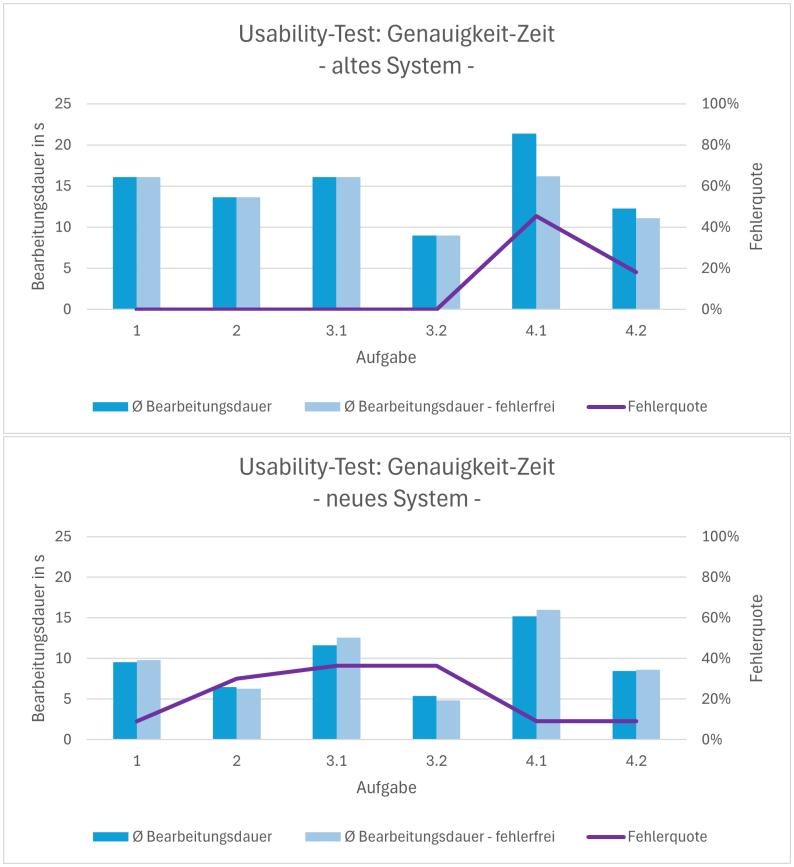


Abbildung 6.9: Usability-Test: Vergleich Genauigkeit-Zeit im alten und neuen System (Daten aus Tabelle D.2)

In Abbildung 6.10 sind die Vergleiche der mittleren Zeit und der Fehlerquote beider Systeme dargestellt. Während das neue System eine schnellere Bearbeitung der Aufgaben ermöglicht, wurden mit dem alten System weniger Fehler bei der Bearbeitung gemacht.

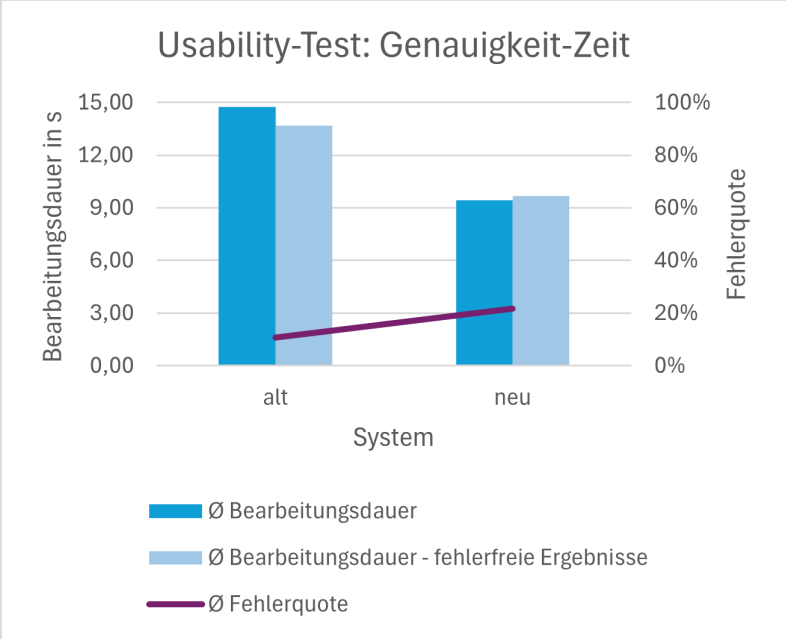


Abbildung 6.10: Usability-Test: Vergleich der mittleren Bearbeitungsdauer im Verhältnis zur Fehlerquote (Daten aus Abbildung 6.3 und Abbildung 6.7)

Um trotz der gegensätzlichen Tendenz eine eindeutige Aussage treffen zu können, werden diese beiden Variablen zu einer Effizienzbewertung verrechnet. Dieses Effizienzmaß kann allerdings nicht als allgemeine Bewertung angesehen werden. Es dient lediglich als Vergleichsmaß der Werte einer Aufgabe.

$f_{alt} = \frac{n_{gültige} - n_{richtige}}{n_{gültige}}$	// Fehlerquote
$e_{alt} = \frac{\overline{t_{alt}}}{1 - f_{alt}}$	// Effizienz$_{alt}$ = mittlere Zeit / Richtigquote
$e_{neu:alt} = -1 * (1 - \frac{e_{alt}}{e_{neu}})$	// Verhältnis: Effizienz$_{neu}$ zu Effizienz$_{alt}$

Tabelle 6.5: Formel zur Effizienzberechnung

Mithilfe der Formel zur Effizienzberechnung wurden die Ergebnisse in Abbildung 6.11 erschlossen. Es zeigt das Verhältnis der Effizienz des neuen Systems zum alten System ($e_{neu} : e_{alt}$) und ist wie folgt zu interpretieren:

⇒ Aufgabe 1:	Das neue System ist anhand von Aufgabe 1 zu 53,25% effizienter als das alte System.
⇒ Aufgabe 3.1:	Das neue System ist anhand von Aufgabe 3.1 zu 11,95% ineffizienter als das alte System.
⇒ ∅:	Das neue System ist im Mittel zu 48,46% effizienter als das alte System.

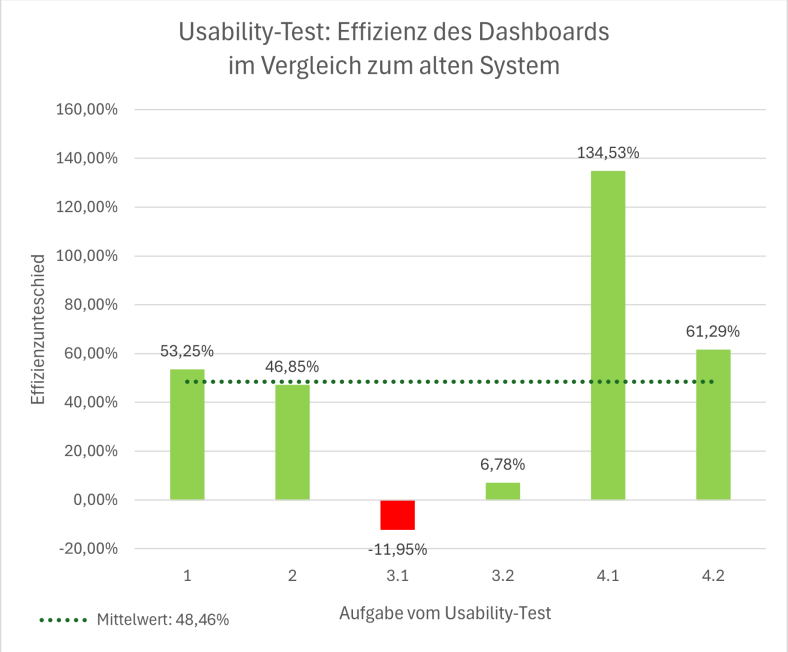


Abbildung 6.11: Usability-Test: Effizienzvergleich vom neuen mit dem alten System (Daten aus Tabelle D.5)

Die mittlere Effizienz des neuen Systems ist 48,48% besser als die des alten Systems. Diese Effizienzverbesserung ist statistisch signifikant. Da jedoch der Unterschied der Effizienzbewertungen zwischen beiden System nicht signifikant ist, kann die Hypothese H_{02} anhand dieser Effizienzbewertung nicht abgelehnt werden. Allerdings fällt auf, dass die Effizienzwerte stark schwanken, wodurch das Ergebnis detaillierter auszuwerten ist.

Der einzige negative Wert tritt bei Aufgabe 3.1 auf. Diese hat im alten System zwar eine durchschnittliche Zeit und keine Fehler erbracht, allerdings kamen im neuen System die zweithöchsten Werte beider Maße zustande (s. Abbildung 6.9). An zweiter Stelle steht das Ergebnis aus Aufgabe 3.2. Dieses zeigt lediglich einen leicht besseren Wert an, da die Zeitdifferenz kleiner ist als bei Aufgabe 3.1. Aufgabe 4.1 überzeugt mit einem stark positiven Wert. Durch die Umkehrung der Fehlerquote sowie der geringeren Bearbeitungsdauer kann das Dashboard anhand der Zählaufgabe überzeugen. Der Wert von Aufgabe 4.2 ist etwas geringer, da eine geringere Zeit- und Fehlerdifferenz vorliegt, jedoch das grobe Verhältnis zu Aufgabe 4.1 übereinstimmt. Die Aufgaben 1 und 2 spiegeln auch die Ergebnisse von zuvor wieder, da das Dashboard mit starken Zeitwerten und einer leichten Fehlerquote überzeugen kann. Diese Aufgaben können weiterhin einen signifikanten Unterschied der Zeitmittelwerte und der Effizienz feststellen (s. Tabelle 6.6).

Auch wenn der Unterschied der Effizienz zwischen den beiden Systemen nicht signifikant ist und die Hypothese H_{02} somit nicht abgelehnt werden kann, zeigt sich anhand der vorangegangen detaillierten Betrachtung, dass das Dashboard die beschriebenen Vorteile erbringen könnte.

Aufgabe 1 + 2	$\varnothing_{t_alt}$	$\varnothing_{t_neu}$	t-Test über $\varnothing_t$	t-Test über Effizienzwerte
Werte	14,86	8,02	0,0137	0,0395

Tabelle 6.6: Usability-Test: Zeitmittelwerte und Signifikanzauswertung der Aufgaben 1 und 2 (Weiterverarbeitung der Daten aus Tabelle D.1 und Tabelle D.5)

Auswertung der subjektiven Daten der Nutzerbefragung

Zusätzlich zu den objektiven Daten haben die Nutzer die Effizienz der Systeme in Form der ISO-Prinzipien Erlernbarkeit, Selbstbeschreibungsfähigkeit und Aufgabenangemessenheit (s. Unterabschnitt 6.2.1) bewertet.
Die Auswertung des ISO-Prinzips der Aufgabenangemessenheit ist im vorherigen Kapitel in Abbildung 6.5 dargestellt, wobei zwei der drei Fragen einen statistisch signifikanten Unterschied aufweisen (s. Unterabschnitt 6.7.5).

In Bezug auf die Erlernbarkeit bewerteten die Nutzer das neue System im Schnitt besser als das alte System (s. Abbildung 6.12). Dabei zeigt der t-Test einen statistisch signifikanten Unterschied bei allen drei Fragen an (s. Unterabschnitt 6.7.5).

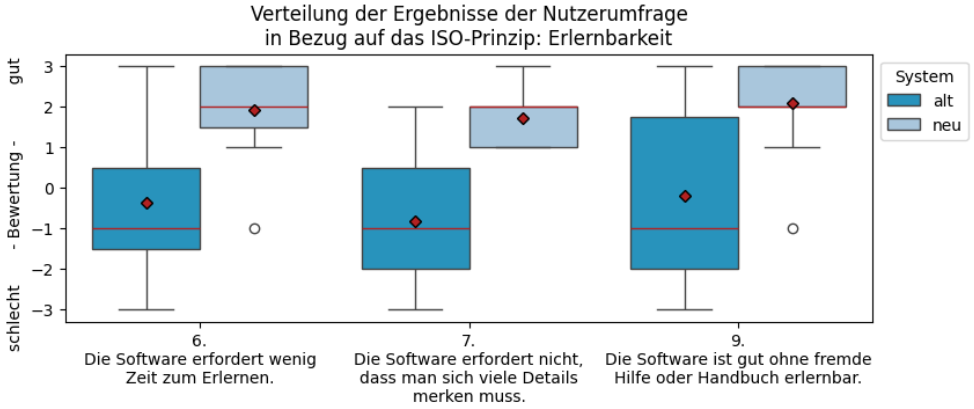


Abbildung 6.12: Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Erlernbarkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14)

Das Prinzip der Selbstbeschreibungsfähigkeit wurde ebenfalls zu Gunsten des neuen Systems bewertet (s. Abbildung 6.13). Der t-Test stellt auch bei Frage 10 einen statistisch signifikanten Unterschied fest (s. Unterabschnitt 6.7.5).

Auf Grundlage der signifikanten Verbesserung der Effizienzbewertung durch die Nutzer anhand der ISO-Kriterien Aufgabenangemessenheit, Erlernbarkeit und Selbstbeschreibungsfähigkeit, kann die Hypothese H_{12} akzeptiert werden.

Die subjektiven und objektiven Daten ergeben nicht das gleiche Ergebnis. Während die Nutzer eine signifikante Verbesserung der Effizienz feststellten, können die Ergebnisse des Usability-Tests dies nicht bestätigen. Der Hauptgrund liegt darin, dass die Nutzer zuvor keinen Zugang zum Dashboard hatten, wodurch sie mehr Fehler in der Benutzung machten, welche

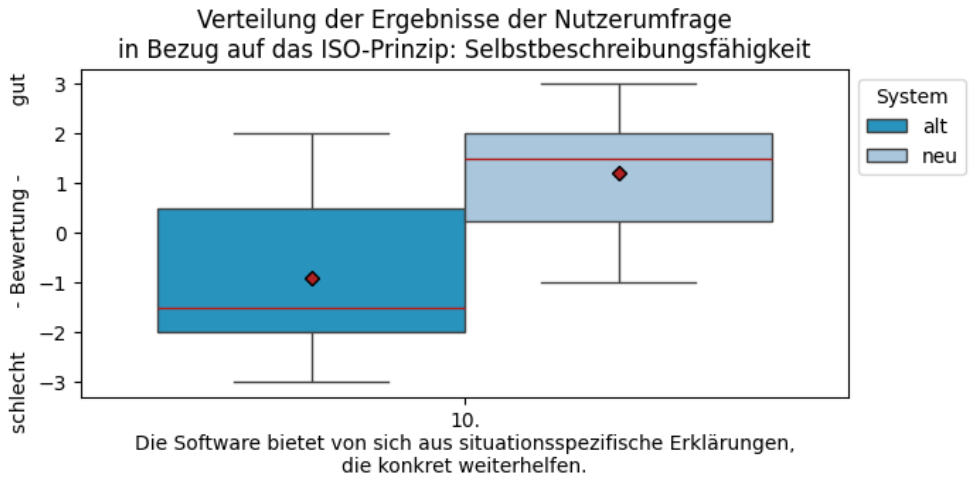


Abbildung 6.13: Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Selbstbeschreibungsfähigkeit nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14)

wiederum die Effizienzbewertung stark beeinflusst. Zusätzlich dazu wurde das alte System überwiegend fehlerfrei verwendet. Mit einer längeren Eingewöhnungszeit sowie regelmäßiger Verwendung ist mit dem neuen System ein ähnliches Ergebnis in der Fehlerquote zu erwarten wie mit dem alten System.

6.7.4 *Bewertung der Intuitivität des Dashboards auf Grundlage der Effizienzbewertung*

Das Dashboard liefert neben der Anzeige der Testergebnisse eine Zusammenfassung von Links, die zu weiteren Informationen führen, weshalb die *Data-Ink-Ratio* (s. Unterabschnitt 2.2.6) auf der Dashboard-Oberfläche sehr niedrig ist. Allerdings liegt keine Vermischung verschiedener Daten vor. Die Ergebnisdaten, welche zentral gelegen und über alle Reihen im gleichen Bereich dargestellt sind, sind gut von den am Rand versammelten Zusatzinformationen unterscheidbar (s. Abschnitt 5.5). Daher kann diese Data-Ink-Wertung vernachlässigt werden. Durch die Farbgestaltung der Werte kann zudem eine Einschätzung des Systemzustands ohne Fokus auf einzelne Werte erfolgen.

Die Daten sind stark vereinfacht dargestellt, da dessen Details über diese Verlinkungen einsehbar sind. Dadurch sind Eigenheiten des Systems, welche Testergebnisse durch vorhandenes Hintergrundwissen potenziell übersehen werden dürfen, nicht so ersichtlich wie zuvor. Stattdessen zeigt die Erstellung des Dashboards solche Probleme auf und regt damit die langfristige Behebung dieser gewachsenen Strukturen an.

Das Dashboard eignet sich durch die doppelte Funktion als Ergebnisanzeige und Dokumentation dazu, neuen Personen einen Überblick über das System zu verschaffen. Statt der Abkürzungen und Fachsprache wurden die

Begriffe auf ein Minimum reduziert. Auch die Verlinkung zeigt primär an, zu welcher Art des Systems weitergeleitet wird, jedoch nicht die genauen Versionsnummern und Maschinennamen. Diese werden für die Bestätigung des Green Days nicht benötigt. Erst im Fehlerfall muss die Detailansicht aufgerufen werden, auf der dann die erforderlichen Informationen zu finden sind. Alle nicht mehr genutzten Oberflächen wurden nicht auf das neue System übertragen, sodass lediglich die aktuell relevanten Inhalte angezeigt werden.

Um Schlüsse auf die Intuitivität des Dashboards zu ziehen, können die Ergebnisse der Aufgaben 4.1 und 4.2 weiterhelfen, welche zuvor für die Hypothesenauswertung als nicht relevant eingestuft wurden. Das System ist den Personen zwar bekannt, jedoch arbeiten sie kaum mit der spezifischen Kategorie (s. Anhang E). Das Dashboard benötigt einen Bruchteil der Zeit und verursacht weniger Fehler. Obwohl der t-Test keine Signifikanz zeigt (s. Tabelle 6.7), ist eine klare Tendenz erkennbar. Die Nutzung des neuen Dashboards ist intuitiver gegenüber dem alten System.

Aufgabe 1 + 2	$\varnothing_{t_alt}$	$\varnothing_{t_neu}$	t-Test über $\varnothing_t$	t-Test über Effizienzwerte
Werte	27,08	13	0,0739	0,1709

Tabelle 6.7: Usability-Test: Zeitmittelwerte und Signifikanzauswertung der Aufgaben 4.1 und 4.2 (Weiterverarbeitung der Daten aus Tabelle D.1, Tabelle D.5)

6.7.5 *Auswertung der Zufriedenheit (H_3)*

Nutzer sind mit einem System zufrieden, wenn sie die Nutzung angenehm und erfreulich finden. Dafür muss es den Erwartungen der Nutzer entsprechen, leicht steuer- und navigierbar sein und eine Bindung zum Nutzer aufbauen. Die Zufriedenheit lässt sich dabei nicht in metrischen Kenngrößen erfassen, stattdessen aber beispielsweise in Form eines Spektrums anhand von Fragebögen (s. Unterabschnitt 2.2.1). Folgende Hypothese ist zu bestätigen:

> H_3 = Die Nutzung des neuen Systems ($\mu 2$) beeinflusst die Bewertung (b) der Software positiv im Vergleich zur Nutzung des alten Systems ($\mu 1$);
> $b(\mu 1) < b(\mu 2)$.

Auf Grundlage der jahrezehntelangen Erfahrung mit dem alten System ist anhand der Befragung festzustellen, dass manche der Nutzer einer Modernisierung ihrer Routine teilweise sehr kritisch gegenüber stehen. Auch wenn das neue System anhand der Bewertung aus dem vorherigen Kapitel sehr intuitiv ist, folgt daraus nicht unbedingt, dass der Nutzer es gut findet. Die Spektren der Antworten der Nutzerumfrage sind in Abbildung 6.14 in Form eines Box-Plots zusammengefasst. Trotz einzelner Ausreißer ist eine klare Tendenz erkennbar, dass das neue System besser bewertet wurde.

Diese grafische Tendenz bestätigt sich durch die Differenzen der Mittelwerte (s. Tabelle 6.8). Das Ergebnis des alten Systems wurde von dem des neues Systems abgezogen. Da die Differenz bei jeder Frage positiv ausfällt, wurde das neue System insgesamt besser bewertet als das alte.

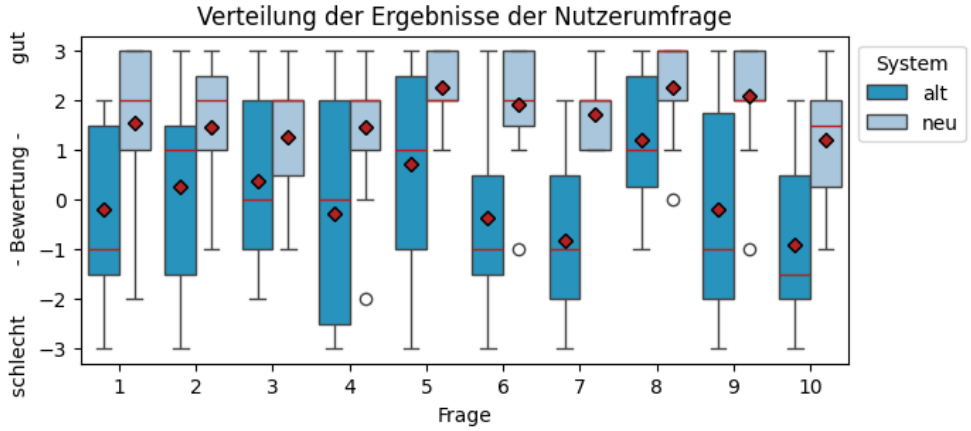


Abbildung 6.14: Antwortverteilung der Nutzerbefragung (Daten aus Tabelle C.1)

Frage	1	2	3	4	5
$\varnothing_{neu} - \varnothing_{alt}$	1,73	1,18	0,91	1,73	1,55
t-Test	0,0195	0,0949	0,1387	0,0487	0,0231
Frage	6	7	8	9	10
$\varnothing_{neu} - \varnothing_{alt}$	2,27	2,55	1,07	2,29	2,1
t-Test	0,0087	0,0021	0,0286	0,021	0,02
t-Test über alle $\varnothing$	0,00000218748				

Tabelle 6.8: Nutzerbefragung - Differenz der Antwortmittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle C.1)

Weiterhin weisen 80% der Fragen anhand der t-Test-Ergebnisse (s. Abbildung 6.15) sowie das Ergebnis des t-Tests über alle durchschnittlichen Werte (s. Tabelle 6.8) einen statistisch signifikanten Unterschied auf.

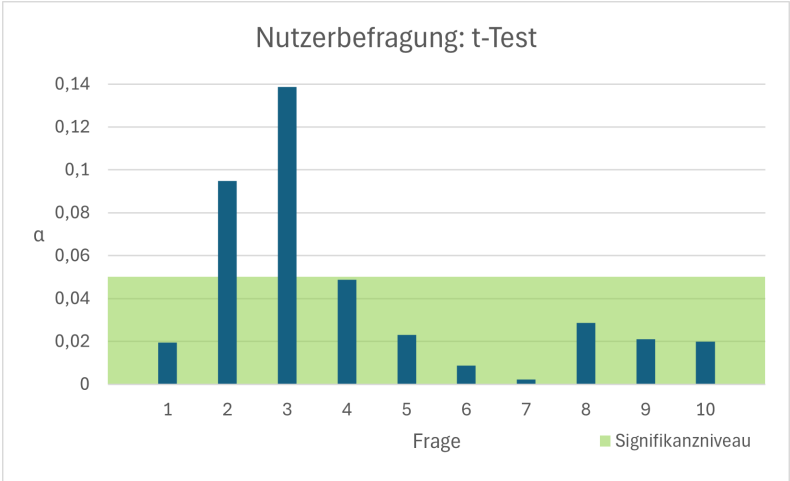


Abbildung 6.15: Signifikanzbewertung der Ergebnisse der Nutzerbefragung (Daten aus Tabelle 6.8)

Die ISO-Prinzipien, die sich spezieller auf das Kriterium der Zufriedenheit beziehen, sind die Erwartungskonformität (s. Abbildung 6.16), die Steuerbarkeit (s. Abbildung 6.6) und die Benutzerbindung, welche nicht durch den Fragebogen repräsentiert wurde (s. Abschnitt C.2).

Allgemein sind die Nutzer sehr zufrieden mit dem neuen Dashboard. 80% der Fragen haben ein signifikant besseres Ergebnis bezüglich des Dashboards erhalten. Nach Ausfilterung der zwei bereits genannten Ausnahmen (s. Unterabschnitt 6.7.2), welche zudem die mit Abstand größte Expertise aufweisen (s. Anhang E), steigt dieser Wert auf 100%.

Auf Grundlage der vorliegenden Ergebnisse hat das Dashboard einen signifikant positiven Einfluss auf den Monitoring-Prozess. Somit kann die Hypothese H_{13} akzeptiert werden.

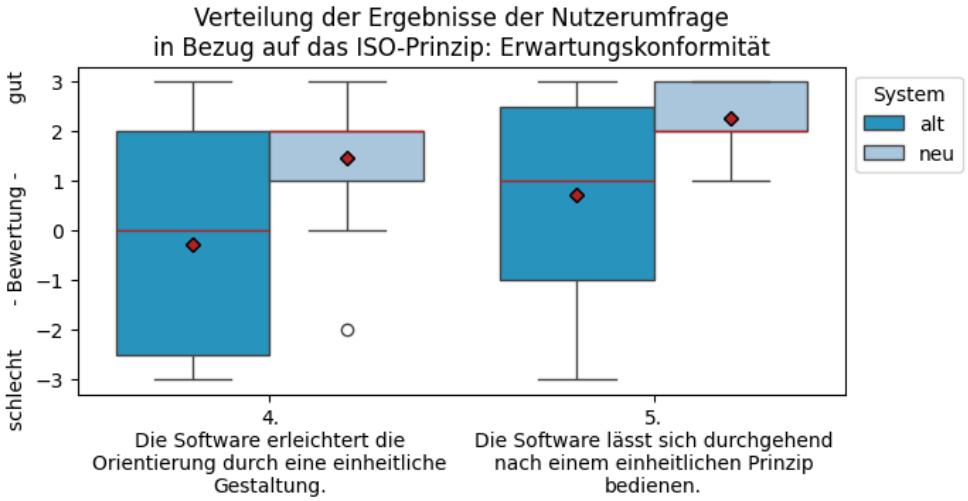


Abbildung 6.16: Verteilung der Nutzerbewertungen bzgl. des Gestaltungskriteriums Erwartungskonformität nach ISO 9241-110 (Ausschnitt aus Abbildung 6.14)

Zusätzlich zu der detaillierten Bewertung der Systeme wurde auch abgefragt, für wie wahrscheinlich es die Teilnehmer halten, das Dashboard in Zukunft zu nutzen (s. Abbildung 6.17). Da im Vergleich zu den anderen t-Tests nur eine Datenreihe vorliegt, wurde das Ergebnis mit Null paarweise, einseitig verglichen, also mit der neutralen Einstellung gegenüber beider Systeme. Bis auf die selben zwei Personen, die ein klares 'nein' antworteten, haben alle weiteren Testpersonen mit 'eher ja' und 'ja' geantwortet. Auch der t-Test bestätigt eine statistische Signifikanz dieser Aussage. Dieses Ergebnis ist daher mit einem positiven Durchschnitt statistisch signifikant.

Ausgehend von diesem Ergebnis kann auch die Hypothese H_{13} akzeptiert werden.

Antworten der Nutzer											∅	$\bar{x}$	t-Test
-2	2	1	2	2	1	2	2	2	1	-2	1	2	0,028974853

Tabelle 6.9: Ergebnisse der Umfrage zur Wahrscheinlichkeit der eigenen zukünftigen Dashboard-Nutzung (Daten aus Tabelle C.1)

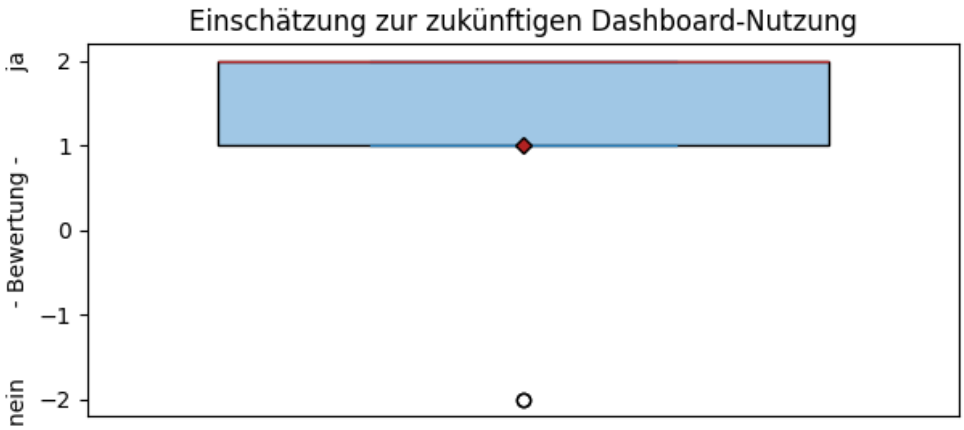


Abbildung 6.17: Antwortverteilung bzgl. der Wahrscheinlichkeit zur zukünftigen Dashboard-Nutzung (Daten aus Tabelle 6.9)

7 DISKUSSION UND EINORDNUNG DER ERGEBNISSE ZUR BEWERTUNG DER USABILITY DES ENTWICKELTEN DASHBOARDS

Im folgenden werden die Ergebnisse der Nutzerstudie zusammengefasst und die verwendete Methodik umfassend reflektiert. Daraufhin werden die Ergebnisse erneut eingeordnet, woraus eine abschließende Bewertung der Eignung der vorgestellten Dashboard-Lösung als Modernisierungsmethode folgt.

7.1 BEWERTUNG DER USABILITY AUF GRUNDLAGE DER EFFEKTIVITÄT, EFFIZIENZ UND ZUFRIEDENHEIT

Abgeleitet von allen vorangegangenen Bewertungen der drei Usability-Dimensionen gibt es eine Diskrepanz zwischen den objektiven Testergebnissen und der subjektiven Nutzererfahrung. Obwohl eine tendenziell höhere Fehlerquote unter Nutzung der Dashboard-Lösung vorliegt, welche ebenfalls die Effizienzbewertung beeinflusst, sind die Nutzer mit dem neuen System viel zufriedener als mit dem alten System.

Das Dashboard ist durch dessen vertauschte Zeilen und Spalten im Vergleich zum Altsystem nicht erwartungskonform für die Nutzer. Zusätzlich hatten diese keine Möglichkeit, sich das Dashboard zuvor akribisch ansehen und es untersuchen zu können. Dies führte zu der höheren Fehlerquote unter Nutzung des Dashboards. Auch die vergleichsweise niedrigen Fehlerwerte des alten Systems sind darauf zurückzuführen, dass die Nutzer dieses bereits mehrere Jahrzehnte nutzten. Durch die regelmäßige Wiederholung des Monitorings konnte das alte System umfangreich erlernt werden (s. Unterabschnitt 2.2.6). Daher ist eine Folgestudie nach einer längeren Einarbeitungszeit, in der das neue System regelmäßig genutzt wird, sinnvoll, um die Auswirkungen des Lernens auf die Fehlerquote anhand desselben Systems erneut zu betrachten.

Zusätzlich zur Funktionalität des alten Systems, welche überwiegend übernommen werden konnte, zeigt das Dashboard im Vergleich zum alten System mehr Funktionen auf, welche die Usability verbessern (s. Abschnitt 5.6).

Bei der Durchführung des Usability-Tests musste jedoch mehrfach darauf hingewiesen werden, dass die benötigten Informationen auf einem zweiten Dashboards zu finden sind. Anhand des Aufbaus von dem Framework Grafana mit dessen Pfadangabe ist dies nicht ersichtlich. Es wird eine eindeutige Verlinkung auf das zweite Dashboard benötigt. Die Kombination auf ein Dashboard wird dabei ausgeschlossen, da die Inhalte des zweiten Dashboards nicht im täglichen Monitoring-Prozess benötigt werden.

Dennoch ist die Resonanz sehr positiv. Durch aktives Feedback in Form von Verbesserungsvorschlägen und Erweiterungswünschen (s. Anhang E) sowie der Angabe, das Dashboard nutzen zu wollen (s. Abbildung 6.17) lässt sich darauf schließen, dass die Nutzer stark an dieser Modernisierung interessiert sind. Zusätzlich vereinfacht das Dashboard, neuen Personen einen Überblick über das System zu verschaffen, indem es als Informationssammlung verwendet werden kann.

7.2 KRITISCHE REFLEXION DER ANGEWANDTEN METHODIK

Zur Einordnung der Aussagekraft der Ergebnisse wird in diesem Abschnitt die angewandte Methodik kritisch beurteilt.

Obwohl alle verfügbaren Entwickler in die Nutzerstudie einbezogen wurden (s. Abschnitt 6.5), fällt die Stichprobe insgesamt relativ klein aus, wodurch die Teststärke reduziert ist.

Da die Stichprobe bis auf wenige Ausnahmen in Alter, Geschlecht, Berufserfahrung und Expertise sehr homogen ausfällt, erfolgt hier keine weitere Betrachtung dieser Variablen.

Ein Reihenfolgeneffekt (s. Abschnitt 6.6) kann nicht ausgeschlossen werden, da bei der Nutzerbefragung die Ergebnisse von 60% der Fragen eine Signifikanz aufzeigen, wenn das Dashboard zuerst getestet wurde (s. Tabelle C.1). Werden die Extrema der Fragen 2 und 3 entfernt, steigt dieser Wert auf 80% (s. Abschnitt C.6). In der invertierten Reihenfolge weisen lediglich 10% der Fragen eine Signifikanz auf. Anhand des Usability-Tests ist keine eindeutige Tendenz bezüglich des Reihenfolgeneffekts zu verzeichnen, da lediglich ein Unterschied in der Reihenfolge mit dem Dashboard zuerst vorliegt.

Nachfolgend wird auf die einzelnen Methoden des Usability-Tests sowie der Nutzerbefragung eingegangen.

7.2.1 *Reflexionen in Bezug auf den Usability-Test*

Die Aufgabenstellung für den Usability-Test ist zusammenfassend nicht ideal aufgestellt worden. Der begrenzte Umfang des neuen Prototyps ermöglichte eine limitierte Auswahl an möglichen Aufgaben. Es hätte zudem besser darauf geachtet werden können, dass die Ergebnisse einzelner Aufgaben relevantere Rückschlüsse für den Arbeitsalltag ermöglichen. Es empfiehlt sich, diese Untersuchung zu wiederholen und dafür einen umfangreicheren Prototyp zu verwenden sowie auf eine besser geeignete Aufgabenstellung zu achten.

Da anhand der variablenreichen Umgebung viele Details in die Aufgabenstellungen aufgenommen werden mussten, erwies es sich als schwierig, diese kurz und verständlich zu bilden. Dadurch wurden teilweise wichtige Informationen zur Lösung der Aufgaben überlesen. Zudem konnten auf Grundlage der Systemvorgaben einzelne Aufgaben unterschiedlich interpretiert werden. Da für die zweite Antwort keine Vorgabe existiert, gestaltet sich

die statistische Auswertung schwierig, weil Daten zur Betrachtung der Fehlerquote fehlen. In diesem Fall wurden alle nach zweiter Art interpretierten, aber dennoch korrekt abgelesenen Werte als *richtig* markiert. Dies zeigt auf, dass die Legacy-Struktur nicht intuitiv genug ist und somit überarbeitet werden sollte. Für die Betrachtung der Fehlerquote hat eine falsch interpretierte Aufgabe jedoch keinen Einfluss, da die Teilnehmer dennoch den gleichen Aufgabentyp bearbeiten mussten.

Die komplexe Aufgabenstellung führte jedoch zusätzlich zu einer Einschränkung in der Auswertung der Zeitergebnisse. Da einige Nutzer mehrfach die Oberfläche wechseln mussten, um die Frage erneut zu lesen, wurde ausschließlich der letzte Wert ab dem Öffnen der Ergebnisanzeige bis zum Zurückwechseln zum Fragebogen aufgezeichnet. Ungenauigkeiten sind daher nicht auszuschließen.

Ungünstigerweise wurden die zusammenhängenden Aufgaben von 3 und 4 jeweils auf der gleichen Seite erfragt. Auch die Zeitauswertung konnte dahergehend nicht ideal umgesetzt werden, da der zweite Wert teilweise direkt mit gesucht wurde, wodurch die Auftrennung der Bearbeitungsdauer auf zwei Werte teilweise uneindeutig ausfiel. Möglicherweise wurden durch die doppelte Abfrage der Werte auch Daten vom Nutzer vertauscht. Da jedoch beide Werte gefragt waren, wurden sie auch in umgekehrter Reihenfolge als richtig akzeptiert.

Alle Unterschiede des Aufbaus wurden in die Konzeption des Usability-Tests aufgenommen (s. Abschnitt D.2). Im Altsystem müssen die Nutzer viele Oberflächen überblicken können. Beim Test war dieser Umfang jedoch nicht gegeben, da der Prototyp unvollständig ist und bisher lediglich zwei der Fälle darstellt (s. Abschnitt 5.5). Es empfiehlt sich daher, den Versuch mit einem umfangreicheren Prototyp zu wiederholen. Stattdessen wurde häufiger vergessen, dass die benötigten Informationen auf dem zweiten Dashboard zu finden sind. Daraus lässt sich schließen, dass entweder die Inhalte beider Dashboards miteinander zu kombinieren sind oder der Pfad zum zweiten Dashboard ersichtlicher darzustellen ist. Die Kombination der beiden Dashboards wurde in der Erstellung jedoch bewusst vermieden, da der Inhalt des zweiten Dashboards für die Release-Versionen nicht im Tagesgeschäft benötigt wird und somit eine Ablenkung zu den täglich relevanten Daten schafft. Stattdessen kann jedoch eine Verlinkung auf das zweite Dashboard erfolgen, welche im oberen Bereich in einem Informationsfeld eingefügt werden kann.

7.2.2 *Reflexionen in Bezug auf die Nutzerbefragung*

Die Nutzerbefragung erfolgte auf der Grundlage eines geprüften und etablierten Fragebogens [Prü+06], welcher die Umsetzung der Interaktionsprinzipien der DIN EN ISO 9241-110 [Dina] sicherstellt. Da mit dem Anwendungsfall des täglichen Testpoolmonitorings der Fokus auf der Usability liegt, musste etwa die Hälfte der Fragen aus der Nutzerbefragung gestrichen werden. Da das Dashboard eine reine Informationsquelle ist, die keine Nut-

zerinteraktion ermöglicht, mussten die Fragen in Bezug auf das Prinzip Robustheit gegen Benutzungsfehler vollständig aussortiert werden. Auch die Fragen des Prinzips der Benutzerbindung wurden aussortiert, da diese Untersuchung auf den Bereich der Usability begrenzt wurde.

Es sind weiterhin vereinzelt Werte entfallen. Die Auswahl des Umfragetools Survio ist rückblickend nicht geeignet, um viele Skalenauswertungen untereinander aufzulisten. Da die Beschriftung der Skala entgegen der allgemeinen Intuition unterhalb steht (s. Abbildung C.1), sind einige Testpersonen in der Zeile verrutscht. Die Daten wurden über die Aufnahmen der Meetings nachträglich ermittelt. Hat der Teilnehmer die Fragen während der Beantwortung mit vorgelesen, konnten die Daten zumeist richtig zugeordnet werden. Allerdings wurden so auch Fragen übersehen. Obwohl letztendlich nur vier Werte fehlen, entfallen diese gemeinsam mit ihrem Pendant bei der Durchführung des paarweisen t-Test. Bei dieser kleinen Stichprobe können fehlende Daten ein Problem bezüglich der Aussagekraft stellen.

7.3 ABSCHLIESSENDE BEWERTUNG ZUR EIGNUNG VON MODERNEN DASHBOARDS

Zusammenfassend lässt sich sagen, dass das Dashboard eine geeignete Lösung zur Modernisierung des Legacy-Testpoolmonitoring-Prozesses darstellt. Die Ergebnisse der Usability-Auswertung stellen jedoch keine signifikante Verbesserung dar.

Anhand der höheren Fehlerquote des Dashboards, welche ebenso die Effizienzbewertung beeinflusst, ist Verbesserungspotenzial erkennbar. Allerdings kann dieses auch in Form des Zeitaufwands der Nutzer erfolgen. Die Ergebnisse zeigen, dass eine intuitive Nutzung des Dashboards möglich ist, wodurch sich der benötigte Lernaufwand minimiert. Dieser Aufwand muss dennoch zu Erlernung des Systems investiert werden, was zur Zeit des Usability-Tests noch nicht erfolgte.

Trotz der Verminderung der Aussagekraft des Usability-Tests bestätigten die Nutzer die Verbesserung des Monitoring-Prozesses anhand der Nutzerbefragung. Das Dashboard hilft dabei, einen Überblick über alle Ergebnisse zu gewinnen. Da davon ausgegangen wird, dass mehr Nicht-Fehler als Fehler angezeigt werden, verringert sich der Aufwand, wie viele Oberflächen anzusehen sind. Für die Detailübersicht wird im Fehlerfall jeweils nur ein zusätzlicher Mausklick benötigt.

Das neue Dashboard ist zur Zeit noch ein Prototyp und zeigt das große Potential dieser Modernisierungsmaßnahme. Zur Vervollständigung werden dahingehend weitere Investitionen in Form von Ressourcen wie Personal und Zeit benötigt. Diese Ressourcen sind jedoch nicht vorhanden (s. Abschnitt 2.1). Allerdings sind Modernisierungsprozesse immer aufwändig, wodurch dieses Argument im Speziellen gegen die vorgeschlagene Dashboard-Lösung hinfällig ist.

Da das alte System jedoch nicht direkt abgelöst wird, müssen potenzielle Verbesserungen und Features in beiden Systemen umgesetzt werden. Um

nicht selbst zur nächsten großen Wartungsaufgabe zu werden, ist der Parser zum Erhalt der Daten so geschrieben, dass das alte System unabhängig von den Inhalten ausgelesen wird (s. Abschnitt B.1). Sollten keine großen strukturellen Veränderungen am Altsystem erfolgen, was angesichts des jahrelangen Stillstands dessen unwahrscheinlich wirkt, benötigt das Dashboard diesbezüglich wenig Wartungsaufwand.

Ein weiterer Vorteil der Lösung ist, dass Personen, die Jahrzehnte mit dem alten System gearbeitet haben, auch weiter mit diesem arbeiten können, da es vollständig unberührt bleibt (s. Abschnitt 5.4). Die Umgewöhnung auf die vertauschten Zeilen und Spalten kann somit vom Nutzer akzeptiert oder ignoriert werden. Da das Dashboard insgesamt stark positiv bewertet wurde und dessen Nutzung somit eine signifikante Verbesserung zum Altsystem darstellt, ist dieser Aspekt als eine minimale Unannehmlichkeit einzustufen, welche durch das vollständige Erlernen des neuen System nichtig wird.

Da das Dashboard nicht in das bestehende System eingreift, sondern nur darauf aufsitzt, ist es eine nicht invasive Lösung mit geringem Risiko in der Umsetzung. Es eignet sich als erster Schritt zur Verbesserung der Usability des Monitorings. Lange aufgeschobene Probleme und Altlasten, die sich in ihrer Komplexität potenzieren, konnten aufgedeckt werden, damit sie doch noch gelöst werden (s. Unterabschnitt 6.7.4).

Des Weiteren kann es in mehreren Bereichen im Vergleich zum Altsystem mit neuen Funktionen überzeugen (s. Anhang A, Abschnitt 5.6). Es konnten die Ergebnisse von allen vorherigen Oberflächen auf wenige vereint werden. Dabei wurde die Struktur vereinfacht und selbsterklärender, indem die Ergebnisse in Fehlerkategorien zusammengefasst, Fachsprache simplifiziert und nicht benötigte Funktionen entfernt wurden. Zudem überzeugt das Dashboard mit einer einheitlicheren, moderneren und intuitiveren Oberflächengestaltung, welche zusätzlich ergänzende Informationen liefert.

Die Einführung des Dashboards ist demnach eine sehr sinnvolle Methode, um den Legacy-Testpoolmonitoring-Prozess effizienter und nutzerfreundlicher zu gestalten. Es unterstützt das Monitoring weiterhin durch die Einsparmöglichkeiten bezüglich Personalzeit, indem der Systemzustand schneller erkannt wird, wodurch die Fehlerbehebung zeitiger initiiert werden kann.

8

SCHLUSSFOLGERUNGEN, LIMITATIONEN UND AUSBLICK

Um einen Beitrag zu nachhaltigen und effizienten Systemen beizusteuern, sollte mit dieser Forschungsarbeit herausgestellt werden, inwiefern moderne Dashboards zur Unterstützung der Modernisierung geeignet sind. Dafür wurde die Ergebnisanzeige eines Legacy-Testpools als Grundlage für ein neues Dashboard aufgegriffen. Ziel war es herauszustellen, wie sinnvoll dessen Einführung ist, um den Monitoring-Prozess effizienter und nutzerfreundlicher zu gestalten.

In diesem Kapitel werden die relevanten Ergebnisse noch einmal zusammengefasst und in den aktuellen Forschungsstand eingeordnet. Anschließend werden die Grenzen des Dashboard-Prototyps aufgezeigt, welche als Grundlage für mögliche Weiterentwicklungen oder aufbauende Forschungsarbeiten dienen können.

8.1 ZUSAMMENFASSUNG DER WICHTIGSTEN ERGEBNISSE

Zur Beantwortung der Problemstellung, inwiefern Dashboards geeignet und sinnvoll sind, als Modernisierungsmethode eingesetzt zu werden, wurde hierfür eine Nutzerstudie bestehend aus einem Usability-Test und einer dazugehörigen Nutzerbefragung durchgeführt. Während die Nutzerbefragung auf den Prinzipien der ISO 9241-110 basiert, wurden innerhalb des Usability-Tests die nachträglich abgefragten Eigenschaften eingebaut. Auf Grundlage dessen konnten die beide Systeme anhand der drei Usability-Dimensionen Effektivität, Effizienz und Nutzerzufriedenheit verglichen werden.

Die gewählte Dashboard-Lösung ist eine Art Hülle welche auf dem Legacy-System aufsitzt. Das Dashboard fasst die komplexen Inhalte des gewachsenen Legacy-Systems zusammen und bereitet diese grafisch neu auf. Aufgrund der Einführung dieser Lösung ist ein zeitlich effizienteres Monitoring möglich als zuvor. Zwar wies der Usability-Test an dem Dashboard eine höhere Fehlerquote auf als an dem Altsystem, jedoch liegt dies an der exzellenten Kenntnis der Nutzer des Altsystems sowie der Tatsache, dass die neue Lösung erst mit der Teilnahme an der Studie vorgestellt wurde. Allerdings konnte das Dashboard in den entscheidenden Testbereichen durch seine verbesserte Effektivität überzeugen und somit eine um fast 50% bessere Effizienz vorweisen.

Anhand der regen Teilnahme an der Feedbackrunde war festzustellen, dass durchaus Verbesserungspotenzial an dem neuen Prototyp besteht. Jedoch wird damit auch Interesse auf Nutzerbasis gezeigt, dieses Projekt weiter zu fördern. Insgesamt sind die Nutzer auch viel zufriedener mit der

Umsetzung und Nutzbarkeit des Dashboards als mit der gewachsenen Altlösung, sodass ein Umstieg auf das neue Dashboard denkbar ist.

8.2 EINORDNUNG IN DEN AKTUELLEN FORSCHUNGSSTAND

Die Dashboard-Lösung ist eine nicht-invasive, risikoarme Modernisierungsmethode. Es hilft Anwendern, Monitoring-Prozesse effizienter zu gestalten, da es die alten Strukturen in eine nutzerfreundliche Oberfläche verpackt. Weiterhin ermöglicht das Dashboard durch dessen informativen Charakter einen vereinfachten Einstieg und unterstützt somit die Einarbeitung neuer Mitarbeiter, was den Generationenwechsel zusätzlich fördert. Da diese Dashboard-Lösung jedoch keine bestehenden Strukturen entfernt, entsteht auch keine Hürde für langjährige Mitarbeiter, welche potenziell Probleme mit der Umstellung haben.

Weiterhin bietet es sich an, eine Ergebnisanzeige mit dieser Lösung zu modernisieren, um vergessene oder geduldete Altlasten aufzudecken. Da es sich teilweise schwierig gestaltet, diese durch die Modernisierungsmaßnahme automatisiert auszulesen, bietet der Prozess eine geeignete Gelegenheit, die Altlasten neu zu entdecken und aufzuarbeiten.

Es kann darüber hinaus dazu dienen, auf das Thema der Modernisierung aufmerksam zu machen, wie diese beispielsweise zur Optimierung von Prozessen eingesetzt werden kann. Das Dashboard kann somit als eine geeignete und zukunftsfähige Modernisierungsmethode für Legacy-Anwendungen mit Ergebnisanzeige eingeordnet werden, welche das Potenzial hat, Altsysteme nachhaltig zu verbessern.

Aufgrund dieser Ergebnisse ist somit bewiesen, dass die Einführung dieser Dashboard-Lösung sinnvoll ist, um Legacy-Monitoring-Prozesse effizienter und nutzerfreundlicher zu gestalten.

8.3 GRENZEN DES ENTWICKELTEN PROTOTYPS UND MÖGLICHE WEITERENTWICKLUNGEN

Da die Dashboard-Lösung bislang ein Projekt prototypischen Charakters ist, kann dieses noch stark ausgeweitet werden. Neben dem Ausbau auf den restlichen Testpool kann das Nutzerfeedback zur Optimierung umgesetzt werden. Dieses liefert hilfreiche Hinweise bezüglich des bestehenden Arbeitsablaufs sowie der Formatierung, Größe und Kapselung zusammengehöriger Informationen, um den Übergang auf das neue System zu erleichtern.

Bisher bietet das Dashboard rein inhaltlich betrachtet keinen Mehrwert. Da die Daten unabhängig vom bestehenden System ausgewertet und aufgearbeitet werden, sind vorgeschlagene Funktionen wie die Darstellung der Fehlerwerte der letzten zwei Wochen in einem Verlaufsdiagramm möglich. Da das Dashboard jeden Tag überwacht wird, ist ein direkter Vergleichswert zum Vortag denkbar. Dieser zeigt zusätzlich zur Fehlerzahl, ob und wie viele Fehler mehr oder weniger als am Vortag vorliegen.

Da das System keine Veränderung am Altsystem vornimmt, kann diese Lösung ausschließlich als erster Schritt des Modernisierungsprozesses angesehen werden. Es hilft, Altlasten zu erkennen und fachfremden Personen den Einstieg in das System zu erleichtern. Ein nächster Schritt wäre, diese Erkenntnisse zur Umstrukturierung und Optimierung oder zur Umstrukturierung in Kombination mit einem Rehosting auf zum Beispiel ein standardisiertes, modernes Framework zu nutzen. Somit trägt diese Lösung aktiv zum nachhaltigen Bestand der Software bei, dessen Daten auf dem Dashboard angezeigt werden.

8.4 AUSBLICK UND EMPFEHLUNGEN FÜR WEITERGEHENDE FORSCHUNG

Dieses Prototyp-Projekt kann mit den aufgezählten Funktionen und vorgeschlagenen Verbesserungen ausgebaut und optimiert werden. Dabei können die Erkenntnisse aus dieser Forschungsarbeit eine Grundlage für beispielsweise folgende Aufbaustudien bieten:

Aufgrund der Durchführung mit begrenzten Kapazitäten ist eine Wiederholung des Versuchs mit einer höheren Teilnehmerzahl oder einem größeren Umfang in Funktionalität und Aufgaben denkbar, um die Ergebnisse mit einer größeren Teststärke validieren zu können. Mit mehr Teilnehmern einer Studie kann auf eine breitere Fächerung sowie gleichmäßigere Verteilung der Nutzer in Erfahrungslevel, Expertise sowie Altersklasse geachtet werden. Dies ermöglicht, Rückschlüsse auf die verschiedenen Variablen ziehen zu können. Dieser Ansatz kann Erkenntnisse darauf bieten, wie Modernisierungsmaßnahmen aufgefasst werden oder wie diese in den verschiedenen Nutzergruppen angegangen werden sollten.

Eine Wiederholung des Versuchs erweist sich ebenfalls als sinnvoll, um den Teilnehmern die Möglichkeit zu geben, mehr mit dem Dashboard arbeiten zu können. Sobald sie dieses erlernt haben, kann eine Folgestudie Aufschluss darüber geben, ob sich die Fehlerquote daduch reduzieren lässt.

Eine weitere Möglichkeit stellt die Untersuchung tiefergreifender Modernisierungsmaßnahmen wie der Umstrukturierung oder des Rehostings dar. Es könnten verschiedene Ansätze getestet oder unterschiedliche standardisierte Frameworks miteinander verglichen werden, um eine gute Lösung für das jeweilige System finden zu können.

Teil II

APPENDIX

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
		Ja / Nein	Grund, falls nicht anwendbar	Was wurde unternommen		Was wurde unternommen	
				Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.1.1	**Aufgabenangemessenheit**						
5.1.2	Empfehlungen in Bezug auf die Identifizierung der Angemessenheit des interaktiven Systems für eine bestimmte Aufgabe						
5.1.2	Genügend Informationen liefern, die die Benutzer dazu befähigen zu ermitteln, ob das System für die von ihnen angestrebten Ergebnisse geeignet ist	ja	---	nein	Übergang von einer Oberfläche auf die nächste ist nicht ersichtlich	ja	alle Oberflächen wurde auf eine vereint
5.1.3	Empfehlungen in Bezug auf die Aufwandsoptimierung bei der Aufgabenerledigung						
5.1.3.1	Dem Benutzer die für jeden Aufgabenschritt erforderlichen Steuerelemente und aufgabenbezogenen Informationen zur Verfügung stellen	ja	---	ja	---	ja	---
5.1.3.2	Dem Benutzer keine Schritte auferlegen, die nicht aus den Erfordernissen der Aufgabe selbst, sondern aus der Technologie resultieren	ja	---	nein	Die Technologie gibt für Details alle Infos an, obwohl nicht alle benötigt werden	nein	Dashboard sitzt nur oben auf, für Details muss die alte Oberfläche genutzt werden
5.1.3.3	Dem Benutzer keine Funktionen anbieten und Informationen darstellen, welche die Ausführung aktueller Aufgaben behindern	ja	---	nein	viele Schaltflächen auswählbar, deren Funktionen abgeschaltet wurden	ja	nur die wichtigsten Infos zusammenfassend dargestellt
5.1.4	Empfehlungen in Bezug auf Standardauswahlmöglichkeiten zur Aufgabenunterstützung						
5.1.4.1	Soweit zweckmäßig, Standardauswahlmöglichkeiten anbieten	ja	---	ja	---	ja	---
5.1.4.2	Keine Standardauswahlmöglichkeiten anbieten, wenn diese den Benutzer in die Irre führen können	ja	---	nein	viele Schaltflächen auswählbar, deren Funktionen abgeschaltet wurden	ja	wurden abgeschafft

Tabelle A.1: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (1/7 Aufgabenangemessenheit)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
				Was wurde unternommen		Was wurde unternommen	
		Ja / Nein	Grund, falls nicht anwendbar	Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.2.1	**Selbstbeschreibungsfähigkeit**						
5.2.2	Empfehlungen in Bezug auf das Vorhandensein und die Offensichtlichkeit von Informationen						
5.2.2.1	Informationen liefern, die den Benutzer führen und die Notwendigkeit der Konsultation von Online-Hilfen, Benutzerhandbüchern oder sonstigen externen Informationen minimieren	ja	---	nein	teilweise - kaum navigierbar	ja	alle benötigten Verlinkungen beisammen dargestellt
5.2.2.2	Eindeutig anzeigen, an welcher Stelle der Navigationsstruktur sich der Benutzer befindet, welche Benutzerhandlungen zu diesem Zeitpunkt möglich sind und wie sie ausgeführt werden können	ja	---	nein	zu viele Möglichkeiten, davon nur wenige funktionsfähig, daher keine Orientierung möglich	ja	es gibt Breadcrumbs
5.2.2.3	Benutzer dazu befähigen, die zur Ausführung der Aufgabe erforderlichen Steuerelemente zu finden	ja	---	ja	---	ja	---
5.2.2.4	Informationen so darstellen, dass eindeutig ersichtlich ist, welche Benutzungsschnittstellen-Elemente interaktiv und welche nicht interaktiv sind	ja	---	ja	---	nein	teilweise - Links / Buttons im Darkmode unscheinbar
5.2.2.5	Informationen mit einem dem Benutzer vertrauten Vokabular darstellen	ja	---	ja	Fachjargon - mit Erfahrung vertraut	ja	Fachjargon vereinfacht dargestellt
5.2.3	Empfehlungen in Bezug auf die eindeutige Anzeige des Systemzustands						
5.2.3.1	Fortschritt bei der Erledigung einer Aufgabe anzeigen	nein	Die Oberfläche kann nur statische Informationen anzeigen	---	---	---	---
5.2.3.2	Den Benutzer über Änderungen des Systemzustands informiert halten	ja	---	nein	Oberfläche muss für Updates aktiv neu geladen werden	ja	Auto Refresh
5.2.3.3	Anzeigen, wann und wo eine Benutzereingabe erforderlich ist	nein	Es sind keine Nutzereingaben, außer der Angabe von Attributen zur Identifikation der gewünschten Oberfläche möglich	---	---	---	---

Tabelle A.2: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (2/7 Selbstbeschreibungsfähigkeit)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
				Was wurde unternommen		Was wurde unternommen	
		Ja / Nein	Grund, falls nicht anwendbar	Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.3.1	**Erwartungskonformität**						
5.3.2	Empfehlungen in Bezug auf angemessene(s) Systemverhalten und -reaktionen						
5.3.2.1	Schritte zur Erledigung der Aufgabe bereitstellen, die mit dem Aufgabenverständnis der Benutzer konsistent sind	ja	---	ja	---	ja	---
5.3.2.2	Entsprechend den Erfordernissen des breitesten Spektrums von Benutzern und Nutzungskontexten reagieren	ja	---	nein	kompliziert, nach Technik aufgebaut	ja	eher - moderner
5.3.2.3	Sofortige und den Benutzererfordernissen angemessene Rückmeldungen auf Benutzerhandlungen liefern	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.3.2.4	Dem Benutzer eine Fortschrittsinformation ausgeben, falls eine erheblich lange Reaktionszeit erwartet wird	nein	Es sind keine Nutzereingaben möglich, auf die das System reagieren kann	---	---	---	---
5.3.3	Empfehlungen in Bezug auf die Konsistenz (interne und externe)						
5.3.3.1	Für Darstellung, Eingabe und Steuerung kulturelle und sprachliche Konventionen verwenden, die den Benutzern vertraut sind	ja	---	ja	jein - Fachbegriffe bekannt, Abkürzungen verwirren	ja	---
5.3.3.2	Innerhalb des interaktiven Systems konsistent sein sowie über andere interaktive Systeme hinweg, mit denen der Benutzer voraussichtlich interagieren wird	ja	---	nein	Oberflächen haben verschiedene Layouts	ja	einheitlicher Aufbau der Oberflächen
5.3.3.3	Sich offensichtlich unterscheiden für Elemente mit unterschiedlichem Zweck innerhalb des interaktiven Systems sowie über andere interaktive Systeme hinweg	ja	---	ja	---	ja	---
5.3.4	Empfehlungen in Bezug auf Änderungen im Nutzungskontext						
5.3.4.1	In der Lage sein, auf die unterschiedlichen Erfordernisse einzelner Benutzer zu reagieren	ja	---	ja	zoombar	ja	zoombar, klappbar
5.3.4.2	Angemessen auf Änderungen an angeschlossenen Ressourcen reagieren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.3.4.3	Informationen auf unterschiedlichen Gerätearten und Anzeigegrößen angemessen darstellen	ja	---	ja	immer gleich, aber angemessen genug	nein	das Grid ließ sich nicht fix einstellen
5.3.4.4	Sich an Änderungen hinsichtlich der physischen Umgebung des Benutzers anpassen	ja	---	nein	nur Lightmode	nein	nur Darkmode

Tabelle A.3: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (3/7 Erwartungskonformität)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
		Ja / Nein	Grund, falls nicht anwendbar	Was wurde unternommen		Was wurde unternommen	
				Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.4.1	**Erlernbarkeit**						
5.4.2	Empfehlungen in Bezug auf Entdeckung						
5.4.2.1	Den Benutzer dabei unterstützen, die systemeigenen Fähigkeiten zu entdecken und so zu nutzen, dass die vom Benutzer angestrebten Ergebnisse erreicht werden	ja	---	nein	Wechsel auf weitere Oberflächen erschwert	ja	alles auf einen Blick verfügbar
5.4.2.2	Benutzer befähigen, Informationen zu finden, die über ihre aktuelle Aufgabe hinausgehen	ja	---	nein	externe Quellen nicht angegeben, z.B. Datenursprung	ja	sind verlinkt
5.4.3	Empfehlungen in Bezug auf Exploration						
5.4.3.1	Es dem Benutzer erlauben, das System ohne negative Konsequenzen zu explorieren	ja	---	ja	---	ja	---
5.4.3.2	Dem Benutzer geeignete Alternativen bieten für die Suche nach und das Navigieren zu Informationen und Funktionen	ja	---	nein	händisch oder Strg+F	nein	händisch oder Strg+F
5.4.4	Empfehlungen in Bezug auf Retention						
5.4.4.1	Rückmeldungen liefern, die dem Benutzer helfen, die Folgen seiner Aktionen zu erlernen	ja	---	nein	nicht verfügbare Auswahlen führen auf leere Seiten, kaum zurück findbar	ja	wieder zurück findbar
5.4.4.2	Entwicklung von Fertigkeiten des Benutzers in Zusammenhang mit den unterstützten Aufgaben fördern	ja	---	nein	viele Abkürzungen, sehr verzweigt	ja	selbst erklärend

Tabelle A.4: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (4/7 Erlernbarkeit)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
		Ja / Nein	Grund, falls nicht anwendbar	Was wurde unternommen Ja / Nein	Was wurde unternommen Bemerkungen	Was wurde unternommen Ja / Nein	Was wurde unternommen Bemerkungen
5.5.1	**Steuerbarkeit**						
5.5.2	Empfehlungen in Bezug auf Unterbrechung durch den Benutzer						
5.5.2.1	Es dem Benutzer erlauben, die Ausführung einer Aufgabe zu jedem beliebigen Zeitpunkt zu unterbrechen	ja	---	ja	---	ja	---
5.5.2.2	Es dem Benutzer erlauben, die Ausführung einer unterbrochenen Aufgabe zu einem späteren Zeitpunkt dort fortzusetzen, wo die Unterbrechung erfolgte	ja	---	ja	---	ja	---
5.5.2.3	Es dem Benutzer erlauben, die laufende Aufgabe zu unterbrechen und die Steuerung zu übernehmen, um die Aufgabe von Hand auszuführen	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.5.3	Empfehlungen in Bezug auf Flexibilität						
5.5.3.1	Es dem Benutzer erlauben, die Aufgabe in der bevorzugten Reihenfolge durchzuführen	ja	---	ja	---	ja	---
5.5.3.2	Dem Benutzer die Flexibilität ermöglichen, zur Ausführung der Aufgabe unterschiedliche Mittel der Interaktion zu wählen	nein	---	---	---	---	---
5.5.3.3	Es dem Benutzer erlauben, die Geschwindigkeit der Interaktion zu steuern	ja	---	ja		ja	
5.5.3.4	Es dem Benutzer erlauben, zumindest die letzte Aktion rückgängig zu machen	nein	Es sind keine Nutzereingaben möglich	---		---	
5.5.4	Empfehlungen in Bezug auf Individualisierung						
5.5.4.1	Es dem Benutzer erlauben, Standardwerte und/oder Auswahlmöglichkeiten dauerhaft zu ändern	ja	---	nein	unveränderbare Anzeige	nein	Tool ermöglicht dies, noch nicht implementiert
5.5.4.2	Es den Benutzern erlauben, die Benutzungsschnittstelle an die individuellen Erfordernisse und Vorlieben anzupassen	ja	---	nein	unveränderbare Anzeige	ja	einklappbare Reihen
5.5.4.3	Es dem Benutzer erlauben, im Anschluss an beliebige Änderungen zu den vorherigen oder Originaleinstellungen zurückzukehren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---

Tabelle A.5: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (5/7 Steuerbarkeit)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
				Was wurde unternommen		Was wurde unternommen	
		Ja / Nein	Grund, falls nicht anwendbar	Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.6.1	**Robustheit gegen Benutzungsfehler**						
5.6.2	Empfehlungen in Bezug auf die Vermeidung von Benutzungsfehlern						
5.6.2.1	Vom Benutzer nicht die Eingabe bereits bekannter Informationen verlangen	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.2.2	Es dem Benutzer erlauben, überall dort, wo geeignete Daten im System verfügbar sind, Daten auszuwählen (mittels Wiedererkennung) anstatt Daten von Hand eingeben zu müssen (mittels Erinnerung), um das Risiko von Eingabefehlern zu minimieren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.2.3	Nur aktuell gültige Auswahlmöglichkeiten zulassen	ja		nein	viele alte Systeme nicht entfernt, ungültige Kombinationen möglich	ja	nur gültige werden angezeigt
5.6.2.4	Sicherstellen, dass den Benutzern ihre geleistete Arbeit nicht infolge von Benutzungs- oder Systemfehlern verloren geht	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.2.5	Vor der Weiterverarbeitung von Eingaben und Einstellungen mögliche Eingabefehler identifizieren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.2.6	Bestätigung anfordern, bevor es die Handlung ausführt, falls sich aus einer Benutzerhandlung schwerwiegende Auswirkungen ergeben können	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.3	Empfehlungen in Bezug auf die Toleranz gegen Benutzungsfehler						
5.6.3.1	Es dem Benutzer erlauben, die Korrektur eines Eingabefehlers zu verschieben oder den Eingabefehler unkorrigiert zu lassen	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.3.2	Den Benutzer über die Ausführung der Korrektur informieren und ihm Gelegenheit geben, zu korrigieren, wenn es Fehler automatisch korrigieren kann	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.4	Empfehlungen in Bezug auf die Behebung von Benutzungsfehlern						
5.6.4.1	Den Benutzer dabei unterstützen, Eingabefehler zu entdecken, nachzuvollziehen und zu korrigieren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.4.2	Präzise, verständliche und höflich formulierte Fehlermeldungen ausgeben	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.4.3	Konstruktive Erläuterungen zu Fehlern liefern, die deren Korrektur erleichtern	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.6.4.4	Zur Fehlerkorrektur erforderliche Schritte und benötigten Aufwand minimieren	nein	Es sind keine Nutzereingaben möglich	---	---	---	---

Tabelle A.6: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (6/7 Robustheit gegen Nutzungsfehler)

Unter-abschnitt	Prinzip / Empfehlung	Anwendbarkeit		altes System		neues System	
				Was wurde unternommen		Was wurde unternommen	
		Ja / Nein	Grund, falls nicht anwendbar	Ja / Nein	Bemerkungen	Ja / Nein	Bemerkungen
5.7.1	**Benutzerbindung**						
5.7.2	Empfehlungen in Bezug auf die Motivierung des Benutzers zur Verwendung des Systems						
5.7.2.1	Dem Benutzer Bestätigungen über erfolgreich erledigte Aufgaben liefern und darüber informieren, dass keine offenen Punkte mehr vorliegen, um die sich der Benutzer kümmern muss	nein	Es sind keine Nutzereingaben möglich	---	---	---	---
5.7.2.2	Affektive Merkmale zur Förderung entsprechender emotionaler Reaktionen mit Bedacht einsetzen	nein	bewertet User-Experience	---	---	---	---
5.7.2.3	Informationen und Funktionen auf eine Weise darstellen, die vom Benutzer als respektvoll empfunden wird	ja	---	ja	---	ja	---
5.7.2.4	So ausgelegt sein, dass es Benutzererfordernisse antizipiert, deren sich der Benutzer möglicherweise gar nicht bewusst ist	nein	bewertet User-Experience	---	---	ja	leitet weiter zu nützlichen Infos, die aber nicht erforderlich sind
5.7.2.5	Für seine Benutzer einen positiven ersten Eindruck erzeugen	ja	---	Ja	leitet zu Details weiter, Farben	ja	Übersichtlichkeit, Vollständigkeit, Farbgestaltung
				Nein	kein Übergang zu anderen Systemen		
5.7.2.6	Für die Benutzer-Bevölkerung attraktiv sein, ohne Abstriche in Bezug auf Effektivität und Effizienz	ja	---	nein	unnötig viel Text, unsortiert	ja	Struktur vereinfacht, unnötige Infos ausgegraut
5.7.2.7	Keine unverhältnismäßigen Anforderungen an den Benutzer stellen	nein	bewertet User-Experience	---	---	---	---
5.7.3	Empfehlungen in Bezug auf die Vertrauenswürdigkeit des Systems						
5.7.3.1	Vertrauen schaffen hinsichtlich seiner Verwendung	nein	bewertet User-Experience	---	---	---	---
5.7.3.2	Dem Benutzer einen realistischen Grad an Vertrauen vermitteln, dass seine Benutzung kein Risiko darstellt	nein	bewertet User-Experience	---	---	---	---
5.7.4	Empfehlungen in Bezug auf gesteigerte Einbeziehung der Benutzer in das						
5.7.4.1	Den Benutzern Funktionen bereitstellen, um einander zu helfen	nein	da dieses System in einem kleinen	---	---	---	---
5.7.4.2	Den Benutzern die Gelegenheit bieten, Vorschläge zu Änderungen und Systemerweiterungen einzureichen, die seine Verwendung verbessern	nein	Entwicklungsteam verwendet wird, ist keine weitere Feedbackfunktion	---	---	---	---
5.7.4.3	Rückmeldungen zu Entwicklungsentscheidungen auf der Grundlage von Benutzervorschlägen liefern	nein	innerhalb dieses Systems notwendig	---	---	---	---

Tabelle A.7: Zustands- und Anforderungsanalyse sowie Vergleich des alten und neuen Systems nach [Dina] (7/7 Nutzerbindung)

B

ANHÄNGE ZUM DASHBOARD

B.1 PARSER-CODE - VON DEN TESTERGEBNIS-DATEN ZUM JSON-FILE

```
import json
import re
import requests
import os

# ********************************************************************
unwanted_tests = {
    "[environment_dev_1]": {
        "BUILD": ["warn"],
        "[test_cat_1]": [],
        "[test_cat_2]": [],
        "[test_cat_3]": ["[test_name_1]", "[test_name_2]", "[test_name
            _3]"],
        "[test_cat_4]": [],
        "[test_cat_5]": []
    },
    "[environment_dev_2]": {
        "BUILD": ["warn"],
        "[test_cat_1]": [],
        "[test_cat_2]": [],
        "[test_cat_3]": []
    },
    "[environment_rel_3]": {
        "BUILD": ["warn"],
        "[test_cat_1]": [],
        "[test_cat_2]": []
    },
    "[environment_rel_4]": {
        "BUILD": ["warn"],
        "[test_cat_1]": [],
        "[test_cat_2]": []
    }
}
ignored_tests = {
    "[environment_dev_1]": {
        "[test_cat_2]": ["[test_name_4]"]
    },
    "[environment_dev_2]": {
        "[test_cat_2]": ["[test_name_4]"]
    },
    "[environment_rel_3]": {
        "[test_cat_2]": []
    },
```

```
    "[environment_rel_4]": {
        "[test_cat_2]": []
    }
}

def get_list_from_NameOfResultView(natvers, node, key, date):
    url = "https://[url]:[port]/[path]?"

    # GET-Request
    payload = {"natvers" : natvers, "node" : node, "key" : key, "DATE" :
         date}
    request = requests.get(url,
                           params = payload,
                           verify = False)
    output = request.text

    # cut html output to wanted substring

    # initializing substrings
    sub1 = "<pre class='result'>"
    sub2 = "</pre>"
    req_result = ""

    while(output.find(sub1) >= 0):
        # getting index of substrings
        idx1 = output.find(sub1) - 1
        idx2 = output.find(sub2)

        # length of substring 1 is added to
        # get string from next character
        res = output[idx1 + len(sub1) + 1: idx2]
        req_result = req_result + res

        # reset string
        output = output[idx2 + len(sub2):]

    #return req_result
    all_lines = req_result.split('\n')
    return all_lines

def get_dict_of_lines(all_lines):
    category_of_line = ""
    dict_of_lines = {}

    for line in all_lines[1:]:
        if line == "":
            continue

        if re.match('[a-z]*:', line) :
            category_of_line = "BUILD"
        else :
            category_of_line = line.split(' ', 1)[0]
```

```
        if category_of_line in dict_of_lines:
            dict_of_lines[category_of_line].append(line)
        else:
            dict_of_lines[category_of_line] = [line]
    return dict_of_lines

def get_tests_of_a_key_list(dict_of_lines, key):
    tests_of_a_key_list = []

    for line in dict_of_lines[key]:
        # TODO - currrently removed, maybe needed
        if "First".lower() in line.lower() or "init".lower() in line.
            lower():
            dict_of_lines[key].remove(line)
            continue

        tests_of_a_line_list = [x.strip(":") for x in line.split()]
        tests_of_a_key_list = tests_of_a_key_list + tests_of_a_line_list
    tests_of_a_key_list = [value for value in tests_of_a_key_list if
        value != key]

    return tests_of_a_key_list

def convert_list_to_dictlist(lst):
    #res_dict = {}
    res_list = []
    for i in range(0, len(lst), 2):
        if(len( lst[i+1] ) > 1):
            """
            -       heute noch nicht gelaufen
            n/a     gibts in der Umgebung nicht
            Err     Fehler
            Ok      ok
            CORE    crashed
            """
            if(lst[i+1] == "N/A"): continue
            if(lst[i+1] == "OK"): lst[i+1] = "0"
            #if(lst[i+1] == "Err"): lst[i+1] = -1
            #if(lst[i+1] == "CORE"): lst[i+1] = -2

        if lst[i+1].isnumeric():
            #res_dict[lst[i]] = int(lst[i + 1])
            res_list.append({ "testname" : lst[i], "result" : int(lst[i
                + 1]) })
        else:
            #res_dict[lst[i]] = lst[i + 1]
            res_list.append({ "testname" : lst[i], "result" : lst[i + 1]
                 })

    #return res_dict
    return res_list
```

```
def remove_elements_from_dictlist(name_of_env, category, dict_list,
    unwanted_elements):# TODO

    if name_of_env in unwanted_elements:
        environment = unwanted_elements[name_of_env]
        if category in environment:
            indices_to_delete = []
            for element in dict_list:
                if element["testname"] in environment[category]:
                    el_index = dict_list.index(element)
                    indices_to_delete = [el_index] + indices_to_delete

            for index in indices_to_delete:
                del dict_list[index]

            return dict_list

        else:
            return []

# main functionality
def parse_to_json(name_of_env, natvers, node, key, date, path):

    all_lines_without_n = get_list_from_NameOfResultView(natvers, node,
        key, date)

    # strip lines and store relevant ones
    all_lines = [x.strip() for x in all_lines_without_n]

    test_results_dict = {}
    test_results_dict["test_categories"] = {}

    dict_of_lines = get_dict_of_lines(all_lines)

    test_categories_list = []

    for key in dict_of_lines:
        tests_of_a_key_list = get_tests_of_a_key_list(dict_of_lines, key
            )

        tests_of_a_key_dictlist = convert_list_to_dictlist(tests_of_a_
            key_list)
        tests_of_a_key_dictlist = remove_elements_from_dictlist(name_of_
            env, key, tests_of_a_key_dictlist, unwanted_tests)

        if tests_of_a_key_dictlist == []:
            continue

        current_category = {"category" : key, "tests" : tests_of_a_key_
            dictlist}
        test_categories_list.append(current_category)
```

```
    test_results_dict['test_categories'] = test_categories_list

    category_stats_list = []
    for category_el in test_results_dict['test_categories']:
        current_category = {}
        this_category = category_el["category"]

        errors = 0
        pending = 0
        crashed = 0
        ignored = 0

        for test_el in category_el["tests"]:
            if this_category in ignored_tests[name_of_env] and test_el["
                testname"] in ignored_tests[name_of_env][this_category]:
                ignored = ignored + test_el["result"]
            elif test_el["result"] == "-":
                pending += 1
            elif test_el["result"] == "CORE":
                crashed += 1
            elif test_el["result"] == "Err":
                errors += 1
            else:
                errors = errors + test_el["result"]

        current_category = {"category" : this_category,
                            "crashed" : crashed,
                            "errors" : errors,
                            "pending" : pending,
                            "ignored" : ignored}

        category_stats_list.append(current_category)

    stats_dict = {}
    stats_dict['test_categories'] = category_stats_list

    # Convert and write JSON object to file
    os.makedirs(os.path.dirname(path), exist_ok=True)
    with open(path, "w") as outfile:
        json.dump(stats_dict, outfile, indent=2)

    print("---   Parsing " + name_of_env + " done   ---")

# ********************************************************************
#           MAIN
# ********************************************************************

# develop
parse_to_json(name_of_env   = "[environment_dev_1]",
              natvers       = "[345]",
              node          = "[machine_name]",
```

```
              key           = "[key]",
              date          = "",
              path          = "../files/dev/[name_of_result_view]_[
                  environment_dev_1].json")
parse_to_json(name_of_env   = "[environment_dev_2]",
              natvers       = "[345]",
              node          = "[machine_name]",
              key           = "[key]",
              date          = "",
              path          = "../files/dev/[name_of_result_view]_[
                  environment_dev_2].json")

# released
parse_to_json(name_of_env   = "[environment_rel_3]",
              natvers       = "[123]",
              node          = "[machine_name]",
              key           = "[key]",
              date          = "",
              path          = "../files/rel/[name_of_result_view]_[
                  environment_rel_3].json")
parse_to_json(name_of_env   = "[environment_rel_4]",
              natvers       = "[234]",
              node          = "[machine_name]",
              key           = "[key]",
              date          = "",
              path          = "../files/rel/[name_of_result_view]_[
                  environment_rel_4].json")

print("---   Program done   ---")
```

B.2 BEISPIEL JSON-OUTPUT VOM PARSER


```
{
  "test_categories": [
    {
      "category": "BUILD",
      "crashed": 0,
      "errors": 0,
      "pending": 0,
      "ignored": 0
    },
    {
      "category": "[test_cat_2]",
      "crashed": 0,
      "errors": 0,
      "pending": 6,
      "ignored": 1
    },
    {
      "category": "[test_cat_3]",
      "crashed": 0,
      "errors": 6,
      "pending": 4,
      "ignored": 34
    },
    {
      "category": "[test_cat_4]",
      "crashed": 0,
      "errors": 10,
      "pending": 12,
      "ignored": 0
    }
  ]
}
```

C

ANHÄNGE ZUR NUTZERBEFRAGUNG

C.1 ABKÜRZUNGSVERZEICHNIS DER NACHFOLGENDEN ISO-INTERAKTIONSPRINZIPIEN

Die Nachfolgenden Abkürzungen wurden aus [Pro06] übernommen:

- aa: Aufgabenangemessenheit
- sb: Selbstbeschreibungsfähigkeit
- ek: Erwartungskonformität
- lf: Erlernbarkeit
- sk: Steuerbarkeit
- ft: Robustheit gegen Nutzungsfehler
- Ik: Nutzerbindung

C.2 BEGRÜNDUNG ZUR AUSFILTERUNG BESTIMMTER FRAGEN AUS DEM FRAGEBOGEN [PRO06]

Nachfolgend wird jeweils die positive Ausprägung der gefilterten Fragen aufgelistet.

Beide Systeme ermöglichen eine einfache Ansicht von Informationen. Die individuelle Arbeitsweise von Personen zur Ansicht beziehungsweise zur Abarbeitung dieser Informationen ist kein Bestandteil dieser Untersuchung. Beide Systeme ermöglichen die benötigte Flexibilität. Daher wurden folgende Fragen aus der Nutzerbefragung entfernt:

- Die Software erzwingt keine unnötig starre Einhaltung von Bearbeitungsschritten. (Sk1)
- Die Software erzwingt keine unnötigen Unterbrechungen der Arbeit. (Sk3)
- Die Software lässt sich von mir gut an meine persönliche, individuelle Art der Arbeitserledigung anpassen. (Ik2)
- Die Software lässt sich - im Rahmen ihres Leistungsumfangs - von mir gut für unterschiedliche Aufgaben passend einrichten. (Ik3)

Es handelt sich für diesen Use-Case (Testpoolmonitoring) ausschließlich um die Ergebnis-Ansicht als Informationsquelle. Es können keine Eingaben getätigt werden. Interaktionen wie die Erweiterung oder Veränderung des Dashboards beziehungsweise der Ansicht sowie weitere administrative Tätigkeiten, die das Framework Grafana ermöglicht, sind kein Teil der täglichen Aufgabe. Daher wurden folgende Fragen aus der Nutzerbefragung entfernt:

- Die Software liefert in zureichendem Maße Informationen darüber, welche Eingaben zulässig oder nötig sind. (sb1)
- Die Software bietet auf Verlangen situationsspezifische Erklärungen, die konkret weiterhelfen. (sb2)
- Die Software informiert in ausreichendem Maße über das, was es gerade macht. (ek2)
- Die Software liefert gut verständliche Fehlermeldungen. (ft1)
- Die Software erfordert bei Fehlern im Großen und Ganzen einen geringen Korrekturaufwand. (ft2)
- Die Software gibt konkrete Hinweise zur Fehlerbehebung. (ft3)
- Die Software lässt sich von mir leicht erweitern, wenn für mich neue Aufgaben entstehen. (lk1)

C.3 GEKÜRZTER FRAGEBOGEN DER NUTZERBEFRAGUNG NACH PRÜMPER

Folgende Fragen wurden übernommen:

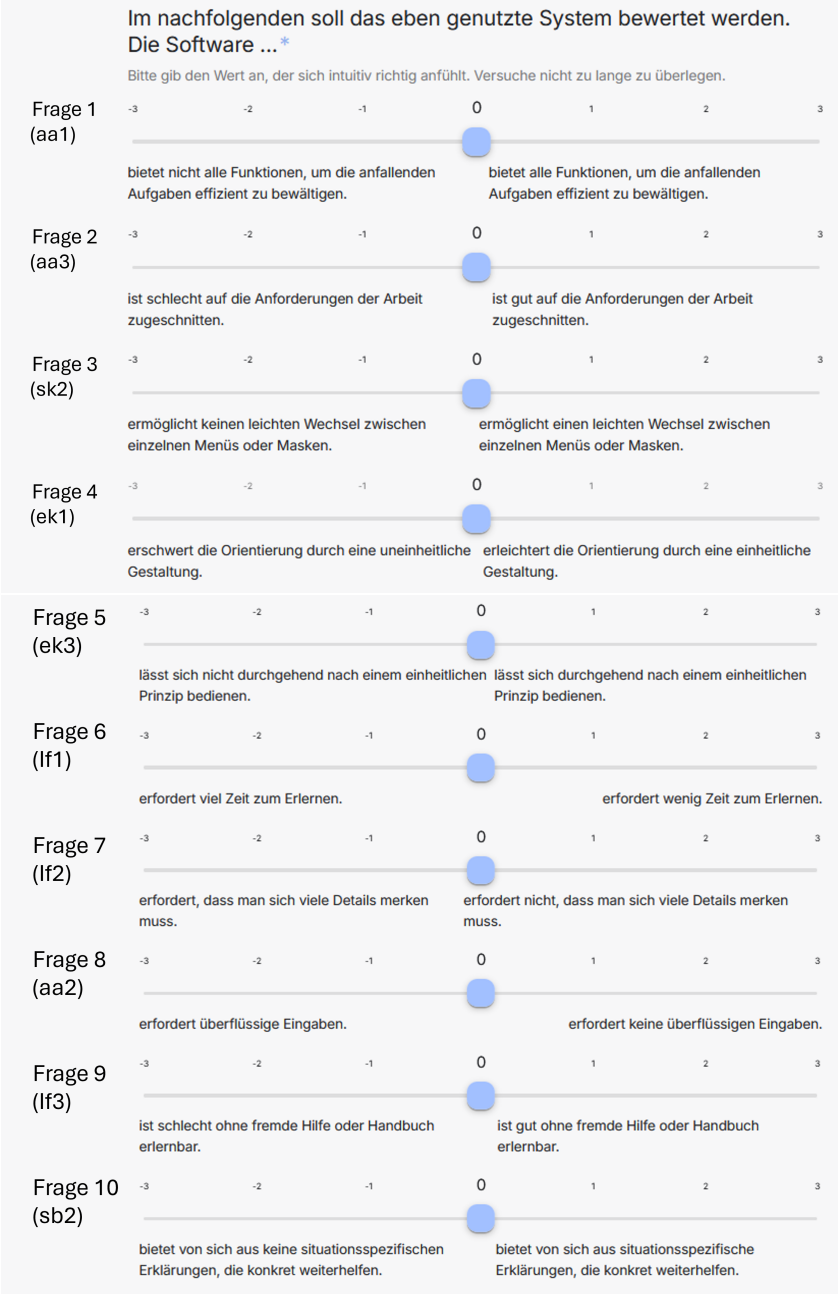


Abbildung C.1: gekürzter Fragebogen nach J. Prümper [Pro06] (Bildschirmaufnahme aus Survio)

C.4 VOLLSTÄNDIGE ERGEBNISSE DER NUTZERBEFRAGUNG

ID			moderierende Variable					Nutzerbefragung nach Prümper																weiteres
	Abfolge						Einsatz-	Frage 1		Frage 2		Frage 3		Frage 4		Frage 5		Frage 6		Frage 7		Frage 8		Frage 9		Frage 10		DB zukünftig
Nr	zuerst	w/m	Alter	Arbeitsdauer	Expertise	Bereich		alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	nutzen
1	alt	w	60+	30+	(fast) täglich	ja		2	0	2	-1	2	-1	2	-2	3	1	3	-1	2	1	3	3	3	-1	2	-1	-2
2	alt	m	50-59	30+	(fast) täglich	ja		2	3	3	3	3	3	3	2	3	3	1	3	0	2	3	3	1	2	1	2	2
3	alt	w	50-59	30+	(fast) täglich	ja		1	1	1	1	1	0	2	0	3	2	3	3	2	1	3	2	3	3	2	0	1
4	alt	m	60+	30+	(fast) täglich	eher nein		-1	2	-1	2	0	1	0	2	-2	2	0	2	-1	2	0	0	-1	3	-2	2	2
5	alt	m	60+	30+	regelmäßig	nein		1	2	1	2	0	1	-1	3	-1	3	-1	1	-2	1	---	2	-2	2	---	---	2
6	alt	m	30-39	1 - 5	(fast) täglich	nein		-2	1	1	1	-2	2	0	2	2	2	-3	2	-3	2	1	3	-3	3	-3	-1	1
7	alt	m	60+	30+	(fast) täglich	eher nein		2	3	2	2	2	2	2	2	2	3	-1	2	1	2	1	3	2	2	-2	3	2
8	neu	w	60+	30+	(fast) täglich	nein		-3	3	-3	3	-2	2	-3	0	-3	2	-3	3	-2	3	-1	3	-1	3	-3	2	2
9	neu	m	60+	30+	regelmäßig	nein		-2	3	-2	3	-1	3	-3	3	1	3	0	3	-3	3	0	3	---	3	-1	3	2
10	neu	m	60+	30+	unregelmäßig	nein		-1	1	-2	1	-1	2	-2	2	-1	2	-1	1	-1	1	1	2	-2	2	-1	1	1
11	neu	m	50-59	21 - 30	(fast) täglich	eher ja		-1	-2	1	-1	2	-1	-3	2	1	2	-2	2	-2	1	1	1	-2	1	-2	1	-2
über alle Werte						Mittelwert		-0,2	1,55	0,27	1,45	0,36	1,27	-0,3	1,45	0,73	2,27	-0,4	1,91	-0,8	1,73	1,2	2,27	-0,2	2,09	-0,9	1,2	1
						MW neu-alt		1,7273		1,1818		0,9091		1,7273		1,5455		2,2727		2,5455		1,0727		2,2909		2,1000		---
					deskriptive Analyse	Median		-1	2	1	2	0	2	0	2	1	2	-1	2	-1	2	1	3	-1	2	-1,5	1,5	2
						Abweichung		1,75	1,5	1,86	1,37	1,67	1,35	2,18	1,44	2,05	0,62	1,97	1,16	1,75	0,75	1,33	0,96	2,14	1,16	1,81	1,4	1,4771
					interferenzstatistische Analyse	t-Test		0,0195		0,0949		0,1387		0,0487		0,0231		0,0087		0,0021		0,0286		0,0210		0,0199		0,0290
neu zuerst						Mittelwert		0,71	1,71	1,29	1,43	0,86	1,14	1,14	1,29	1,43	2,29	0,29	1,71	-0,1	1,57	1,83	2,29	0,43	2	-0,3	0,83	1,1429
					deskriptive Analyse	Abweichung		1,48	1,03	1,16	1,18	1,55	1,25	1,36	1,58	1,92	0,7	2,05	1,28	1,81	0,49	1,21	1,03	2,26	1,31	2,05	1,57	1,3553
					interferenzstatistische Analyse	t-Test		0,0887		0,4191		0,3679		0,4473		0,1850		0,1143		0,0432		0,1816		0,1310		0,2056		0,0422
alt zuerst						Mittelwert		-1,8	1,25	-1,5	1,5	-0,5	1,5	-2,8	1,75	-0,5	2,25	-1,5	2,25	-2	2	0,25	2,25	-1,7	2,25	-1,8	1,75	0,75
					deskriptive Analyse	Abweichung		0,83	2,05	1,5	1,66	1,5	1,5	0,43	1,09	1,66	0,43	1,12	0,83	0,71	1	0,83	0,83	0,47	0,83	0,83	0,83	1,6394
					interferenzstatistische Analyse	t-Test		0,0770		0,0952		0,1601		0,0030		0,0243		0,0109		0,0110		0,0581		0,0041		0,0062		0,2430

Tabelle C.1: aufgezeichnete Daten der Nutzerbefragung

Frage 1	$\bar{x}$	$\tilde{x}$	σ
alt	-0,2	-1	1,75
neu	1,55	2	1,5

Frage 2	$\bar{x}$	$\tilde{x}$	σ
alt	0,27	1	1,86
neu	1,45	2	1,37

Frage 3	$\bar{x}$	$\tilde{x}$	σ
alt	0,36	0	1,67
neu	1,27	2	1,35

Frage 4	$\bar{x}$	$\tilde{x}$	σ
alt	-0,3	0	2,18
neu	1,45	2	1,44

Frage 5	$\bar{x}$	$\tilde{x}$	σ
alt	0,73	1	2,05
neu	2,27	2	0,62

Frage 6	$\bar{x}$	$\tilde{x}$	σ
alt	-0,4	-1	1,97
neu	1,91	2	1,16

Frage 7	$\bar{x}$	$\tilde{x}$	σ
alt	-0,8	-1	1,75
neu	1,73	2	0,75

Frage 8	$\bar{x}$	$\tilde{x}$	σ
alt	1,2	1	1,33
neu	2,27	3	0,96

Frage 9	$\bar{x}$	$\tilde{x}$	σ
alt	-0,2	-1	2,14
neu	2,09	2	1,16

Frage 10	$\bar{x}$	$\tilde{x}$	σ
alt	-0,9	-1,5	1,81
neu	1,2	1,5	1,4

verwendete Formelzeichen:

- $\bar{x}$ Mittelwert
- $\tilde{x}$ Median
- σ Standardabweichung

Tabelle C.2: Zusammenfassung der Ergebnisse der Nutzerumfrage (Weiterverarbeitung der Daten aus Tabelle C.1)

C.5 HISTOGRAMME DER DIFFERENZEN

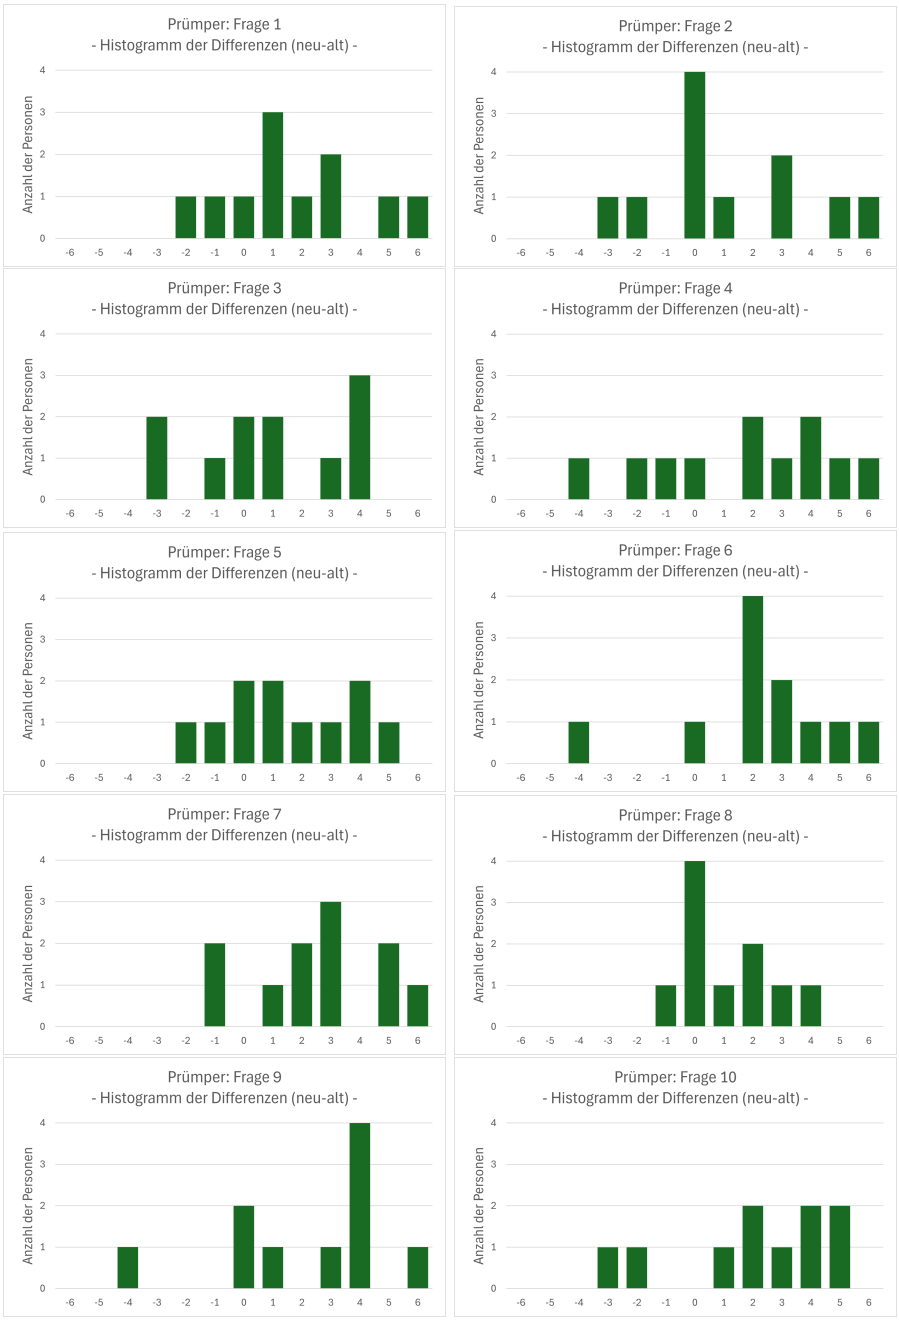


Abbildung C.2: Histogramme mit den Differenzen neu-alt der Nutzerbefragung

C.6 WIEDERHOLUNG DES SIGNIFIKANZTESTS NACH ENTFERNUNG DER EXTREMA

ID	moderierende Variable							Nutzerbefragung nach Prümper																				weiteres
	Nr	Abfolge zuerst	w/m	Alter	Arbeitsdauer	Expertise	Einsatz-Bereich	Frage 1		Frage 2		Frage 3		Frage 4		Frage 5		Frage 6		Frage 7		Frage 8		Frage 9		Frage 10		DB zukünftig nutzen
								alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	alt	neu	
	2	alt	m	50-59	30+	(fast) täglich	ja	2	3	3	3	3	3	3	2	3	3	1	3	0	2	3	3	1	2	1	2	2
	3	alt	w	50-59	30+	(fast) täglich	ja	1	1	1	1	1	0	2	0	3	2	3	3	2	1	3	2	3	3	2	0	1
	4	alt	m	60+	30+	(fast) täglich	eher nein	-1	2	-1	2	0	1	0	2	-2	2	0	2	-1	2	0	0	-1	3	-2	2	2
	5	alt	m	60+	30+	regelmäßig	nein	1	2	1	2	0	1	-1	3	-1	3	-1	1	-2	1	---	2	-2	2	---	---	2
	6	alt	m	30-39	1 - 5	(fast) täglich	nein	-2	1	1	1	-2	2	0	2	2	2	-3	2	-3	2	1	3	-3	3	-3	-1	1
	7	alt	m	60+	30+	(fast) täglich	eher nein	2	3	2	2	2	2	2	2	2	3	-1	2	1	2	1	3	2	2	-2	3	2
	8	neu	w	60+	30+	(fast) täglich	nein	-3	3	-3	3	-2	2	-3	0	-3	2	-3	3	-2	3	-1	3	-1	3	-3	2	2
	9	neu	m	60+	30+	regelmäßig	nein	-2	3	-2	3	-1	3	-3	3	1	3	0	3	-3	3	0	3	---	3	-1	3	2
	10	neu	m	60+	30+	unregelmäßig	nein	-1	1	-2	1	-1	2	-2	2	-1	2	-1	1	-1	1	1	2	-2	2	-1	1	1
über alle Werte							Mittelwert	-0,3	2,11	0	2	0	1,78	-0,2	1,78	0,44	2,44	-0,6	2,22	-1	1,89	1	2,33	-0,4	2,56	-1,1	1,5	1,6667
							MW neu-alt	2,4444		2,0000		1,7778		2,0000		2,0000		2,7778		2,8889		1,3333		2,9306		2,6250		---
						deskriptive Analyse	Median	-1	2	1	2	0	2	0	2	1	2	-1	2	-1	2	1	3	-1	3	-1,5	2	2
							Abweichung	1,76	0,87	1,94	0,82	1,63	0,92	2,1	1,03	2,11	0,5	1,77	0,79	1,63	0,74	1,32	0,94	2	0,5	1,69	1,32	0,4714
						interferenzstatistische Analyse	t-Test	0,0032		0,0169		0,0138		0,0249		0,0111		0,0008		0,0022		0,0272		0,0041		0,0085		0,000004
alt zuerst							Mittelwert	0,5	2	1,17	1,83	0,67	1,5	1	1,83	1,17	2,5	-0,2	2,17	-0,5	1,67	1,6	2,17	0	2,5	-0,8	1,2	1,6667
						deskriptive Analyse	Abweichung	1,5	0,82	1,21	0,69	1,6	0,96	1,41	0,9	1,95	0,5	1,86	0,69	1,71	0,47	1,2	1,07	2,16	0,5	1,94	1,47	0,4714
						interferenzstatistische Analyse	t-Test	0,0150		0,1177		0,1446		0,2009		0,0955		0,0086		0,0241		0,1870		0,0293		0,0889		0,0003
neu zuerst							Mittelwert	-2	2,33	-2,3	2,33	-1,3	2,33	-2,7	1,67	-1	2,33	-1,3	2,33	-2	2,33	0	2,67	-1,5	2,67	-1,7	2	1,6667
						deskriptive Analyse	Abweichung	0,82	0,94	0,47	0,94	0,47	0,47	0,47	1,25	1,63	0,47	1,25	0,94	0,82	0,94	0,82	0,47	0,5	0,47	0,94	0,82	0,4714
						interferenzstatistische Analyse	t-Test	0,0345		0,0170		0,0041		0,0195		0,0317		0,0464		0,0345		0,0471		#DIV/0!		0,0266		0,0189

Tabelle C.3: aufgezeichnete Daten der Nutzerbefragung nach Entfernung der Extrema (Ausschnitt aus Tabelle C.1)

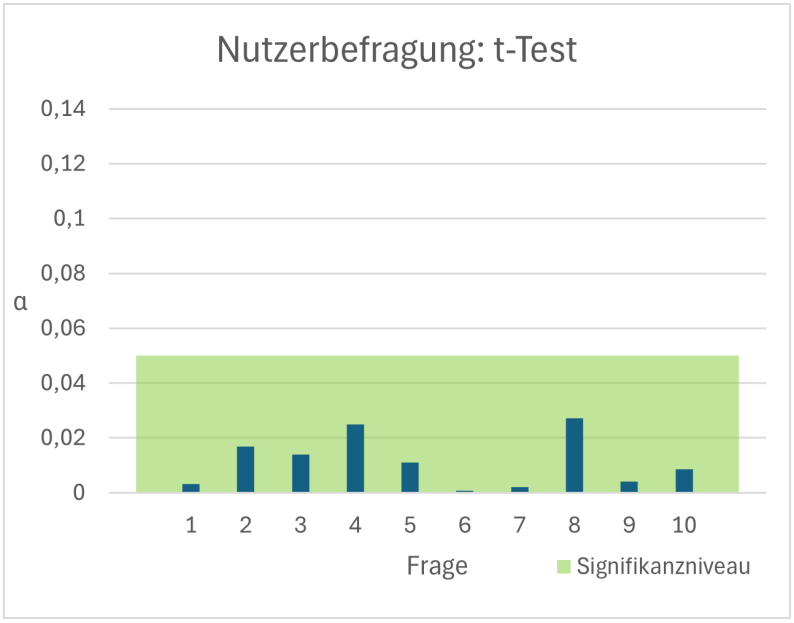


Abbildung C.3: Signifikanzbewertung der Ergebnisse der Nutzerbefragung nach Entfernung der Extrema (Daten aus Tabelle C.3)

D

ANHÄNGE ZUM USABILITY-TEST

D.1 VOLLSTÄNDIGER AUFGABENKATALOG DES USABILITY-TESTS

Aufgabe 1	Haben wir heute einen Green Day im [Modus] der Dev-Version ([Maschine])? Wenn nein, warum?
Aufgabe 2	Wie viele BUILD-Fehler weisen die Dev-Versionen auf?
Aufgabe 3.1	Wie viele Fehler weist die [test_cat_3] in der älteren releasten Version [Nr] auf?
Aufgabe 3.2	... und in der neueren [Nr]?
Aufgabe 4.1	Wie viele Tests (Test-Kategorien) sind in der (Dev) [test_cat_4] im [Modus 1] noch nicht gelaufen?
Aufgabe 4.2	... und im [Modus 2]?

D.2 BEGRÜNDUNG ZUR AUSWAHL UND REIHENFOLGE DER AUFGABEN DES USABILITY-TESTS

Legende: AS – altes System; DB – Dashboard
Vorgabe: alle benötigten Links zu den abgefragten Oberflächen

- im AS (tagesaktuell): 2x Develop, 2x Release
- auf dem DB (äquivalenter Inhalt mit gemockten Werten): 1x Develop, 1x Release

Ziel: Abdeckung des Tagesgeschäfts sowie der Inhalte der Nutzerbefragung zur anschließenden Bewertung der Eignung

- Frage 1, 2, 6, 7, 8, 9 und 10 - zur allgemeinen Einschätzung
- Frage 4 - in Form von verschiedenen Aufgabentypen zur Darstellung der Uneinheitlichen Gestaltung des alten Systems
- Die Fragen 3 und 5 - anhand der Systemwechsel zu Aufgabe 3 und 4

Aufgabe 1

- Begründung: Dieser Status wird täglich abgefragt.
- Aufgabe: Haben wir heute einen Green Day im [Modus] der Dev-Version ([Maschine])?
  Wenn nein, warum?
- erfragtes Ergebnis
  - AS: Überblick auf zwei Oberflächen, ob rote Felder mit ‚ERR' oder Zahlen != Null
  - DB: je ein roter Wert in zwei Reihen zum Ablesen
- Ziel:
  - Start einer Diskussion, da die Aufgabe 2 mögliche Lösungen hat
  - Aufmerksamkeit auf Ungenauigkeit im alten System lenken

Aufgabe 2

- Begründung: das Ausbleiben von Baufehlern ist kritisch zur Ausführbarkeit weiterer Tests
- Aufgabe: Wie viele BUILD-Fehler weisen die Dev-Versionen auf?
- erfragtes Ergebnis
  - AS: Ergebnis ist in mehreren Bereichen als Zahlenwert dargestellt
    –> Überblick über 2 Oberflächen und verrechnen der Werte
    –> abgefragte Werte sind nicht farbig hervorgehoben
  - DB: Ergebnis ist als jeweils ein roter Zahlenwert in zwei Zeilen dargestellt
    –> Verrechnen der Werte
- Ziel:
  - Abfrage eines weiteren Wertes
  - Überblick über 2 Systeme
  - im alten System ist zumeist der Wert Null dargestellt
    –> Überprüfung, wie leicht Fehleranzeigen übersehen werden können

Aufgabe 3

- Begründung: Wechsel der Oberfläche
  - Grundlage für die Fragen 3 und 5 der Nutzerbefragung (s.Abbildung C.1)
  - in Aufgabe 4 der Wechsel zurück auf die erste Oberfläche
    –> es wird hier gewechselt, damit der Wechsel zweimal erfolgt, um zu testen, ob der neu erlernte Wechsel direkt erneut angewendet werden kann
- Aufgaben:
  - 3.1: Wie viele Fehler weist die [test_cat_3] in der älteren releasten Version [Nr] auf?
  - 3.2: ... und in der neueren [Nr]?
- erfragtes Ergebnis
  - AS: erfordert das Zusammenzählen / -rechnen mehrerer Zahlenwerte einer Kategorie
    –> keine Zahlenangabe, wie viele Tests gut gelaufen sind
    –> abgefragte Werte sind nicht farbig hervorgehoben
  - DB: Ablesen eines roten Zahlenwertes
- Ziel:
  - Wechsel der allgemeinen Oberfläche, um zu testen ob die neue Ansicht mit dem 2. Dashboard intuitiv verstanden wird
    –> Testen der Merk- und Navigationsfähigkeit (Erlernbarkeit)
  - Aufmerksamkeit lenken auf Erlangung der Ergebnisse auf dem anderen System

Aufgabe 4

- Begründung: Auswertung einer weiteren Kategorie, wieder auf dem ersten System
- Aufgaben:
  - 4.1: Wie viele Tests (Test-Kategorien) sind in der (Dev) [test_cat_4] im [Modus 1] noch nicht gelaufen?
  - 4.2: ... und im [Modus 2]?
- erfragtes Ergebnis
  - AS: erfordert das Zusammenzählen von der Fehleranzeige '-' einer Kategorie
    –> keine Zahlenangabe, wie viele Tests gut / nicht gut gelaufen sind, nur ob die Testsammlung insgesamt Fehler hat oder nicht
    –> abgefragte Werte sind nicht farbig hervorgehoben
  - DB: Ablesen eines gelben Zahlenwertes
- Ziel:
  - Wechsel der allgemeinen Oberfläche zurück zur ersten verwendeten Oberfläche
    –> Aufmerksamkeit lenken auf Erlangung der Ergebnisse auf dem ersten System
  - Es wird nicht der rot hervorgehobene Fehlerstatus 'Err' (AS) oder 'errors' (DB) erfragt, sondern der nicht hervorgehobene '-' (AS) bzw. gelbe Fehlerstatus 'pending' (DB)
    * Ablenkung durch andere Werte ist gegeben
    * Aufmerksamkeit darauf lenken, dass Ergebnisse im AS teilweise nur umständlich erreicht werden können
    * Überprüfen, ob Fehler durch Unübersichtlichkeit entstehen

D.3 VOLLSTÄNDIGE ERGEBNISSE DES USABILITY TEST

ID			moderierende Variable					Usability-Test																								
								Aufgabe 1				Aufgabe 2				Aufgabe 3.1				Aufgabe 3.2				Aufgabe 4.1				Aufgabe 4.2			
								alt		neu		alt		neu		alt		neu		alt		neu		alt		neu		alt		neu	
Nr	Abfolge zuerst	w/m	Alter	Arbeitsdauer	Expertise	Einsatz-Bereich		c	t	c	t	c	t	c	t	c	t	c	t	c	t	c	t	c	t	c	t	c	t	c	t
1	alt	w	60+	30+	(fast) täglich	ja		//	42	o	13	o	5	x	7	x	---	o	23	o	3	o	7	o	12	o	32	o	6	o	9
2	alt	m	50-59	30+	(fast) täglich	ja		//	8	o	11	o	9	o	8	o	7	x	13	o	2	x	4	x	18	o	9	o	17	o	7
3	alt	w	50-59	30+	(fast) täglich	ja		//	8	x	7	o	8	x	---	o	12	o	23	o	6	o	8	o	14	o	11	o	5	o	7
4	alt	m	60+	30+	(fast) täglich	eher nein		//	14	o	4	o	10	o	6	o	19	o	9	o	6	o	4	x	31	o	7	o	12	o	5
5	alt	m	60+	30+	regelmäßig	nein		//	6	o	6	o	13	o	5	o	14	o	11	o	8	o	4	x	26	o	23	o	6	o	13
6	alt	m	30-39	1 - 5	(fast) täglich	nein		//	13	o	7	o	9	o	3	o	25	x	10	o	20	x	1	o	18	o	2	o	4	o	3
7	alt	m	60+	30+	(fast) täglich	eher nein		//	14	o	7	o	12	o	6	o	20	o	5	o	14	o	3	o	15	x	7	o	11	x	7
8	neu	w	60+	30+	(fast) täglich	nein		//	24	o	17	o	9	o	8	o	12	o	15	o	10	o	3	o	20	o	17	x	28	o	6
9	neu	m	60+	30+	regelmäßig	nein		//	13	o	12	o	32	x	3	o	15	x	11	o	9	x	8	x	26	o	12	o	15	o	19
10	neu	m	60+	30+	unregelmäßig	nein		//	6	o	9	o	33	x	11	o	27	x	6	o	16	x	12	x	37	o	24	o	24	o	12
11	neu	m	50-59	21 - 30	(fast) täglich	eher ja		//	29	o	12	o	10	o	8	o	10	o	2	o	5	o	5	o	18	o	23	x	7	o	5
über alle Werte					deskriptive Analyse		Mittelwert		16		9,5		14		6,5		16		12		9		5,4		21		15		12		8,5
							MW neu-alt		-6,5455				-7,1364				-4,4636				-3,6364				-6,1818				-3,8182		
							Median		13		9		10		6,5		15		11		8		4		18		12		11		7
							Abweichung		11		3,6		9,1		2,3		6,2		6,4		5,4		3		7,4		8,8		7,7		4,4
					interferenzstatistische Analyse		T-Test		0,0232				0,0186				0,0579				0,0506				0,0554				0,0826		
alt zuerst					deskriptive Analyse		Mittelwert		15		7,9		9,4		5,8		16		13		8,4		4,4		19		13		8,7		7,3
							Abweichung		11		2,8		2,4		1,6		5,9		6,5		5,9		2,2		6,4		9,8		4,4		2,9
					interferenzstatistische Analyse		T-Test		0,0630				0,0262				0,1891				0,1249				0,1406				0,2749		
					deskriptive Analyse		Mittelwert		18		13		21		7,5		16		8,5		10		7		25		19		19		11
							Abweichung		9		2,9		12		2,9		6,6		4,9		3,9		3,4		7,4		4,8		8,1		5,6
neu zuerst					interferenzstatistische Analyse		T-Test		0,1477				0,0762				0,1168				0,0770				0,1294				0,1280		
							Anzahl Fehler				1		0		4		2		4		2		4		5		1		2		1

Tabelle D.1: aufgezeichnete Daten des Usability-Tests

Aufgabe 1	$\bar{x}$	$\tilde{x}$	σ	f
alt	16	13	11	0%
neu	9,5	9	3,6	9,09%

Aufgabe 2	$\bar{x}$	$\tilde{x}$	σ	f
alt	14	10	9,1	0%
neu	6,5	6,5	2,3	30%

Aufgabe 3.1	$\bar{x}$	$\tilde{x}$	σ	f
alt	16	15	6,2	0%
neu	12	11	6,4	36,36%

Aufgabe 3.2	$\bar{x}$	$\tilde{x}$	σ	f
alt	9	8	5,4	0%
neu	5,4	4	3	36,36%

Aufgabe 4.1	$\bar{x}$	$\tilde{x}$	σ	f
alt	21	18	7,4	45,45%
neu	15	12	8,8	9,09%

Aufgabe 4.2	$\bar{x}$	$\tilde{x}$	σ	f
alt	12	11	7,7	18,18%
neu	8,5	7	4,4	9,09%

verwendete Formelzeichen:

- $\bar{x}$ Mittelwert
- $\tilde{x}$ Median
- σ Standardabweichung
- f Fehlerquote

Tabelle D.2: Zusammenfassung der Ergebnisse des Usability-Tests (Weiterverarbeitung der Daten aus Tabelle D.1)

Aufgabe	1	2	3.1	3.2	4.1	4.2
$\varnothing t_{neu} - \varnothing t_{alt}$	-6,55	-7,14	-4,46	-3,64	-6,18	-3,81
t-Test	0,0231	0,0186	0,0579	0,0506	0,0554	0,0826

Tabelle D.3: Usability Test - Differenz der Zeitmittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle D.2)

	1	2	3.1	3.2	4.1	4.2	$\varnothing$	t-Test
alt	0%	0%	0%	0%	45,45%	18,18%	10,61%	0,1989
neu	9,09%	30%	36,36%	36,36%	9,09%	9,09%	21,67%	

Tabelle D.4: Usability Test - Fehlerquoten, -mittelwerte und t-Test-Ergebnisse (Weiterverarbeitung der Daten aus Tabelle D.2)

	1	2	3.1	3.2	4.1	4.2	tTest
alt	16,0909	13,6364	16,1	9	39,16667	15	0,0720
neu	10,5	9,2857	18,2857	8,4286	16,7	9,3	
Verhältnis*	53,25%	46,85%	-11,95%	6,78%	134,53%	61,29%	0,0336

Tabelle D.5: Usability-Test - Effizienzbewertung der Systeme im Verhältnis zueinander (Weiterverarbeitung der Daten aus Tabelle D.1 anhand der Formel zur Effizienzberechnung)

*Dashboard im Vergleich zum alten System

E

MITSCHRIFTEN VON MITARBEITERAUSSAGEN WÄHREND DER BEFRAGUNG UND DES USABILITY-TESTS

Hinweis: Da diese Mitschriften live während der Durchführung des Versuchs angefertigt wurden, existiert keine Garantie auf Vollständigkeit aller Aussagen.

```
Zusammenfassung: Feedback / Wünsche für das Dashboard:
- Security Error beim öffnen von Grafana
- die letzte Spalte [test_cat_5] kann statt des Kürzels Namen [...]
    bekommen - ID 4
- 2. Dashboard wurde oft nicht wahrgenommen / vergessen / nicht mehr
    gefunden später
- die ignorierten Werte können aus der Ansicht rausgenommen werden
- Layout verrutscht bei größeren Werten (Bsp.: "529", "crashed")
- Tree-verwöhnt - "warum werden die  anderen Dashboards nicht als tree
    angezeigt?"
  --> Breadcrumbs/Pfadangabe reichen nicht aus
- DB-Benennung (dev) aus dem alten System übernommen -> aktuelle Version
    !
- Darkmode - gibts Grafana im Lightmode?
- hellgrauen Kasten um die zusammengehörigen Zahlen einer Kategorie
    machen
- Datumsauswahl gibt es schon
  --> ABER: wie sich das Ergebnis von gestern auf heute geändert hat
      (nicht aber von gestern auf vorgestern)
  --> allgemein Verlaufsgrafiken der letzten 14 Tage
- Grafiken einbauen, statt nur Zahlen
  --> erst ab Verlaufsdaten möglich

=======

Zusammenfassung: Green Day (Aufgabe 1) Begründungen:
- nein
  --> es sind nicht alle Tests grün / 0 / fehlerfrei
- ja
  --> bekannte Fehler - Bsp. Timingproblem in der Testumgebung
  --> TUI Umgebung wird nicht beachtet (sehr instabile Tests)
  ==> Wissen benötigt, was ignoriert werden darf - es sollte langfristig
       lieber die Testumgebung aufgeräumt werden

=======

Testperson 1:
-------------
altes System:
- nutzt das seit 30+ Jahren
```

```
- "ich mache mir jeden Morgen 20 [Oberflächen / Tabs] auf" - "komme in 3
     Minuten durch"
  --> muss täglich viele der Ergebnisse durchschauen
  --> ist mit für die Wartung zuständig
- seit 2023 haben die Kollegen was noch nicht gefixt - Verschiebung
- "ich habe eine Vorgehensweise wie ich das alles lese"
  --> "fotografischer Blick"
Dashboard:
- "ich muss wirklich lesen, ich habe den Eindruck, dass ich sonst nicht
    mehr lese, wenn ich die [Oberflächen des alten System] durchgucke"
- "das ist jetzt in Spalten angeordnet, was vorher in Zeilen war"

Testperson 2:
-------------
- macht das noch länger als [Testperson 1]
altes System:
- Green Day: "nach den Regeln der Kunst nein, aber mit beiden Augen zudr
    ücken ja"
- Anfang war nur die BUILD-Kategorie
  --> ist immer weiter gewachsen, man übersieht auch gerne mal eine Zahl
  --> für den groben Überblick gut geeignet
Dashboard:
- gut, irritiert hat: das Zeilen Spalten vertauscht sind
- deutlich einfacher, als das andere, ob noch Tests fehlen
- durch das simplifizieren der Ausgabe

Testperson 3:
-------------
altes System:
- ist ein Green Day mit Spezialwissen
- 30 Jahre mit [altes System] und Jenkins
- standardmäßig 5 Tabs (nächtlich laufend) - auf den ersten Blick
    bearbeitbar
- "viele alte Information und vieles führt ins Leere"
Dashboard:
- neues Dashboard natürlich erstmal gewöhnungsbedürftig
- Dashboard hat verwirrt, ist einiges an Information drauf
  --> viele Information die man vorher (im [altes System]) erstmal nicht
      beachtet/ausblendet
  --> man muss sich neu daran gewöhnen
- Zahlen sind sehr groß (man sieht zu wenig auf einmal)

Testperson 4:
-------------
altes System:
- Green Day - kann er nicht eindeutig erkennen
  --> nur [Testperson 3] weiß ob angezeigte Fehler in [test_cat_4] eine
      Relevanz haben
  --> genauso bei einem anderen System [kein Part des untersuchten Use-
      Cases]
  --> ohne das Wissen ist kein Green Day
```

```
- Maskenwechsel: "ich mache das mit den Tabs da geht das relativ schnell
    "
  --> gemeint: Tableiste ist links im Browser - Tabs untereinander
      aufgelistet
  --> Anmerkung Autorin: "ja aber sind viele Tabs und alle kryptisch
      benannt"
- hat für jede Version den Testpool abgespeichert
  --> auf VM, läuft 24/7
  --> ist alles gruppiert in Lesezeichen
Dashboard:
- "ist man gar nicht gewohnt so ein Comfort"
- wenn man in einem Dashboard ist sieht man die anderen nicht
  --> es gibt keine Tree-Funktonion, aber Breadcrumbs sind da
- schnell erlernbar, nicht vergleichbar
- wenn man sich 1-2 Tage einfindet, ist es super
- Wunsch: Overview über die einzelnen Versionen und deren aktuellen
    Zustand
  --> in der DB Liste: Overview OK oder nicht [wurde noch nicht geprüft
      ob technisch umsetzbar]

Testperson 5:
-------------
altes System:
- Green Day: sieht ok aus, nur die [test_cat_4] Tests - ja
Dashboard:
- findet gut dass man sich die Rechner nicht merken muss
- das Dashboard zu haben findet er gut
  --> Farbcodierung
  --> einheitliche UI/Navigieren
  --> filtert die unwichtigen Details aus
  --> anders sortiert, leichter zu verstehen
- "Darkmode mögen jüngere lieber"
- Grafiken einbauen, statt nur Zahlen
  --> erst ab Verlaufsdaten sinnvoll möglich - noch nicht implementiert

Testperson 6:
-------------
altes System:
- wenn rot ist das kein GreenDay
  --> er arbeitet aber auch nicht damit [mit explizit diesem System,
      aber dem Testpool], kann das nicht einschätzen
- eigentlich müsste man die Sachen kontinuierlich verbessern, als das es
    irgendwann heißt jetzt ein halbes Jahr um alles Umzukrempeln
  --> er hätte statt einem Executable einen REST mit React irgendwie
      geschrieben, was das von sich aus schon anders aufbaut
Dashboard:
- Beschreibung der Versionen ist besser
  --> statt Keys, oder Maschinen durchklickt
- Wunsch: soll man direkt drauf kommen von der Startseite, nicht erst ü
    ber den Reiter
  --> Anmerkung Autorin: wird Grafana aufgerufen, muss sich (nach
      aktuellem Stand) zuerst angemeldet werden, dann den Reiter "
```

```
      Dashboards" auswählen und schließlich das richtige Dashboard aus
      der Liste (bestehend aus aktuell 2 DBs) anklicken
- man erkennt dass es ein Framework ist, mit dem man einiges mehr machen
     kann
  --> die Werbung ist unschön

Testperson 7:
-------------
altes System:
- Green Day: ja, aber ist eine Definitionsfrage
-> kommt auf die erfahrung an -> build, Batch und wichtige Tests waren
    ok
-> nur unwichtige und bekannte tests waren rot
neues System:
- findet gut:
  --> Farbgebung gut - Errors rot und pending so gelb-artig (Modi gut
      unterscheidbar)
  --> [altes System] muss man 2x klicken, deswegen DB besser
  --> aufklappen / reihen, findet er gut, geht im scresult nicht (war
      damals vor 20 Jahren Top-aktuell)
- Zahlen kleiner machen, dass man die 2 Modi nebeneinander / auf einen
    Blick sieht
  --> Anmerkung Autorin: ist via zoom machbar, dass 2 Reihen auf einmal
      sichtbar sind

Testperson 8:
-------------
- ist eher für [anderes System; kein Part des Use-Case] verantwortlich,
    kennt sich nur grob aus
altes System:
- Green Day: nein "Tests haben err"
  --> weil es rot leuchtet
- scresult Codes sind random, weiß man nicht
  --> hat die Links als Shortcuts und richtig benannt, macht das
      Dashboard besser
  --> Anmerkung Autorin: "Codes" = [altes System: Version, Maschine_1]
Dashboard:
- intuitivere Titel für Reihen, statt Codes (s. altes System)
- untersch. DBs waren nicht direkt ersichtlich, aber mit mehr Praxis,
    gewöhnt man sich dran

Testperson 9:
-------------
altes System:
- Green Day: viele Sachen laufen immer rot
  --> bedeutet nein, weil 4 Fehler / rote Anzeigen
    ----> GD = wenn die Seite green ist oder muss anders definiert sein
    ----> wenn was nicht wichtig wäre müsste es eigentlich rausgenommen
        werden
  --> "ich als Laie, würde das sagen"
- "es tendieren manche dazu, wenn ein Test länger rot ist, ihn zu
    ignorieren"
```

```
- esotherische Tests, die noch nie eine Rolle gespielt haben
  --> beim Kunden läuft es seit Jahrzehnten stabil, muss man pragmatisch
      sehen
  --> unterscheiden zwischen:
    ----> fehlerhaften Tests, die nicht einfach zu fixen sind
    ----> und den Altlasten, die seit Jahren nicht angefasst wurden und
        "ignoriert" werden können
- Umfrage: "das ist fies" [die bekannten / ignorierten Probleme so
    offensichtlich abzufragen]
  --> bekannte / offensichtliche / ignorierte Probleme
  --> neues Tool ist herausgehoben
Dashboard:
- DB sehr gut / übersichtlich, aber man muss sich einarbeiten
- Abkürzungen sind gewöhnungsbedürftig, wenn man nicht regelmäßig damit
    arbeitet
  --> [soll teilweise noch durch bessere Begriffe ausgetauscht werden]
- "ignored" evtl. auf neuen Tab, nimmt zu viel Platz weg für die Ü
    bersicht

Testperson 10:
--------------
altes System:
- kein Green Day
  --> das ist rot, also muss Fehler

Testperson 11:
--------------
- es gibt 2 Maschinen
  --> nur das was auf der [Maschine 1] gebaut wird, wird an den Kunden
      ausgeliefert
  --> [Maschine 2] ist nur für die Tests
  --> Anmerkung Autorin: diese wurden hier als Modi bezeichnet, da zwei
      verschiedene Modi auf jeweils einer der Maschinen getestet wird
altes System:
- Green Day: unwahrscheinlich -> Fehler + CORE
  --> "ich müsste es als GreenDay bewerten" - auch wenn es das nicht ist
- Aufgabe 3: Kategorie gemeint - einer der Tests wurde angesehen
  --> wenn [Test] faul ist, braucht man die anderen nicht mehr angucken
  --> bauen auf dem ersten auf
- macht jeden Tag 14 Tabs auf
  --> befasst sich mehr mit den Windows-Tests, nicht so sehr mit dem Use
      -Case
  --> "das gefällt mir mit den Tabs gut, dass mache ich immer so"
- [Fehler]: ist seit 20 Jahren, kommt immer mal an einer anderen Stelle
    auf
  --> kommt fast jeden Tag
- jeder [Test-Prozess], muss seine Ergebnisse selber auf die Seite in
    Text schreiben
  --> braucht etwas zu lange, können sie sich die Ergebnisse gegenseitig
      wegschreiben
- altes System = results von source-control
  --> das ist ein ganz dummes Tool, das macht nicht viel
```

Dashboard:
- Übergang zwischen Dashboards: "finde ich schwierig: ein Dashboard ist offen, [das andere] gar nicht mehr im Blick gehabt"
- Namen brauchen viel Platz
- [Modus-Namen] nicht so geläufig - eher verwirrend gewesen
- kann die Hilfe nicht geben, die es bräuchte, um die Tests auszuwerten
  --> Unterschied zum Vortag
- 2 Fehler hast du immer
  --> nicht direkt erkennbar, ob relevant oder nicht [Anmerkung Autorin: dann sollte die Umgebung angepasst werden]
  --> Liste der deaktivierten Tests (Konzept funktioniert nicht, keiner geht die Liste durch um zu sehen, welche evtl. wieder funktionieren) - [wurden in "ignored" aufgelistet]
- Wunsch:
  --> Datumsauswahl gibt es im alten System schon [im neuen noch nicht]
  --> ABER: wie sich das Ergebnis von gestern auf heute geändert habe (nicht aber von gestern auf vorgestern, das wäre zu dem Zeitpunk bereits bekannt)

Testperson 12:

- ist für einen ganz anderen Kontext zuständig (UI, Weboberfläche)
  --> Daten wurden aus allen Auswertungen rausgenommen

altes System:
- Green Day: nein, weil rot in der Tabelle sichtbar
- Aufgabe 3: "man kann nur raten - es ist nicht rot markiert"
--> könnte alles sein, müssen keine Fehler sein, die angezeigt werden
- es wäre was gutes, wenn man nicht voraussetzt, dass ein Fachfremder das nicht versteht

Dashboard:
- Dashboard ist falsch benannt
- Aufbereitung ist super, intuitiv, ist genau wie man sich das vorstellt

LITERATUR

[Anno9] Anna Schantl. "Emotionale Intelligenz. Analyse von Instruktions- und Reihenfolgeeffekten". Diplomarbeit zur Erlangung des akademischen Grades einer Magistra. Graz: Karl-Franzens Universität Graz, 2009. URL: https://unipub.uni-graz.at/obvugrhs/content/titleinfo/206531/full.pdf.

[Axe25] Axel Kannenberg. *Umfrage: Zu viel ranzige Software in deutschen Firmen*. Hrsg. von heise online. 2025. URL: https://www.heise.de/news/IT-Modernisierung-Unternehmen-muessen-ihren-Legacy-Anwendungen-zu-Leibe-ruecken-10504678.html.

[BD06] Jürgen Bortz und Nicola Döring. *Forschungsmethoden und Evaluation*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006. DOI: 10.1007/978-3-540-33306-7.

[BS10] Jürgen Bortz und Christof Schuster. *Statistik für Human- und Sozialwissenschaftler*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010. DOI: 10.1007/978-3-642-12770-0.

[Dina] *DIN EN ISO 9241-110:2020-10, Ergonomie der Mensch-System-Interaktion- Teil110: Interaktionsprinzipien (ISO 9241-110:2020); Deutsche Fassung EN ISO 9241-110:2020*. Auch als ISO 9241-110:2020; Deutsche Fassung EN ISO 9241-110:2020. DIN, 2020. DOI: 10.31030/3147467.

[Dinb] *DIN EN ISO 9241-210:2011-01, Ergonomie der Mensch-System-Interaktion_- Teil_210: Prozess zur Gestaltung gebrauchstauglicher interaktiver Systeme (ISO_9241-210:2010); Deutsche Fassung EN_ISO_9241-210:2010*. DIN. DOI: 10.31030/1728173.

[EMEG21] Khaled El-Morabea und Hassaan El-Garem. *Modularizing Legacy Projects Using TDD*. Berkeley, CA: Apress, 2021. ISBN: 978-1-4842-7427-9. DOI: 10.1007/978-1-4842-7428-6.

[Fea13] Michael C. Feathers. *Working effectively with legacy code*. 14. print. Robert C. Martin series. Upper Saddle River, N.J.: Prentice Hall, 2013. ISBN: 0131177052.

[Flo24] Florian Stocker. *Legacy-Modernisierung: Modernisierung braucht ein "Warum"*. Hrsg. von Computerwoche. 2024. URL: https://www.computerwoche.de/article/2833820/modernisierung-braucht-ein-warum.html.

[Gas18] Oliver Gast. "Von Usability zu User Experience". In: *User Experience im E-Commerce*. Hrsg. von Oliver Gast. Wiesbaden: Springer Fachmedien Wiesbaden, 2018, S. 13–24. DOI: 10.1007/978-3-658-22484-4_3.

[GraoDa] Grafana Labs, Hrsg. *Build Dashboards*. (o.D.) URL: https://grafana.com/docs/grafana/latest/dashboards/build-dashboards/ (besucht am 03. 09. 2025).

[GraoDb] Grafana Labs, Hrsg. *Create a Dashboard*. (o.D.) URL: https://grafana.com/docs/grafana/latest/dashboards/build-dashboards/create-dashboard/ (besucht am 03. 09. 2025).

[GraoDc] Grafana Labs, Hrsg. *Dashboards*. (o.D.) URL: https://grafana.com/docs/grafana/latest/dashboards/ (besucht am 03. 09. 2025).

[HZW24] Anina Hille, Yvonne Seiler Zimmermann und Gabrielle Wanzenried. "Generationenmanagement als Strategie Gegen Den Fachkräftemangel". In: *Fachkräftemangel und Maßnahmen-Champions*. Hrsg. von Hendrik Budliger. Demografie und Wirtschaft. Wiesbaden: Springer Fachmedien Wiesbaden, 2024, S. 17–35. ISBN: 978-3-658-45363-3. DOI: 10.1007/978-3-658-45364-0{\textunderscore}2.

[Ile03] Ilene Burnstein. *Practical Software Testing: A Process-Oriented Approach*. Springer Professional Computing. New York: Springer-Verlag, 2003. DOI: 10.1007/b97392.

[Mat25] Mathias Jesussek. *t-Test*. Hrsg. von DATAtab. 2025. URL: \url{https://datatab.de/tutorial/t-test} (besucht am 14. 06. 2025).

[Mic23] Michelle Tan. *Celebrating Grafana 10: Top 10 Grafana features you need to know about*. Hrsg. von Grafana Labs. 2023. URL: https://grafana.com/blog/2023/07/14/celebrating-grafana-10-top-10-grafana-features-you-need-to-know-about/ (besucht am 03. 09. 2025).

[Nad22] Nadine Riederer. *Warum die Modernisierung von Legacy-Software längst überfällig ist*. 2022. URL: https://www.it-daily.net/it-management/business-software/warum-die-modernisierung-von-legacy-software-laengst-ueberfaellig-ist.

[Opp25] Philipp Oppel. "Konzeption und prototypische Umsetzung einer No-Code- Plattform zur automatisierten Testerstellung in Projekten mit Software- und Hardwarekomponenten". Diplomarbeit zur Erlangung des akademischen Grades einer Diplom-Ingenieurin. Wien: Technische Universität Wien, 2025. DOI: 10.34726/HSS.2025.130920.

[Pi20] Chenchen Pi. "Development and Classification of Computer Software Testing Technology". In: *Journal of Physics: Conference Series* 1650.3 (2020). ISSN: 1742-6588. DOI: 10.1088/1742-6596/1650/3/032111.

[Proo6] Prof. Dr. Jochen Prümper. *Fragebogen ISONORM 9241/110-S: Beurteilung von Software auf Grundlage der Internationalen Ergonomie-Norm DIN EN ISO 9241-110*. 2006. URL: http://www.uselab.tu-berlin.de/wiki/images/6/62/ISONorm_Kurzversion.pdf (besucht am 09. 07. 2025).

[Prü97] Jochen Prümper. "Der Benutzungsfragebogen ISONORM 9241/10: Ergebnisse zur Reliabilität und Validität". In: *Software-Ergonomie '97*. Hrsg. von Rüdiger Liskowsky, Boris M. Velichkovsky und Wolfgang Wünschmann. Bd. 49. Berichte des German Chapter of the ACM. Wiesbaden: Vieweg+Teubner Verlag, 1997, S. 253–262. ISBN: 978-3-519-02690-7. DOI: 10.1007/978-3-322-86782-7_21.

[Prü+06] Jochen Prümper, K. Pataki, Katharina Sachse und Manfred Thuering. *ISONORM 9241/10-S: Kurzfragebogen zur Software-Evaluation*. Hrsg. von F. Lösel und D. Bender. Nürnberg, 2006. URL: https://www.researchgate.net/publication/323869516_ISONORM_924110-S_Kurzfragebogen_zur_Software-Evaluation (besucht am 09. 07. 2025).

[SR18] Peter Sedlmeier und Frank Renkewitz. *Forschungsmethoden und Statistik für Psychologen und Sozialwissenschaftler*. 3., aktualisierte und erweiterte Auflage. München: Pearson Benelux B.V. (Zweigniederlassung Deutschland), 2018. ISBN: 978-3-86326-808-4.

[SonoDa] Sonar, Hrsg. *Linter IDE Tool und Echtzeitsoftware für Code mit SonarQube for IDE*. (o.D.) URL: https://www.sonarsource.com/de/products/sonarlint/ (besucht am 03. 09. 2025).

[SonoDb] Sonar, Hrsg. *Plans and Pricing*. (o.D.) URL: https://www.sonarsource.com/de/plans-and-pricing/sonarqube/ (besucht am 03. 09. 2025).

[SonoDc] Sonar, Hrsg. *SonarQube*. (o.D.) URL: https://www.sonarsource.com/sem/products/sonarqube/ (besucht am 03. 09. 2025).

[SKK10] Vladimir Stantchev, Hermann Krallmann und Martin Kolbe. "Modernisierung von Legacy Systemen - Statusaufnahme und Handlungsempfehlungen". In: *OBJEKTspektrum* (2010), S. 4–34. URL: https://www.researchgate.net/publication/287210316_Modernisierung_von_Legacy_Systemen_-_Statusaufnahme_und_Handlungsempfehlungen.

[Vol15] Mark Vollrath. *Ingenieurpsychologie: Psychologische Grundlagen und Anwendungsgebiete*. 1. Auflage. Bd. 30. Grundriss der Psychologie. Stuttgart: Kohlhammer Verlag, 2015. ISBN: 978-3-17-022620-3. URL: http://nbn-resolving.org/urn:nbn:de:bsz:24-epflicht-1290446.

[WC95] Christopher D. Wickens und C. Melody Carswell. “The Proximity Compatibility Principle: Its Psychological Foundation and Relevance to Display Design”. In: *Human Factors: The Journal of the Human Factors and Ergonomics Society* 37.3 (1995), S. 473–494. ISSN: 0018-7208. DOI: 10.1518/001872095779049408.

[Wic+13] Christopher D. Wickens, Justin G. Hollands, Simon Banbury und Raja Parasuraman. *Engineering Psychology and Human Performance*. Fourth edition. Boston, MA, USA: Pearson, 2013. ISBN: 978-0-205-02198-7.